

VILNIAUS UNIVERSITETAS  
MATEMATIKOS IR INFORMATIKOS FAKULTETAS

Magistro baigiamasis darbas

Parametrų funkcinių apribojimų testavimas  
integruotų skirtingo dažnio duomenų  
regresiniuose modeliuose

Testing the Functional Constraints on Parameters in  
Regression Models with Integrated Variables of  
Different Frequency

Benediktas Bilinskas

VILNIUS 2013

**MATEMATIKOS IR INFORMATIKOS FAKULTETAS**  
**EKONOMETRINĖS ANALIZĖS KATEDRA**

Darbo vadovas doc. Virmantas Kvedaras \_\_\_\_\_

Darbo recenzentas Dr. Vaidotas Zemlys \_\_\_\_\_

Darbas apgintas 2013 01 11

Darbas įvertintas 10

Registravimo NR. \_\_\_\_\_

Darbas atiduotas į katedrą 2013 01 03

# Turinys

<b>Santrauka / Abstract</b>	<b>2</b>
<b>1 Įvadas</b>	<b>3</b>
<b>2 Parametrų apribojimo funkcijos adekvatumo testavimas integruotų skirtingo dažnio duomenų regresiniame modelyje</b>	<b>5</b>
2.1 Nagrinėjami regresiniai modeliai . . . . .	5
2.2 Parametrų vertinimas . . . . .	7
2.3 Parametrų apribojimo funkcijos adekvatumo testavimas . . . . .	10
<b>3 Parametrų apribojimo funkcijos adekvatumo testavimas integruotų kintamųjų regresiniame modelyje su papildomais paaiškinančiais kintamaisiais</b>	<b>14</b>
3.1 Nagrinėjami regresiniai modeliai ir jų parametrų vertinimas . . . . .	14
3.2 Parametrų apribojimo funkcijos adekvatumo testavimas . . . . .	16
<b>4 Imitacinė analizė</b>	<b>20</b>
4.1 Duomenis generuojantys procesai . . . . .	20
4.2 Testo statistikų empiriniai skirstiniai, kai nulinė hipotezė teisinga . . . . .	22
4.3 Testo statistikų asimptotinis elgesys, kai nulinė hipotezė neteisinga . . . . .	25
4.4 Miller'io parametrų apribojimo funkcijos adekvatumo testas ir jo empirinio reikšmingumo tyrimas . . . . .	25
4.5 Apribojimo funkcijos adekvatumo testų galios palyginimas . . . . .	28
<b>5 Išvados</b>	<b>30</b>
<b>Literatūra</b>	<b>31</b>
<b>I Teiginių įrodymai</b>	<b>32</b>
A Teiginio 2.2 įrodymas . . . . .	32
B Teiginio 2.3 įrodymas . . . . .	41
C Teiginio 3.1 įrodymas . . . . .	45
D Teiginio 3.2 įrodymas . . . . .	52
E Teiginio 3.3 įrodymas . . . . .	55
<b>II Grafikai</b>	<b>58</b>
<b>III Lentelės</b>	<b>64</b>

# Parametrų funkcinių apribojimų testavimas integruotų skirtingo dažnio duomenų regresiniuose modeliuose

## Santrauka

Kvedaras ir Zemlys (2012) pristatė statistinį testą funkciniam parametrų apribojimams tikrinti stacionarių skirtingo dažnio kintamųjų regresiniame modelyje. Šiame darbe testas pritaikomas integruotų skirtingo dažnio kintamųjų regresiniam modeliui. Dviejų kintamųjų regresinis modelis praplečiamas įtraukiant papildomus stacionarius ir integruotus paaiškinančiuosius kintamuosius. Apibrėžiamos kelios testo statistikos ir nustatomas jų asimptotinis elgesys nulinės ir alternatyvios hipotezių atvejais. Taip pat palyginami nagrinėjamo ir Miller (2011) pristatyto testų reikšmingumas ir galia.

**Raktiniai žodžiai:** parametrų apribojimas, integruoti kintamieji, kointegruoti kintamieji, regresinis modelis, skirtingo dažnio, statistinis testas.

# Testing the Functional Constraints on Parameters in Regression Models with Integrated Variables of Different Frequency

## Abstract

Recently, Kvedaras and Zemlys (2012) proposed a statistical test of acceptability of imposed functional constraint on parameters in mixed frequency data regression model with stationary variables. In this paper the test is adapted for the mixed frequency data regression model with integrated variables. Regression model of two variables is extended by inclusion of additional stationary and integrated explanatory variables. Several test statistics are defined and their asymptotic behaviour is characterized under null and alternative hypotheses. Moreover, a comparison of size and power of the investigated test and the test, presented by Miller (2011), is made.

**Key words:** parameter constraint, integrated variables, cointegrated variables, regression model, different frequency, mixed frequency, statistical test.

# 1 Įvadas

Tipiniai laiko eilučių regresiniai modeliai naudoja vienodo dažnio duomenis. Norėdami sudaryti regresinį modelį, turėdami žemo dažnio priklausomąjį kintamąjį ir aukštesnio dažnio paaiškinantįjį kintamąjį, įprastai pastarąjį tradiciniais būdais agreguojame laike. Įprastas agregavimas dažniausiai yra aukštesnio dažnio duomenų vidurkio ar paskutinės reikšmės ėmimas laiko periode. Taip gali būti prarandama dalis informacijos, slypinčios aukšto dažnio duomenų dinamikoje. Be to, kaip parodoma [1], gali būti gaunami nesuderinti parametru įvertiniai. Vienas iš būdų šią informaciją panaudoti yra atsisakyti išankstinio agregavimo ir agregavimo funkcijos parametrus vertinti jų neapribojant. Tačiau tokiu atveju iškyla didelio parametru skaičiaus problema, kada visų jų vertinimas yra neefektyvus ta prasme, kad prarandamas modelio prognozių tikslumas. Kitas būdas panaudoti informaciją, esančią aukšto dažnio duomenyse, siūlomas straipsniuose [4], [5], [6]. Juose pristatyti MIDAS regresiniai modeliai, kuriuose tariama, kad agregavimo funkcijos parametrai yra reikšmės apribojimo funkcijos, priklausančios nuo nedidelio skaičiaus hiper-parametru. Parinkus teisingą apribojimo funkciją, gaunamos tikslesnės priklausomo kintamojo prognozės.

Realybėje tikroji parametru apribojimo funkcija yra nežinoma, todėl iškyla jos parinkimo problema. Straipsnyje [1] pristatytas testas, kuriuo tikrinama hipotezė, kad aukšto dažnio duomenų agregavimas, kai imamas jų vidurkis laiko periode, yra tinkamas prieš bendresnio agregavimo alternatyvą. Tačiau toks testas neatsako į klausimą, ar pasirinkta apribojimo funkcija yra tinkama naudoti, jei tikrieji agregavimo funkcijos parametrai nėra lygūs tarpusavyje. Taigi reikalingi statistiniai testai, skirti tikrinti hipotezę, kad apribojimo funkcija yra parinkta teisingai, t.y., agregavimo funkcijos parametrai gali būti aprašomi pasirinkta apribojimo funkcija. Pastaruoju metu pristatyti du skirtingi testai, skirti tikrinti šią hipotezę. Straipsnyje [12] pateiktas testas, kai aukšto dažnio kintamasis yra stacionarus arba pirmos eilės integruotas procesas. Straipsnyje [8] pasiūlytas kitoks testas, tačiau daroma prielaida, kad modelio kintamieji yra stacionarūs.

Pirmasis šio darbo tikslas yra pritaikyti [8] pristatytą testą atvejui, kai modelio kintamieji yra pirmos eilės integruoti procesai. Nagrinėjamas modelis perrašomas į parametru vertinimo formą, kada priklausomą kintamąjį aprašo aukšto dažnio proceso stacionarūs skirtumai ir vienas liekamasis integruotas narys. Parodoma, kad [8] testo statistika, pritaikyta šiam modeliui, asimptotiškai tebeturi  $\chi^2$  atsitiktinio dydžio skirstinį, jei nulinė hipotezė yra teisinga, ir diverguoja kitu atveju.

Antrasis tikslas yra apibendrinti [8] pristatytą statistinį testą skirtingo dažnio duomenų regresiniam modeliui, į kurį įtraukiami papildomi paaiškinantieji kintamieji, o aukšto dažnio procesas lieka integruotas. Toks apibendrinimas reikalingas dėl galimos praleistų kintamųjų problemos, kada modelio liekanos būtų gaunamos nestacionarios ar koreliuotos su paaiškinančiais kintamaisiais. Apibrėžiama statistika, į kurią simetriškai įeina ir integruoti, ir stacionarūs paaiškinantieji kintamieji, ir kuri, be to, yra paprastas [8] pateiktos statistikos apibendrinimas. Įrodoma, kad statistika pagal pasiskirstymą konverguoja į  $\chi^2$  atsitiktinį dydį, jei apribojimo funkcija yra parinkta teisingai, ir diverguoja kitu atveju.

Straipsnyje [12] pateiktas kitas apribojimo funkcijos adekvatumo statistinis testas. Trečiasis darbo tikslas yra konkretiems duomenis generuojantiems procesams palyginti nagrinėjamą ir [12] pritattytą testus. Jei nulinė hipotezė teisinga, Monte Carlo metodu įvertinami testo statistikų empirinių ir teorinių asimptotinių pasiskirstymų skirtumai. Neteisingos nulinės hipotezės atveju palyginama abiejų testų galia, kuri įvertinama naudojantis Monte Carlo metodu.

Toliau darbas išdėstyta tokiu būdu. Antrame skyriuje [8] pristatytas testas pritaikomas integruotų kintamųjų regresiniam modeliui. Trečiame skyriuje modelis praplečiamas, įtraukiant papildomus paaiškinančiuosius kintamuosius. Apibrėžiamos kelios testo statistikos bei nustatomas jų asimptotinis elgesys. Ketvirtame skyriuje atliekama imitacinė analizė. Penktame skyriuje gauti rezultatai apibendrinami. Ilgesni teiginių įrodymai, didesnės lentelės bei grafikai pateikiami prieduose.

## 2 Parametrų apribojimo funkcijos adekvatumo testavimas integruotų skirtingo dažnio duomenų regresiniame modelyje

Šiame skyriuje parametrų apribojimo funkcijos adekvatumo statistinis testas, aprašytas straipsnyje [8], pritaikomas dviejų integruotų skirtingo dažnio kintamųjų regresiniam modeliui. Skyrelyje 2.1 nagrinėjamas modelis pristatomas ir perrašomas į parametrų vertinimo formą. Taip pat suformuluojamos nulinė ir alternatyvi hipotezės. Skyrelyje 2.2 modelis užrašomas matriciniu pavidalu ir aprašomi du parametrų vertinimo metodai. Pirma, jei nėra naudojama jokia parametrų apribojimo funkcija, parametrus vertiname mažiausių kvadratų metodu (toliau – MKM). Jei parametrus norima apriboti netiesine funkcija, jos parametrai vertinami netiesiniu mažiausių kvadratų metodu (toliau – NMKM). Parametrų apribojimo funkcijos adekvatumo testas aprašomas 2.3 skyrelyje. Jame pateikiamos dvi testo statistikos ir suformuluojami teiginiai apie statistikų asimptotinę elgesį nulinės ir alternatyvios hipotezės atvejais. Šių teiginių įrodymai nukeliami į priedus.

### 2.1 Nagrinėjami regresiniai modeliai

Tegu yra turimi du diskretaus laiko procesai  $y = \{y_t \in \mathbb{R}, t \in \mathbb{N}\}$  ir  $x = \{x_\tau \in \mathbb{R}, \tau \in \mathbb{N}\}$ . Procesai  $y$  ir  $x$  yra tokie, kad laiko momentu  $t$  įvyksta vienas  $y$  stebėjimas  $y_t$ , o tarp  $t - 1$  ir  $t$  įvyksta  $m$  proceso  $x$  stebėjimų  $x_{(t-1)m+1}, \dots, x_{tm}$ . Procesą  $y$  vadinsime žemo dažnio, o  $x$  – aukšto dažnio procesu. Tariame, kad  $m$  yra fiksuotas ir žinomas. Laikome, kad  $x$  yra toks pirmos eilės integruotas procesas:

$$x_\tau = x_{\tau-1} + v_\tau, \quad x_0 = 0, \quad \tau \in \mathbb{N}. \quad (2.1)$$

kur  $v = \{v_\tau \in \mathbb{R}, \tau \in \mathbb{Z}\}$  yra stacionarus procesas,  $Ev_\tau = 0$ . Reikia pastebėti, kad jei stebimas procesas  $x$ , tai stebimas ir procesas  $v$ . Šiame skyriuje nagrinėjamas toks bazinis regresinis modelis:

$$y_t = \sum_{i=0}^d \theta_i x_{tm-i} + u_t, \quad t \in \mathbb{N}. \quad (2.2)$$

Dėl apibrėžtumo, tegu  $x_\tau = 0$ , kai  $\tau < 0$ . Tariame, kad parametrų  $\theta := (\theta_0, \dots, \theta_d)'$  skaičius  $d + 1$  yra žinomas. Parametrai  $\theta$  atitinka gana bendrą aukšto dažnio proceso agregavimą, kada įprastas agregavimo formas galima užrašyti kaip atskirus  $\theta$  įgyjamų reikšmių atvejus. Pavyzdžiui, atveju  $d + 1 = m$  vidurkio agregavimą periode atitinka  $\theta_i = \theta_j$  atvejis,  $i, j = 1, \dots, m$ .

Modelio (2.2) liekanos tenkina tokią prielaidą.

**Prielaida P1.**  $\{u_t, t \in \mathbb{Z}\}$  yra n.v.p. atsitiktiniai dydžiai,  $Eu_t = 0$ ,  $Eu_t^2 = \sigma_u^2$ ,  $Eu_t^4 < \infty$ ,  $\forall t \in \mathbb{Z}$ . Be to, procesai  $u$  ir  $v$  yra nepriklausomi.

Čia n.v.p. – nepriklausomi ir vienodai pasiskirstę. Prielaida P1 bus naudojama, ieškant

toliau šiame skyriuje apibrėžtų testo statistikų asimptotinio elgesio.

Kadangi procesas  $x$  laikomas integruotu, (2.2) modelio paaiškinantieji kintamieji yra stipriai koreliuoti. Perrašykime modelį į tokią formą, kad tarp paaiškinančiųjų kintamųjų būtų tik vienas integruotas narys. Pasinaudojus (2.1) ir (2.2), gauname, kad

$$\begin{aligned} y_t &= \left( \sum_{i=0}^d \theta_i \right) x_{tm-d} + \theta_0 \sum_{j=0}^{d-1} v_{tm-j} + \theta_1 \sum_{j=1}^{d-1} v_{tm-j} + \cdots + \theta_{d-1} v_{tm-(d-1)} + u_t \\ &= \left( \sum_{i=0}^d \theta_i \right) x_{tm-d} + \theta_0 v_{tm} + (\theta_0 + \theta_1) v_{tm-1} + \cdots + (\theta_0 + \theta_1 + \cdots + \theta_{d-1}) v_{tm-(d-1)} + u_t. \end{aligned}$$

Taigi (2.2) modelį galima užrašyti taip:

$$y_t = \sum_{i=0}^{d-1} \beta_i v_{tm-i} + \beta_d x_{tm-d} + u_t, \quad (2.3)$$

kur

$$\beta_i := \sum_{j=0}^i \theta_j, \quad i = 0, \dots, d.$$

Dar kartą pasinaudojus (2.1), turime, kad  $\beta_d x_{tm-d} = \beta_d x_{tm-d-1} + \beta_d v_{tm-d}$ . Taigi (2.3) modelį užrašome taip:

$$y_t = \sum_{i=0}^d \beta_i v_{tm-i} + \beta_d x_{tm-d-1} + u_t, \quad (2.4)$$

Nors parametrai  $\beta_0, \dots, \beta_d$  gali būti vertinami MKM, esant dideliui parametų skaičiui  $d+1$ , MKM įvertinių dispersija gali būti didelė. MIDAS regresijoje tariama, kad (2.2) modelio parametrai  $\theta$  yra parametrinės funkcijos  $g : \Lambda_g \times \mathbb{N} \rightarrow \mathbb{R}$ ,  $\Lambda_g \subset \mathbb{R}^q$ , reikšmės, t.y.,

$$\theta_i = g(\lambda, i), \quad i = 0, \dots, d, \quad \lambda \in \Lambda_g. \quad (2.5)$$

Funkciją  $g$  vadinsime parametų apribojimo funkcija. Paprastai tariama, kad parametų  $\lambda$  skaičius  $q$  yra žymiai mažesnis nei  $d+1$ . Pavyzdžiui, literatūroje dažnai naudojama vadinama „Almon lag“ apribojimo funkcija, turinti tokią formą:

$$g(\lambda, i) = \lambda_1 \frac{\exp(\lambda_2 i^1 + \dots + \lambda_q i^{q-1})}{\sum_{j=0}^d \exp(\lambda_2 j^1 + \dots + \lambda_q j^{q-1})}, \quad i \in \mathbb{N}.$$

Natūralu laikyti, kad tikroji parametų  $\theta$  apribojimo funkcija  $g$  nėra žinoma. Gali būti, kad  $\theta$  apskritai negali būti aprašomi mažai parametų turinčia funkcija. Tegu yra pasirenkama parametų apribojimo funkcija  $h : \Lambda \times \mathbb{N} \rightarrow \mathbb{R}$ , kur  $\Lambda \subset \mathbb{R}^r$ . Formaliai užrašykime nulinę hipotezę  $H_0$  ir jos alternatyvą  $H_1$ .

$$H_0 : \exists \gamma \in \Lambda, \text{ kad } \theta_i = h(\gamma, i), \forall i \in \{0, \dots, d\}; \quad (2.6)$$

$$H_1 : \exists i \in \{0, \dots, d\}, \text{ kad } \theta_i \neq h(\gamma, i), \forall \gamma \in \Lambda. \quad (2.7)$$



Straipsnyje [8] pristatytas apribojimo funkcijos  $h$  adekvatumo testas, kuriuo tikrinama  $H_0$  prieš alternatyvą  $H_1$ , kai modelyje (2.2) aukšto dažnio procesas  $x$  yra stacionarus. Šio skyriaus tikslas yra pritaikyti [8] testą, kai  $x$  yra pirmos eilės integruotas procesas.

Tegu  $f : \Lambda \times \mathbb{N} \rightarrow \mathbb{R}$ ,  $\Lambda \subset \mathbb{R}^r$ , yra spėjama parametrų  $\beta_0, \dots, \beta_d$  apribojimo funkcija. Tuo atveju, kai manoma, kad  $h$  yra parametrų  $\theta_0, \dots, \theta_d$  apribojimo funkcija, imame  $f(\gamma, i) = \sum_{j=0}^i h(\gamma, j)$ ,  $i = 0, \dots, d$ . Modelis (2.4) su spėjama parametrų  $\beta_0, \dots, \beta_d$  apribojimo funkcija  $f$  užrašomas taip:

$$y_t = \sum_{i=0}^d f(\gamma, i) v_{tm-i} + \beta_d x_{tm-d-1} + e_t, \quad (2.8)$$

$$e_t := u_t + \sum_{i=0}^d (\beta_i - f(\gamma, i)) v_{tm-i}. \quad (2.9)$$

Jeigu funkcija  $f$  yra pasirinkta teisingai<sup>1</sup>, (2.8) modelyje liekanos  $e_t$  tampa  $u_t$ , jei  $\gamma \in \Lambda$  yra toks, kad  $\beta_i = f(\gamma, i)$ ,  $i = 0, \dots, d$ .

## 2.2 Parametrų vertinimas

Šiame skyrelyje aprašomi (2.4) ir (2.8) modelių parametrų vertinimo metodai. Iš pradžių (2.4) modelis užrašomas matriciniu pavidalu, apibrėžiami parametrų MKM įvertiniai. Antroje skyrelio dalyje apibrėžiami (2.8) modelio parametrų NMKM įvertiniai.

Tegu yra turimi procesų  $y$  ir  $x$  stebėjimai  $\{y_t\}_{t=1}^n$  ir  $\{x_\tau\}_{\tau=1}^{nm}$ . Panašiai kaip [8], perrašyime (2.4) modelį matriciniu pavidalu. Dėl modelyje esančių proceso  $x$  vėlavimų, pirmas efektyvus  $y$  stebėjimas įvyksta laiko momentu  $t_1$ :

$$t_1 = \begin{cases} \lfloor d/m \rfloor + 2, & \text{jei } d+1 = mj \text{ kažkuriam } j \in \mathbb{N}; \\ \lfloor d/m \rfloor + 1, & \text{kitu atveju.} \end{cases} \quad (2.10)$$

Įveskime tokius pažymėjimus:

$$\mathbf{y} := (y_{t_1}, y_{t_1+1}, \dots, y_n)', \quad \mathbf{u} := (u_{t_1}, u_{t_1+1}, \dots, u_n)', \quad (2.11)$$

$$\mathbf{X} := (x_{t_1 m - d - 1}, x_{(t_1+1)m - d - 1}, \dots, x_{nm - d - 1})', \quad (2.12)$$

$$\mathbf{V} := \begin{bmatrix} v_{t_1 m} & v_{t_1 m - 1} & \dots & v_{t_1 m - d} \\ v_{(t_1+1)m} & v_{(t_1+1)m - 1} & \dots & v_{(t_1+1)m - d} \\ \vdots & \vdots & \dots & \vdots \\ v_{nm} & v_{nm - 1} & \dots & v_{nm - d} \end{bmatrix}, \quad \mathbf{Z} := [\mathbf{V} \quad \mathbf{X}], \quad (2.13)$$

$$\beta_{0,d} := (\beta_0, \dots, \beta_d)', \quad \beta := (\beta'_{0,d}, \beta_d)'. \quad (2.14)$$

Pažymėkime vektorių  $\mathbf{y}$ ,  $\mathbf{u}$  ilgį ir matricos  $\mathbf{Z}$  eilučių skaičių  $n_d := n - t_1 + 1$ . Apibrėžtiems

<sup>1</sup> Vietoje „galioja  $H_0$ “ dažnai sakysime „apribojimo funkcija parinkta teisingai“. Panašiai, „apribojimo funkcija parinkta neteisingai“ reikš „galioja  $H_1$ “, „negalioja  $H_0$ “ ir pan.

duomenims (2.4) modelis matriciniu pavidalu užrašomas taip:

$$\mathbf{y} = \mathbf{V}\beta_{0,d} + \mathbf{X}\beta_d + \mathbf{u} = \mathbf{Z}\beta + \mathbf{u}. \quad (2.15)$$

Parametrų  $\beta$  MKM įvertiniai  $\hat{\beta}$  yra:

$$\hat{\beta} := \arg \min_{\beta \in \mathbb{R}^{d+2}} [n_d^{-1} (\mathbf{y} - \mathbf{Z}\beta)' (\mathbf{y} - \mathbf{Z}\beta)] = (\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{y}. \quad (2.16)$$

Kadangi parametrų  $\beta$  skaičius yra  $d + 2$ , liekanų dispersijos  $\sigma_u^2$  įprastinis įvertis  $\hat{\sigma}_u^2$  yra:

$$\hat{\sigma}_u^2 := \frac{1}{n_d - d - 2} (\mathbf{y} - \mathbf{Z}\hat{\beta})' (\mathbf{y} - \mathbf{Z}\hat{\beta}).$$

Užrašykime (2.8) modelį matriciniu pavidalu. Panašiai kaip ir [8], tegu  $\mathbf{f} : \Lambda \rightarrow \mathbb{R}^{d+1}$  yra tokia vektorinė funkcija:

$$\mathbf{f}(\gamma) := (f(\gamma, 0), f(\gamma, 1), \dots, f(\gamma, d))'. \quad (2.17)$$

Hiper-parametrų  $\gamma$  vektorių papildykime koeficientu  $\beta_d$  ir naują  $r + 1$  ilgio vektorių pažymėkime  $\psi$ , t.y.,  $\psi := (\gamma', \beta_d)'$ . Funkciją  $\tilde{\mathbf{f}} : \Lambda \times \mathbb{R} \rightarrow \mathbb{R}^{d+2}$  apibrėžkime taip:

$$\tilde{\mathbf{f}}(\psi) := (\mathbf{f}(\gamma)', \beta_d)'. \quad (2.18)$$

Naudojantis įvestais pažymėjimais, (2.8) modelį galima užrašyti matriciniu pavidalu:

$$\mathbf{y} = \mathbf{V}\mathbf{f}(\gamma) + \mathbf{X}\beta_d + \mathbf{e} = \mathbf{Z}\tilde{\mathbf{f}}(\psi) + \mathbf{e}, \quad (2.18)$$

$$\mathbf{e} = \mathbf{u} + \mathbf{V}(\beta_{0,d} - \mathbf{f}(\gamma)). \quad (2.19)$$

Reikia pastebėti, kad lygybė (2.18) su (2.19) apibrėžtomis liekanomis teisinga  $\forall \gamma \in \Lambda$ . Jeigu egzistuoja toks  $\gamma \in \Lambda$ , kad  $\mathbf{f}(\gamma) = \beta_{0,d}$ , tuomet šiam  $\gamma$ ,  $\mathbf{e} = \mathbf{u}$ . Modelis (2.18) bendru atveju yra netiesinis parametrų  $\gamma$  atžvilgiu. Parametras  $\beta_d$  prie  $\tilde{\mathbf{X}}$  vertinamas kaip neapribotas. Kadangi spėjama, kad  $f(\gamma, d) = \beta_d$ , kitu atveju  $\beta_d$  galima būtų vertinti kaip apribotą. Toks atvejis šiame darbe nenagrinėjamas.

Toliau bus apibrėžti parametrų  $\gamma$  ir  $\beta_d$  NMKM įvertiniai. Tariame, kad apribojimo funkcija  $f$  tenkina sekančią prielaidą.

**Prielaida P2.** *Apribojimo funkcija  $f : \Lambda \times \mathbb{N} \rightarrow \mathbb{R}$  yra tolydi ir du kartus diferencijuojama parametrų  $\gamma \in \Lambda$  atžvilgiu.*

Tegu  $(d + 1) \times r$  matrica  $\mathbf{D}_{f,\gamma}$  žymi funkcijos  $\mathbf{f}$  Jakobiano matricą taške  $\gamma = (\gamma_1, \dots, \gamma_r)'$ :

$$\mathbf{D}_{f,\gamma} := \frac{\partial \mathbf{f}}{\partial \gamma'}(\gamma) = \left[ \frac{\partial \mathbf{f}}{\partial \gamma_1}(\gamma), \dots, \frac{\partial \mathbf{f}}{\partial \gamma_r}(\gamma) \right]. \quad (2.20)$$

Darbe funkcijos Jakobiano matricą vadinsime tiesiog Jakobianu. Kadangi funkcija  $f$  yra

du kartus diferencijuojama, tai matricos  $\mathbf{D}_{f,\gamma}$  elementai yra diferencijuojamos funkcijos. Kadangi diferencijuojama funkcija turi būti tolydi, tai  $\mathbf{D}_{f,\gamma}$  elementai yra tolydžios funkcijos. Šis faktas bus reikalingas kitame skyrelyje. Panašiai,  $\mathbf{D}_{\tilde{f},\psi}$  pažymėkime funkcijos  $\tilde{f}$  Jakobianą taške  $\psi = (\gamma', \beta_d)'$ :

$$\mathbf{D}_{\tilde{f},\psi} := \frac{\partial \tilde{f}}{\partial \psi'}(\psi) = \left[ \frac{\partial \tilde{f}}{\partial \gamma_1}(\psi), \dots, \frac{\partial \tilde{f}}{\partial \gamma_r}(\psi), \frac{\partial \tilde{f}}{\partial \beta_d}(\psi) \right].$$

Kadangi  $\frac{\partial f}{\partial \beta_d}(\psi) = \mathbf{0}$ ,  $\frac{\partial \beta_d}{\partial \gamma'}(\psi) = \mathbf{0}$ ,  $\frac{\partial f}{\partial \gamma'}(\psi) = \mathbf{D}_{f,\gamma}$ ,  $\frac{\partial \beta_d}{\partial \beta_d}(\psi) = 1$ , tai  $(d+2) \times (r+1)$  matricą  $\mathbf{D}_{\tilde{f},\psi}$  galima suskaidyti į keturias dalis taip:

$$\mathbf{D}_{\tilde{f},\psi} = \mathbf{D}_{\tilde{f},\gamma} = \begin{bmatrix} \mathbf{D}_{f,\gamma} & \mathbf{0} \\ \mathbf{0} & 1 \end{bmatrix}. \quad (2.21)$$

Tariame, kad apribojimo funkcija  $f$  yra sudaryta taip, kad jos parametrai  $\gamma$  yra identifikuojami, kas šiame darbe ekvivalentu sąlygai, kad  $\mathbf{D}_{f,\gamma}$  yra pilno rango, t.y.,  $\mathbf{D}_{f,\gamma}$  rangas lygus jos stulpelių skaičiui  $r$ . Taip pat tariame, kad  $d+1 > r$ . Kitu atveju koeficientus  $\beta_{0,d}$  apriboti nebūtų prasmės.

NMKM įvertiniai  $\hat{\psi} := (\hat{\gamma}', \hat{\beta}_d^{nls})'$ , pagal metodo apibrėžimą, randami minimizuojant modelio liekanų kvadratų vidurkį:

$$\begin{aligned} \hat{\psi} &:= \arg \min_{\gamma \in \Lambda, \beta_d \in \mathbb{R}} \left[ n_d^{-1} (\mathbf{y} - \mathbf{V}f(\gamma) - \mathbf{X}\beta_d)' (\mathbf{y} - \mathbf{V}f(\gamma) - \mathbf{X}\beta_d) \right] \\ &= \arg \min_{\psi \in (\Lambda \times \mathbb{R})} \left[ n_d^{-1} (\mathbf{y} - \mathbf{Z}\tilde{f}(\psi))' (\mathbf{y} - \mathbf{Z}\tilde{f}(\psi)) \right]. \end{aligned} \quad (2.22)$$

NMKM įvertiniai  $\hat{\psi}$ , kaip ir [8], tenkina tokią pirmos eilės sąlygą:

$$\mathbf{D}'_{\tilde{f},\hat{\gamma}} \mathbf{Z}' (\mathbf{y} - \mathbf{Z}\tilde{f}(\hat{\psi})) = \mathbf{0}. \quad (2.23)$$

**Prielaida P3.**  $\exists \text{ plim} \hat{\psi}$ , kai  $n_d \rightarrow \infty$ , kur  $\hat{\psi}$  yra (2.18) modelio NMKM įvertiniai, apibrėžti (2.22) ir tenkinantys sąlygą (2.23).<sup>2</sup>

Remiantis prielaida P3, lengviau parodyti, kad, pasirinkus tikrą apribojimo funkciją  $f$ , parametrai  $\hat{\gamma}$  yra suderinti. Kaip teigiama [3] (p. 216), prielaida P3 yra būtina tam, kad

---

<sup>2</sup> Žymėjimas  $\hat{\gamma} \xrightarrow{P} \gamma$  arba  $\gamma = \text{plim} \hat{\gamma}$ , kai  $n_d \rightarrow \infty$ , šiame darbe reiškia, kad atsitiktinių vektorių  $\hat{\gamma} = \hat{\gamma}(n_d) = \hat{\gamma}(\mathbf{y}(n_d), \mathbf{Z}(n_d))$  seka  $\{\hat{\gamma}(n_d)\}_{n_d=1}^{\infty}$  konverguoja į neatsitiktinį vektorių  $\gamma$  pagal tikimybę, kai  $n_d \rightarrow \infty$ , o tai savo ruožtu reiškia, kad  $\forall i \in \{1, \dots, r\}$ , seka  $\{\hat{\gamma}_i(n_d)\}_{n_d=1}^{\infty}$  konverguoja į skaičių  $\gamma_i$  pagal tikimybę, kai  $n_d \rightarrow \infty$ . Pagal apibrėžimą,  $\hat{\gamma}_i \xrightarrow{P} \gamma_i$ , kai  $n_d \rightarrow \infty$ , jei  $\forall \varepsilon > 0$  ir  $\forall \delta > 0 \exists N$  toks, kad  $P(|\hat{\gamma}_i(n_d) - \gamma_i| > \delta) < \varepsilon$ ,  $\forall n_d > N$ .

Žymėjimas  $X = X(n_d) \xrightarrow{d} Y$  arba  $Y = \text{dlim} X(n_d)$ , kai  $n_d \rightarrow \infty$ , šiame darbe reiškia, kad atsitiktinių dydžių seka  $\{X(n_d)\}_{n_d=1}^{\infty}$  konverguoja pagal pasiskirstymą į atsitiktinį dydį  $Y$ , t.y.,  $\{X(n_d)\}_{n_d=1}^{\infty}$  pasiskirstymo funkcijų seka konverguoja į  $Y$  pasiskirstymo funkciją kiekviename tolydumo taške, kai  $n_d \rightarrow \infty$ . Lygiai taip pat apibrėžiamas atsitiktinių vektorių ar matricų sekų konvergavimas pagal pasiskirstymą. Apibrėžimai paimti iš [7]. Teiginių įrodymuose sąlygą  $n_d \rightarrow \infty$  praleisime kaip savaime aiškia.

NMKM įvertiniai būtų suderinti, tačiau jos įrodymas yra gana sudėtingas net laiko atžvilgiu nepriklausomų kintamųjų atveju. Pagal šią prielaidą, net ir neteisingai pasirinkus apribojimo funkciją, įvertiniai  $\hat{\psi}$  pagal tikimybę konverguoja į kažkokį neatsitiktinį vektorių. Šis faktas bus naudingas nustatant kitame skyrelyje apibrėžtų testo statistikų asimptotinių elgesį alternatyvios hipotezės atveju.

## 2.3 Parametrų apribojimo funkcijos adekvatumo testavimas

Šiame skyrelyje aprašomas parametrų apribojimo funkcijos adekvatumo statistinis testas. Hipotezėms  $H_0$  ir  $H_1$  iš (2.6) ir (2.7) suformuluojamos ekvivalenčios hipotezės, kurioms tiesiogiai tikrinti ir konstruojamas testas. Apibrėžiamos dvi statistikos ir nustatomas jų asimptotinis elgesys  $H_0$  ir  $H_1$  atvejais.

Tegu  $h : \Lambda \times \mathbb{N} \rightarrow \mathbb{R}$  yra spėjama parametrų  $\theta_0, \dots, \theta_d$  apribojimo funkcija (2.2) modelyje. Pažymėkime  $f(\gamma, i) = \sum_{j=0}^i h(\gamma, j)$ ,  $i = 0, \dots, d$ . Suformuluokime ekvivalenčias hipotezes  $\tilde{H}_0$  ir  $\tilde{H}_1$  hipotezėms  $H_0$  ir  $H_1$ , kurios apibrėžtos atitinkamai (2.6) ir (2.7).

$$\tilde{H}_0 : \exists \gamma \in \Lambda, \text{ kad } \beta_i = f(\gamma, i), \forall i \in \{0, \dots, d\}; \quad (2.24)$$

$$\tilde{H}_1 : \exists i \in \{0, \dots, d\}, \text{ kad } \beta_i \neq f(\gamma, i), \forall \gamma \in \Lambda. \quad (2.25)$$

Čia  $\beta_0, \dots, \beta_d$  yra (2.4) modelio parametrai. Tuomet galioja toks teiginys.

**Teiginys 2.1** Jei  $f(\gamma, i) = \sum_{j=0}^i h(\gamma, j)$ ,  $i = 0, \dots, d$ , tai  $H_0 \iff \tilde{H}_0$ ,  $H_1 \iff \tilde{H}_1$ .

### Įrodymas.

Tegu teisinga  $H_0$ . Fiksuokime  $\gamma \in \Lambda$  tokį, kad  $\theta_i = h(\gamma, i)$ ,  $i = 0, \dots, d$ . Tada  $f(\gamma, i) = \sum_{j=0}^i h(\gamma, j) = \sum_{j=0}^i \theta_j = \beta_i$ ,  $\forall i \in \{0, \dots, d\}$ . Taigi  $H_0 \implies \tilde{H}_0$ .

Tegu teisinga  $\tilde{H}_0$ . Fiksuokime  $\gamma \in \Lambda$  tokį, kad  $\beta_i = f(\gamma, i)$ ,  $i = 0, \dots, d$ . Tada  $h(\gamma, i) = f(\gamma, i) - f(\gamma, i-1) = \beta_i - \beta_{i-1} = \theta_i$ ,  $\forall i \in \{1, \dots, d\}$ .  $i = 0$  atveju  $h(\gamma, 0) = f(\gamma, 0) = \beta_0 = \theta_0$ . Taigi  $\tilde{H}_0 \implies H_0$ .

Tegu teisinga  $H_1$ . Fiksuokime bet kurį  $\gamma \in \Lambda$ . Jeigu  $h(\gamma, 0) \neq \theta_0$ , tai  $f(\gamma, 0) = h(\gamma, 0) \neq \theta_0 = \beta_0$ . Jeigu  $h(\gamma, 0) = \theta_0$ , imame pirmą aibės  $\{1, \dots, d\}$  narį  $i$  tokį, kad  $h(\gamma, i) \neq \theta_i$ . Kadangi  $f(\gamma, i-1) = \beta_{i-1}$ , tai  $f(\gamma, i) = f(\gamma, i-1) + h(\gamma, i) \neq \beta_i$ . Taigi  $H_1 \implies \tilde{H}_1$ .

Tegu teisinga  $\tilde{H}_1$ . Fiksuokime bet kurį  $\gamma \in \Lambda$ . Jeigu  $f(\gamma, 0) \neq \beta_0$ , tai  $h(\gamma, 0) = f(\gamma, 0) \neq \beta_0 = \theta_0$ . Jeigu  $f(\gamma, 0) = \beta_0$ , imame pirmą aibės  $\{1, \dots, d\}$  narį  $i$  tokį, kad  $f(\gamma, i) \neq \beta_i$ . Tada  $h(\gamma, i) = f(\gamma, i) - f(\gamma, i-1) \neq \beta_i - \beta_{i-1} = \theta_i$ . Taigi  $\tilde{H}_1 \implies H_1$ .  $\square$

Iš teiginio (2.1) išplaukia, kad (2.6) apibrėžtą hipotezę  $H_0$  galima patikrinti, sukonstravus statistinį testą parametrų  $\beta_{0,d}$  apribojimo funkcijos  $f$  adekvatumui tikrinti. Taigi, nors testas konstruojamas hipotezei  $\tilde{H}_0$  tikrinti, jos atmetimas (neatmetimas) reiškia ir hipotezės  $H_0$  atmetimą (neatmetimą). Pastebėkime, kad į (2.15) modelį parametras  $\beta_d$  įeina du kartus. Vienu atveju jis yra prie stacionaraus kintamojo, kitu atveju – prie integruoto kintamojo. Vadinasi, yra gaunami du parametro  $\beta_d$  įverčiai. Taip yra daroma dėl to, kad galiotų 2.1

teiginys. Kitu atveju gali būti iškart manoma, kad pasirinkta funkcija  $\mathbf{f}(\boldsymbol{\gamma})$  yra parametrų  $\boldsymbol{\beta}_{0,d}$  apribojimo funkcija. Tada  $h(\boldsymbol{\gamma}, i) := f(\boldsymbol{\gamma}, i) - f(\boldsymbol{\gamma}, i - 1)$  yra parametrų  $\boldsymbol{\theta}$  apribojimo funkcija (2.2) modelyje.

Tam, kad vėliau būtų galima pasinaudoti iš funkcinės centrinės ribinės teoremos išvestais rezultatais, įveskime papildomą prielaidą. Sudarykime procesą  $\tilde{\mathbf{v}} = \{\tilde{\mathbf{v}}_t \in \mathbb{R}^{d+1}, t \in \mathbb{Z}\}$  taip:

$$\tilde{\mathbf{v}}_t := (v_{tm}, v_{tm-1}, \dots, v_{tm-d})'. \quad (2.26)$$

**Prielaida P4.**  $\tilde{\mathbf{v}}_t = \sum_{j=0}^{\infty} \mathbf{W}_j \boldsymbol{\varepsilon}_{t-j}$ , kur  $\{\boldsymbol{\varepsilon}_t, t \in \mathbb{Z}\}$  yra n.v.p. atsitiktiniai vektoriai, turintys baigtinius ketvirtus momentus<sup>3</sup>,  $\mathbf{E}\boldsymbol{\varepsilon}_t = \mathbf{0}$ , kovariacijų matrica  $\mathbf{E}(\boldsymbol{\varepsilon}_t \boldsymbol{\varepsilon}_t')$  yra simetrinė ir teigiamai apibrėžta. Matricių seka  $\{j\mathbf{W}_j\}_{j=0}^{\infty}$  yra absoliučiai sumuojama, t.y., jei  $W_{j,kl}$  pažymėsime matricos  $\mathbf{W}_j$   $k$ -osios eilutės ir  $l$ -ojo stulpelio narį, tai  $\sum_{j=0}^{\infty} j|W_{j,kl}| < \infty$ ,  $\forall k, l = 1, \dots, d+1$ . Be to, matrica  $\mathbf{Q} := \mathbf{E}(\tilde{\mathbf{v}}_t \tilde{\mathbf{v}}_t')$  yra teigiamai apibrėžta.

Kaip ir straipsnyje [12], kuriame pristatomas kitas apribojimo funkcijos adekvatumo testas, prielaida P4 nusako jau agreguotų žemo dažnio procesų, įeinančių į duomenų matricos  $\mathbf{Z}$  eilutes, struktūrą. Tačiau, kaip teigiama [12], prielaida P4 gali būti išvesta iš panašios aukšto dažnio proceso struktūros<sup>4</sup>. Ši prielaida reikalinga tam, kad būtų galima rasti sumų  $\mathbf{Z}'\mathbf{Z}$  ir  $\mathbf{Z}'\mathbf{u}$  konvergavimo pagal pasiskirstymą greičius, pasiremiant [7] teiginiu 18.1 (p. 547).

Testo statistikos pagrindą sudaro skirtumas tarp MKM įverčių  $\hat{\boldsymbol{\beta}}_{0,d}$  ir NMKM įverčių  $\mathbf{f}(\hat{\boldsymbol{\gamma}})$ . Pagal [8] idėją, esant parinktai teisingai apribojimo funkcijai, tiek MKM įvertiniai  $\hat{\boldsymbol{\beta}}_{0,d}$ , tiek NMKM įvertiniai  $\mathbf{f}(\hat{\boldsymbol{\gamma}})$ , augant imties dydžiui  $n_d$ , pagal tikimybę turi artėti į tą patį tikrųjų parametrų vektorių  $\boldsymbol{\beta}_{0,d}$ . Jeigu apribojimo funkcija yra pasirenkama neteisingai, tuomet, MKM įvertiniams  $\hat{\boldsymbol{\beta}}_{0,d}$  liekant suderintais,  $\mathbf{f}(\hat{\boldsymbol{\gamma}})$  negali pagal tikimybę artėti į  $\boldsymbol{\beta}_{0,d}$ .

Toliau įveskime pažymėjimus, reikalingus testo statistikai apibrėžti. Simboliu  $\Delta_{\mathbf{f}, \hat{\boldsymbol{\gamma}}}$  Pažymėkime tokią  $(d+1) \times (d+1)$  matricą:

$$\Delta_{\mathbf{f}, \hat{\boldsymbol{\gamma}}} := \mathbf{D}_{\mathbf{f}, \hat{\boldsymbol{\gamma}}} (\mathbf{D}_{\mathbf{f}, \hat{\boldsymbol{\gamma}}}^{\prime} n_d^{-1} \mathbf{V}' \mathbf{V} \mathbf{D}_{\mathbf{f}, \hat{\boldsymbol{\gamma}}})^{-1} \mathbf{D}_{\mathbf{f}, \hat{\boldsymbol{\gamma}}}^{\prime}.$$

Tegu  $\mathbf{F}_{\mathbf{V}}$  yra matrica, gauta taikant Cholesky dekompoziciją matricai  $n_d^{-1} \mathbf{V}' \mathbf{V}$ , tai yra,  $n_d^{-1} \mathbf{V}' \mathbf{V} = \mathbf{F}_{\mathbf{V}} \mathbf{F}_{\mathbf{V}}'$ .<sup>5</sup> Apibrėžkime tokį atsitiktinį vektorių  $\mathbf{h}_1$ :

$$\mathbf{h}_1 := \frac{\sqrt{n_d}}{\hat{\sigma}_u} \mathbf{F}_{\mathbf{V}}' (\hat{\boldsymbol{\beta}}_{0,d} - \mathbf{f}(\hat{\boldsymbol{\gamma}})).$$

<sup>3</sup> $\mathbf{E}|\varepsilon_{t,k_1} \varepsilon_{t,k_2} \varepsilon_{t,k_3} \varepsilon_{t,k_4}| < \infty$ ,  $\forall k_1, k_2, k_3, k_4 = 1, \dots, d+1$ , kur  $\boldsymbol{\varepsilon}_t = (\varepsilon_{t,1}, \dots, \varepsilon_{t,d+1})'$ .

<sup>4</sup>Tarkime  $x_{\tau} = \sum_{j=0}^{\infty} w_j \varepsilon_{\tau-j}$ ,  $\sum_{j=0}^{\infty} j|w_j| < \infty$  ir  $\{\varepsilon_{\tau}, \tau \in \mathbb{Z}\}$  yra n.v.p.a.d. Nesunkiai galima parodyti, kad procesą  $\tilde{\mathbf{v}}$  galima užrašyti prielaidoje P4 nurodytu būdu (sunkiau būtų įrodyti, kad  $\mathbf{Q}$  yra teigiamai apibrėžta). Vadinasi, tokia prielaida būtų tik stipresnė už prielaidą P4.

<sup>5</sup>Kadangi  $\mathbf{V}' \mathbf{V}$  yra atsitiktinė matrica, tai ji yra teigiamai apibrėžta beveik tikrai. Sąlygą „beveik tikrai“, kai kalbėsime apie atsitiktinių matricių rangą, praleisime.

Imkime tokį  $\mathbf{h}_1$  kovariacijų matricos įvertinį  $\hat{\Sigma}_{\mathbf{h}_1}$ :

$$\hat{\Sigma}_{\mathbf{h}_1} := \mathbf{I}_{d+1} - \mathbf{F}'_V \Delta_{f,\hat{\gamma}} \mathbf{F}_V. \quad (2.27)$$

Testo statistika  $T_1$  apibrėžiama taip:

$$T_1 := \mathbf{h}'_1 \hat{\Sigma}_{\mathbf{h}_1} \mathbf{h}_1.$$

**Teiginys 2.2** *Jei galioja prielaidos P1-P4, tai:*

- jei  $\tilde{H}_0$  teisinga, tai  $T_1 \xrightarrow{d} \chi^2(d+1-r)$ , kai  $n_d \rightarrow \infty$ ;
- jei  $\tilde{H}_1$  teisinga, tai  $T_1 \xrightarrow{p} \infty$ , kai  $n_d \rightarrow \infty$ .

Teiginio 2.2 įrodymas nukeltas į priedą A.  $\tilde{H}_0$  atveju bendras įrodymo planas atitinka [8] teoremos 1 įrodymo planą. Parodoma, kad  $\mathbf{h}_1$  yra asimptotiškai pasiskirstęs pagal normalųjį dėsnį su nuliniu vidurkių vektoriumi ir kovariacijų matrica, pažymėkime,  $\Sigma_{\mathbf{h}_1}$ . Tada parodoma, kad  $\hat{\Sigma}_{\mathbf{h}_1} \xrightarrow{p} \Sigma_{\mathbf{h}_1}$ , kai  $n_d \rightarrow \infty$ . Galiausiai įrodoma, kad  $\text{rank}(\hat{\Sigma}_{\mathbf{h}_1}) = \text{rank}(\Sigma_{\mathbf{h}_1}) = d+1-r$ . Įrodžius paminėtus faktus, galima pasiremti [2] teorema 1, kurioje teigiama, kad  $\mathbf{h}_1 \hat{\Sigma}_{\mathbf{h}_1}^- \mathbf{h}_1 \xrightarrow{d} \chi^2(d+1-r)$ , kur  $\hat{\Sigma}_{\mathbf{h}_1}^-$  yra matricos  $\hat{\Sigma}_{\mathbf{h}_1}$  apibendrinta atvirkštinė matrica<sup>6</sup>. Matrica  $\hat{\Sigma}_{\mathbf{h}_1}$  yra idempotentinė<sup>7</sup> ir simetrinė, todėl, remiantis [10], jos apibendrinta atvirkštinė matrica lygi jai pačiai. Jei galioja  $\tilde{H}_1$ , parodoma, kad  $n_d^{-1}T_1$  pagal tikimybę artėja į teigiamą skaičių. Tuo remiantis daroma išvada, kad  $T_1 \xrightarrow{p} \infty$ , kai  $n_d \rightarrow \infty$ .

Statistika  $T_1$  niekuo nesiskiria nuo [8] pristatyto testo statistikos, jei atsitiktinių vektorių  $\mathbf{y}$  generuotų modelis  $\mathbf{y} = \mathbf{V}\beta_{0,d} + \mathbf{u}$ . Tuomet (2.15) modelis nuo šio savo forma skiriasi tik tuo, kad (2.15) modelyje tiesiškai įeina narys  $\mathbf{X}\beta_d$ . Kai parametras  $\beta_d$  vertinamas kaip neapribotas, iš teiginio 2.1 išplaukia, kad uždavinys yra tiesiog patikrinti [8] teoremos 1 rezultato galiojimą šiame skyriuje nagrinėjamam modeliui.

Galima pateikti kitą testo statistikos variantą. Įveskime tokius pažymėjimus:

$$\mathbf{L} := \begin{bmatrix} \sqrt{n_d} \mathbf{I}_{d+1} & \mathbf{0} \\ \mathbf{0} & n_d \end{bmatrix}, \quad \mathbf{P} := \begin{bmatrix} \mathbf{I}_{d+1} & \mathbf{0} \end{bmatrix}_{(d+1) \times (d+2)}.$$

$\mathbf{L}$  yra normavimo matrica, o  $\mathbf{P}$  yra išrinkimo matrica, kuri išrenka iš  $d+2$  ilgio vektoriaus pirmuosius  $d+1$  narius. Likę pažymėjimai, reikalingi statistikai apibrėžti, yra:

$$\mathbf{h}_2 := \frac{\sqrt{n_d}}{\hat{\sigma}_u} (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})), \quad \Delta_{\tilde{f},\hat{\gamma}} := \mathbf{D}_{\tilde{f},\hat{\gamma}} (\mathbf{D}'_{\tilde{f},\hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{f},\hat{\gamma}})^{-1} \mathbf{D}'_{\tilde{f},\hat{\gamma}},$$

$$\hat{\Sigma}_{\mathbf{h}_2} := \mathbf{P} \mathbf{L} (\mathbf{Z}' \mathbf{Z})^{-1} \mathbf{L} \mathbf{P}' - \mathbf{P} \mathbf{L} \Delta_{\tilde{f},\hat{\gamma}} \mathbf{L} \mathbf{P}'.$$

<sup>6</sup>Šiame darbe apibendrinta atvirkštinė matrica vadinama Moore–Penrose tipo apibendrinta atvirkštinė matrica. Kvadratinė matrica  $\mathbf{A}^-$  yra Moore–Penrose tipo apibendrinta atvirkštinė kvadratinei (realiųjų skaičių) matricai  $\mathbf{A}$ , jei yra tenkinamos šios keturios sąlygos:  $\mathbf{A} \mathbf{A}^- \mathbf{A} = \mathbf{A}$ ;  $\mathbf{A}^- \mathbf{A} \mathbf{A}^- = \mathbf{A}^-$ ;  $(\mathbf{A} \mathbf{A}^-)' = \mathbf{A} \mathbf{A}^-$ ;  $(\mathbf{A}^- \mathbf{A})' = \mathbf{A}^- \mathbf{A}$ .

<sup>7</sup>Matrica  $\mathbf{A}$  vadinama idempotentine, jei  $\mathbf{A} \mathbf{A} = \mathbf{A}$ .

$\hat{\Sigma}_{h_2}$  yra  $h_2$  kovariacijų matricos įvertis. Jis, galima sakyti, yra „artimesnis“ tikrajai baigtinės imties atsitiktinio vektoriaus  $h_2$  kovariacijų matricai nei įvertis  $\hat{\Sigma}_{h_1}$  atsitiktinio vektoriaus  $h_1$  tikrajai kovariacijų matricai. Tačiau  $\hat{\Sigma}_{h_2}$  nėra idempotentinė ir neartėja į idempotentinę matricą.  $\hat{\Sigma}_{h_2}^-$  tegu žymi  $\hat{\Sigma}_{h_2}$  apibendrintą atvirkštinę matricą. Apibrėžkime tokią testo statistiką  $T_2$ :

$$T_2 := h_2' \hat{\Sigma}_{h_2}^- h_2.$$

Norint nusakyti statistikos  $T_2$  asimptotinę elgesį  $\tilde{H}_1$  atveju, reikia įvesti papildomus pažymėjimus. Tegų  $\gamma_0 := \text{plim} \hat{\gamma}$  ir

$$\Delta := D_{f,\gamma_0} (D_{f,\gamma_0}' Q D_{f,\gamma_0})^{-1} D_{f,\gamma_0}', \quad \Sigma_{h_2,\gamma_0} := Q^{-1} - \Delta.$$

Čia  $Q$  apibrėžta prielaidoje P4.

**Teiginys 2.3** *Jei galioja prielaidos P1-P4, tai:*

- jei  $\tilde{H}_0$  teisinga, tai  $T_2 \xrightarrow{d} \chi^2(d+1-r)$ , kai  $n_d \rightarrow \infty$ ;
- jei  $\tilde{H}_1$  teisinga, tai  $n_d^{-1} \hat{\sigma}_u^2 T_2 \xrightarrow{p} (\beta_{0,d} - f(\gamma_0))' \Sigma_{h_2,\gamma_0}^- (\beta_{0,d} - f(\gamma_0)) \geq 0$ , kai  $n_d \rightarrow \infty$ .

Teiginio 2.3 įrodymas pateiktas priede B.

Skirtumus tarp teiginio 2.2 ir teiginio 2.3 įrodymų reikia pakomentuoti plačiau. Pastebime, kad  $h_2$  apibrėžime skirtumas  $(\hat{\beta}_{0,d} - f(\hat{\gamma}))$  nepadaugintas iš matricos  $F_V'$ . Dėl to  $h_2$  asimptotinė kovariacijų matrica  $\Sigma_{h_2}$  ir jos įvertis  $\hat{\Sigma}_{h_2}$  nėra idempotentinės. Tai pasunkina įrodymą, kad jų rangai yra lygūs  $d+1-r$ . Visgi rangų sąlygą įrodžius, iš 2.2 teiginio  $\tilde{H}_0$  dalies rezultato išplaukia 2.3 teiginio  $\tilde{H}_0$  dalies rezultatas.  $\tilde{H}_1$  atveju nepavyko įrodyti, kad  $T_2 \xrightarrow{p} \infty$ , kai  $n_d \rightarrow \infty$ . Čia problemų kyla ne dėl to, kad reikia skaičiuoti  $\hat{\Sigma}_{h_2}$  apibendrintą atvirkštinę matricą, bet todėl, kad  $(\hat{\beta}_{0,d} - f(\hat{\gamma}))$  nėra padaugintas iš  $F_V'$ .

Teiginio  $\tilde{H}_1$  dalis taip pat nusako liekanų dispersijos ir testo galios sąryšį. Kuo  $\sigma_u^2$  yra mažesnė, tuo į didesnį skaičių artės  $n_d^{-1} T_1$ . Taigi galima spėti, kad testo galia atvirkščiai proporcinga liekanų dispersijos  $\sigma_u^2$  dydžiui, esant fiksuotam duomenų imties dydžiui.

Teiginys 2.2 yra pagrindinis šiame skyriuje pateiktas rezultatas. Kai integruotų dviejų skirtingo dažnio kintamųjų modelis (2.2) perrašomas į (2.4) formą, kada  $y_t$  aprašo aukšto dažnio proceso  $x$  stacionarūs skirtumai ir vienas liekamasis integruotas narys, [8] apibrėžta testo statistika tinka tikrinti hipotezę, kad (2.4) modelio parametrai tenkina pasirinktą funkcinį apribojimą.

### 3 Parametrų apribojimo funkcijos adekvatumo testavimas integruotų kintamųjų regresiniame modelyje su papildomais paaiškinančiais kintamaisiais

Šiame skyriuje apribojimo funkcijos adekvatumo testas apibendrinamas, kai į praeitame skyriuje nagrinėtą dviejų kintamųjų regresinį modelį įtraukiami papildomi paaiškinantieji kintamieji. Toks modelio praplėtimas reikalingas dėl kelių priežasčių. Pirma, dviejų kintamųjų modelio parametrų MKM ir NMKM įvertinių suderinamumas remiasi prielaida, kad modelio liekanos ir paaiškinantysis kintamasis yra nepriklausomi. Viena iš priežasčių, kodėl ši prielaida gali negaliooti, yra praleisti paaiškinantieji kintamieji. Antra, gali būti, kad žemo ir aukšto dažnio procesai nėra kointegruoti, bet yra kointegruoti kartu su turimais papildomais integruotais kintamaisiais. Šiuos kintamuosius būtina įtraukti į modelį, kitaip būtų gaunamos integruotos modelio liekanos. Trečia, papildomų kintamųjų įtraukimas į modelį gali sąlygoti mažesnę liekanų dispersiją, kas, tikėtina, padidintų testo galią.

Šį skyrių sudaro dvi dalys. Skyrelyje 3.1 apibrėžiamas modelis ir jo parametrų MKM ir NMKM įvertiniai. Skyrelyje 3.2 apibrėžiamos kelios testo statistikos, suformuluojami bei įrodomi teiginiai apie jų asimptotinę elgesį nulinės ir alternatyvios hipotezių atvejais.

#### 3.1 Nagrinėjami regresiniai modeliai ir jų parametrų vertinimas

Modelį (2.4) galima praplėsti įtraukiant laisvąjį narį ir daugiau paaiškinančiųjų kintamųjų:

$$y_t = \sum_{i=0}^d \beta_i v_{tm-i} + \beta_d x_{tm-d-1} + \alpha + \boldsymbol{\xi}'_t \boldsymbol{\eta} + u_t, \quad t \in \mathbb{N}. \quad (3.1)$$

Kintamuosius  $\boldsymbol{\xi}$  suskaidykime į stacionarius ir integruotus. Papildomą stacionarių procesų vektorių pažymėkime  $\boldsymbol{\xi}_0 = \{\boldsymbol{\xi}_{0,t} \in \mathbb{R}^{d_0}, t \in \mathbb{Z}\}$ , o pirma eile integruotų procesų vektorių pažymėkime  $\boldsymbol{\xi}_1 = \{\boldsymbol{\xi}_{1,t} \in \mathbb{R}^{d_1}, t \in \mathbb{N}\}$ . Tariame, kad procesas  $\boldsymbol{\xi}_1$  yra toks, kad  $\boldsymbol{\xi}_{1,t} = \sum_{j=1}^t \Delta \boldsymbol{\xi}_{1,j}$ , kur  $\{\Delta \boldsymbol{\xi}_{1,t} \in \mathbb{R}^{d_1}, t \in \mathbb{Z}\}$  yra stacionarus procesas<sup>8</sup>, ir  $\boldsymbol{\xi}_{1,0} = \mathbf{0}$ . Užrašykime modelį (3.1) matriciniu pavidalu.  $\boldsymbol{\Xi}_0$  ir  $\boldsymbol{\Xi}_1$  pažymėkime matricas, atitinkancias  $\boldsymbol{\xi}_0$  ir  $\boldsymbol{\xi}_1$  stebėjimus:

$$\boldsymbol{\Xi}_0 := \begin{bmatrix} \boldsymbol{\xi}'_{0,t_1} \\ \boldsymbol{\xi}'_{0,t_1+1} \\ \vdots \\ \boldsymbol{\xi}'_{0,n} \end{bmatrix}, \quad \boldsymbol{\Xi}_1 := \begin{bmatrix} \boldsymbol{\xi}'_{1,t_1} \\ \boldsymbol{\xi}'_{1,t_1+1} \\ \vdots \\ \boldsymbol{\xi}'_{1,n} \end{bmatrix}.$$

Čia  $t_1$  apibrėžtas (2.10). Tegu  $\mathbf{1}$  žymi  $n_d$  ilgio vienetų vektorių. Imkime matricą  $\mathbf{V}$  ir vektorių  $\mathbf{y}$  ir  $\mathbf{X}$  tokius, kaip apibrėžta atitinkamai (2.13), (2.11) ir (2.12). Tada (2.15)

<sup>8</sup>Tiksliau proceso  $\Delta \boldsymbol{\xi}_1$  struktūra bus apibrėžta skyrelyje 3.2, prielaidoje N4.



modelis su tiesiškai įeinančiais papildomais kintamaisiais matriciniu pavidalu užrašomas taip:

$$\mathbf{y} = \mathbf{V}\beta_{0,d} + \Xi_0\boldsymbol{\eta}_0 + \mathbf{1}\alpha + \beta_d\mathbf{X} + \Xi_1\boldsymbol{\eta}_1 + \mathbf{u} = \tilde{\mathbf{Z}}\boldsymbol{\Gamma} + \mathbf{u}. \quad (3.2)$$

Čia  $\tilde{\mathbf{Z}}$  yra bendra duomenų matrica,  $\boldsymbol{\Gamma}$  yra bendras vertinamų parametrų vektorius, kurių nariai, nemažinant bendrumo, išdėstyti tokia tvarka:

$$\tilde{\mathbf{Z}} := \begin{bmatrix} \mathbf{V} & \Xi_0 & \mathbf{1} & \mathbf{X} & \Xi_1 \end{bmatrix}, \quad \boldsymbol{\Gamma} := (\beta'_{0,d}, \boldsymbol{\eta}'_0, \alpha, \beta_d, \boldsymbol{\eta}'_1)'.$$

Parametrų  $\boldsymbol{\Gamma}$  skaičių pažymėkime  $\tilde{d} := d + 1 + d_0 + 1 + 1 + d_1$ .

Parametrų  $\boldsymbol{\Gamma}$  MKM įvertiniai  $\hat{\boldsymbol{\Gamma}}$ , minimizuojantys liekanų kvadratų sumą modelyje (3.2), yra:

$$\hat{\boldsymbol{\Gamma}} = (\tilde{\mathbf{Z}}'\tilde{\mathbf{Z}})^{-1} \tilde{\mathbf{Z}}'\mathbf{y}.$$

Likučių dispersijos  $\sigma_u^2$  įvertinys  $\hat{\sigma}_u^2$  šiuo atveju yra:

$$\hat{\sigma}_u^2 := \frac{1}{n_d - \tilde{d}} (\mathbf{y} - \tilde{\mathbf{Z}}\hat{\boldsymbol{\Gamma}})'(\mathbf{y} - \tilde{\mathbf{Z}}\hat{\boldsymbol{\Gamma}}). \quad (3.3)$$

Tegu funkcija  $f : \Lambda \times N \rightarrow \mathbb{R}$ ,  $\Lambda \subset \mathbb{R}^r$ , yra parametrų  $\beta_{0,d}$  apribojimų funkcija, kuriai norima patikrinti hipotezę  $\tilde{H}_0$  prieš alternatyvą  $\tilde{H}_1$ , apibrėžtas atitinkamai (2.24) ir (2.25). Vektorinis jos variantas  $\tilde{\mathbf{f}} : \Lambda \times \mathbb{R}^{d_0+d_1+2} \rightarrow \mathbb{R}^{\tilde{d}}$ , kai likusių parametrų vertinimas nėra apribojamas, yra:

$$\tilde{\mathbf{f}}(\boldsymbol{\psi}) = (\mathbf{f}(\boldsymbol{\gamma})', \boldsymbol{\eta}'_0, \alpha, \beta_d, \boldsymbol{\eta}'_1)', \quad \boldsymbol{\psi} := (\boldsymbol{\gamma}', \boldsymbol{\eta}'_0, \alpha, \beta_d, \boldsymbol{\eta}'_1)'.$$

Funkcija  $\mathbf{f}$  apibrėžta (2.17). Vertinamų parametrų  $\boldsymbol{\psi}$  skaičių pažymėkime  $\tilde{r} := r + d_0 + 1 + 1 + d_1$ . Tada MIDAS modelis matriciniu pavidalu užrašomas taip:

$$\mathbf{y} = \mathbf{V}\mathbf{f}(\boldsymbol{\gamma}) + \Xi_0\boldsymbol{\eta}_0 + \mathbf{1}\alpha + \mathbf{X}\beta_d + \Xi_1\boldsymbol{\eta}_1 + \mathbf{e} = \tilde{\mathbf{Z}}\tilde{\mathbf{f}}(\boldsymbol{\psi}) + \mathbf{e}, \quad (3.4)$$

kur  $\mathbf{e} := \mathbf{u} + \mathbf{V}(\beta_{0,d} - \mathbf{f}(\boldsymbol{\gamma}))$ . Funkcijos  $\tilde{\mathbf{f}}$  Jakobianas  $\mathbf{D}_{\tilde{\mathbf{f}},\boldsymbol{\psi}}$  taške  $\boldsymbol{\psi}$  šiuo atveju yra tokia blokinė  $\tilde{d} \times \tilde{r}$  matrica:

$$\mathbf{D}_{\tilde{\mathbf{f}},\boldsymbol{\psi}} = \mathbf{D}_{\tilde{\mathbf{f}},\boldsymbol{\gamma}} = \begin{bmatrix} \mathbf{D}_{\mathbf{f},\boldsymbol{\gamma}} & \mathbf{0} \\ \mathbf{0} & \mathbf{I}_{d_0+d_1+2} \end{bmatrix}. \quad (3.5)$$

Jakobianas  $\mathbf{D}_{\mathbf{f},\boldsymbol{\gamma}}$  apibrėžtas (2.20). NMKM įvertiniai  $\hat{\boldsymbol{\psi}} := (\hat{\boldsymbol{\gamma}}', \hat{\boldsymbol{\eta}}'^{nls}_0, \hat{\alpha}^{nls}, \hat{\beta}_d^{nls}, \hat{\boldsymbol{\eta}}'^{nls}_1)'$  randami minimizuojant (3.4) modelio liekanų kvadratų vidurkį:

$$\hat{\boldsymbol{\psi}} := \arg \min_{\boldsymbol{\psi} \in \Lambda \times \mathbb{R}^{d_0+d_1+2}} \left[ n_d^{-1} (\mathbf{y} - \tilde{\mathbf{Z}}\tilde{\mathbf{f}}(\boldsymbol{\psi}))'(\mathbf{y} - \tilde{\mathbf{Z}}\tilde{\mathbf{f}}(\boldsymbol{\psi})) \right]. \quad (3.6)$$

NMKM įvertiniai  $\hat{\boldsymbol{\psi}}$  tenkina tokią pirmos eilės sąlygą:

$$\mathbf{D}'_{\tilde{\mathbf{f}},\hat{\boldsymbol{\gamma}}} \tilde{\mathbf{Z}}'(\mathbf{y} - \tilde{\mathbf{Z}}\tilde{\mathbf{f}}(\hat{\boldsymbol{\psi}})) = \mathbf{0}. \quad (3.7)$$

## 3.2 Parametrų apribojimo funkcijos adekvatumo testavimas

Šio skyriaus modelis nuo 2 skyriaus modelio skiriasi tuo, kad įtraukiami trijų tipų papildomi kintamieji – stacionarūs, laisvasis narys, pirmos eilės integruoti kintamieji. 2 skyriuje matėme, kad į testo statistiką neįtraukus integruoto kintamojo duomenų, vienas integruotas kintamasis niekaip nepakeičia testo statistikos asimptotinio elgesio palyginus su tuo, koks gautas [8], kai į modelį įeina tik stacionarūs aukšto dažnio proceso nariai. Todėl galima spėti, kad daugiau nei vienas integruotas kintamasis taip pat niekaip nepaveiks  $\sqrt{n_d}(\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))$  asimptotinio elgesio. Tačiau nėra aišku, ar  $\sqrt{n_d}(\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))$  asimptotinis skirstinys nepasikeis, kai į modelį įtraukiami kiti stacionarūs kintamieji ir laisvasis narys. Galima spėti, kad nulinės hipotezės galiojimo atveju šis asimptotinis skirstinys bus normalusis su nuliniu vidurkių vektoriumi, tačiau neaišku, ar su tokia pačia kovariacijų matrica. Todėl reikia išsiaiškinti, ar reikia (ir jei reikia, tai kaip) kaip nors keisti 2 skyriuje apibrėžtas testo statistikas, kad jos turėtų  $\chi^2$  asimptotinę skirstinę su žinomu laisvės laipsnių skaičiumi, kai nulinė hipotezė teisinga.

Įveskime prielaidas N1-N4, analogiškas 2 skyriaus prielaidoms P1-P4.

**Prielaida N1.** Modelio (3.1) liekanos  $\{u_t, t \in \mathbb{Z}\}$  yra n.v.p. atsitiktiniai dydžiai,  $Eu_t = 0$ ,  $Eu_t^2 = \sigma_u^2$ ,  $Eu_t^4 < \infty$ ,  $\forall t \in \mathbb{Z}$ . Be to,  $u$  nepriplauso nuo procesų  $v$  ir  $\xi_0$ .

Prielaida N1 nereikalauja, kad integruoti kintamieji  $\xi_1$  ir liekanos būtų nepriklausomi. Gerai žinoma, kad kointegravimo vektoriaus parametrų įvertiniai yra suderinti, kai integruoti kintamieji yra koreliuoti su liekanomis.

**Prielaida N2.** Apribojimo funkcija  $f : \Lambda \times \mathbb{N} \rightarrow \mathbb{R}$  yra tolydi ir du kartus diferencijuojama parametrų  $\gamma \in \Lambda$  atžvilgiu.

**Prielaida N3.**  $\exists$  plim $\hat{\psi}$ , kai  $n_d \rightarrow \infty$ , kur  $\hat{\psi}$  yra (3.4) modelio NMKM įvertiniai, apibrėžti (3.6) ir tenkinantys lygybes (3.7).

Reikia padaryti prielaidą, kad proceso, sudaryto iš stacionarių kintamųjų ir integruotų kintamųjų skirtumų, MA( $\infty$ ) forma turėtų greitai gėstančias koeficientų matricas. Tokios prielaidos reikia tam, kad būtų galima naudotis iš funkcinės centrinės ribinės teoremos gautais rezultatais, suformuluotais [7] teiginyje 18.1 (p. 547). Formaliau, sudarykime procesą  $\tilde{\mathbf{v}} := \{\tilde{\mathbf{v}}_t \in \mathbb{R}^{\tilde{d}-2}, t \in \mathbb{Z}\}$  taip:

$$\tilde{\mathbf{v}}_t := (v_{tm}, v_{tm-1}, \dots, v_{tm-d}, \xi'_{0,t}, \Delta \xi'_{1,t})', \quad t \in \mathbb{Z}.$$

**Prielaida N4.**  $\tilde{\mathbf{v}}_t = \sum_{j=0}^{\infty} \mathbf{W}_j \boldsymbol{\varepsilon}_{t-j}$ , kur  $\{\boldsymbol{\varepsilon}_t, t \in \mathbb{Z}\}$  yra n.v.p. atsitiktiniai vektoriai, turintys baigtinius ketvirtus momentus,  $E\boldsymbol{\varepsilon}_t = \mathbf{0}$ , kovariacijų matrica  $E(\boldsymbol{\varepsilon}_t \boldsymbol{\varepsilon}_t')$  yra teigiamai apibrėžta. Seka  $\{j\mathbf{W}_j\}_{j=0}^{\infty}$  yra absoliučiai sumuojama. Be to, matrica  $E(\tilde{\mathbf{v}}_t \tilde{\mathbf{v}}_t')$  yra teigiamai apibrėžta.

Prielaida N4 nenorima uždrausti atvejo, kada į modelį įtraukiamas integruotas kintamasis kartu su savo skirtumais. Tuomet vektorių  $\tilde{\mathbf{v}}_t$  tiesiog reikia apibrėžti taip, kad nebūtų du kartus įtrauktas tas pats kintamasis.

Išskirsime dar vieną prielaidą, kurios nereikėjo 2 skyriuje.

**Prielaida N5.** Tegu  $\tilde{\mathbf{x}}_t := (x_{tm-d-1}, \boldsymbol{\xi}'_{1,t})'$ . Imkime  $\tilde{\mathbf{x}}_t$  realizaciją  $\{\tilde{\mathbf{x}}_t\}_{t=t_1}^\infty$ . Tada  $n_d^{-2} \sum_{t=t_1}^n \tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t'$  konverguoja į teigiamai apibrėžtą matricą, kai  $n \rightarrow \infty$ .

Prielaida N5 užtikrina, kad tarp integruotų kintamųjų nėra „asimptotiškai multikolinearių“. Taip būtų, jei, pavyzdžiui, vienas iš  $\boldsymbol{\xi}_{1,t}$  narių būtų  $x_{tm-d-2}$ . Nesunku įsitikinti, kad sumos  $n_d^{-2} \sum_{t=t_1}^n (x_{tm-d-i} x_{tm-d-j})$  konkrečiai duomenų sekai artėja į tą patį skaičių  $\forall i, j = 1, 2$  (pagal pasiskirstymą konverguoja į atsitiktinius dydžius, kurių tarpusavio koreliacija yra vienetas).

Apibrėžkime pirmąją šio skyriaus testo statistiką. Apibrėžkime tokią  $(d+1) \times (d+1)$  matricą  $\hat{\mathbf{A}}$ :

$$\hat{\mathbf{A}} := n_d^{-1} (\mathbf{V}'\mathbf{V} - \mathbf{V}'\boldsymbol{\Xi}_0 (\boldsymbol{\Xi}_0'\boldsymbol{\Xi}_0)^{-1} \boldsymbol{\Xi}_0'\mathbf{V}). \quad (3.8)$$

Toliau esančio teiginio įrodyme pagrįsta, kad  $\hat{\mathbf{A}}$  yra teigiamai apibrėžta matrica. Pagal Cholesky dekompoziciją išskaidykime matricą  $\hat{\mathbf{A}}$ :  $\hat{\mathbf{A}} = \mathbf{F}_{\hat{\mathbf{A}}} \mathbf{F}_{\hat{\mathbf{A}}}'$ . Kaip ir 2.3 skyrelyje, testo statistikos pagrindą sudaro skirtumas tarp MKM įverčių  $\hat{\beta}_{0,d}$  ir NMKM įverčių  $\mathbf{f}(\hat{\gamma})$ :

$$\mathbf{h}_3 := \frac{\sqrt{n_d}}{\hat{\sigma}_u} \mathbf{F}_{\hat{\mathbf{A}}} (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})).$$

Atsitiktinio vektoriaus  $\mathbf{h}_3$  kovariacijų matricos įvertinį  $\hat{\Sigma}_{\mathbf{h}_3}$  apibrėžkime taip:

$$\hat{\Sigma}_{\mathbf{h}_3} := \mathbf{I}_{d+1} - \mathbf{F}_{\hat{\mathbf{A}}} \mathbf{D}_{\mathbf{f},\hat{\gamma}} (\mathbf{D}_{\mathbf{f},\hat{\gamma}}' \hat{\mathbf{A}} \mathbf{D}_{\mathbf{f},\hat{\gamma}})^{-1} \mathbf{D}_{\mathbf{f},\hat{\gamma}}' \mathbf{F}_{\hat{\mathbf{A}}}. \quad (3.9)$$

$\hat{\Sigma}_{\mathbf{h}_3}$  yra simetrinė ir idempotentinė kvadratinė matrica, taigi jos apibendrinta atvirkštinė matrica yra lygi jai pačiai. Testo statistika  $T_3$  skaičiuojama pagal tokią formulę:

$$T_3 = \mathbf{h}_3' \hat{\Sigma}_{\mathbf{h}_3} \mathbf{h}_3. \quad (3.10)$$

**Teiginys 3.1** Jei galioja prielaidos N1-N5, tai:

- jei  $\tilde{H}_0$  teisinga, tai  $T_3 \xrightarrow{d} \chi^2(d+1-r)$ , kai  $n_d \rightarrow \infty$ ;
- jei  $\tilde{H}_1$  teisinga, tai  $T_3 \xrightarrow{p} \infty$ , kai  $n_d \rightarrow \infty$ .

Teiginio 3.1 įrodymas pateiktas priede C. Kadangi 2 skyriaus regresinis modelis nedaug skiriasi nuo šio skyriaus nagrinėjamo, tai atskiros teiginių 2.2 ir 3.1 įrodymų dalys keliose vietose sutampa.

Gavome, kad į statistikos  $T_3$  formulę apibrėžtu būdu reikia įtraukti papildomų stacionarių kintamųjų duomenis. Pastebėkime, kad jeigu į (3.4) modelį nėra įtraukta papildomų stacionarių kintamųjų, tai matricos  $\hat{\mathbf{A}}$  apibrėžime nėra dalies  $\mathbf{V}'\boldsymbol{\Xi}_0 (\boldsymbol{\Xi}_0'\boldsymbol{\Xi}_0)^{-1} \boldsymbol{\Xi}_0'\mathbf{V}$ . Tokiu atveju  $\mathbf{F}_{\hat{\mathbf{A}}} = \mathbf{F}_{\mathbf{V}}$ , taigi statistika  $T_3$  tampa 2.3 skyrelyje apibrėžta statistika  $T_1$ .

Teiginio 3.1 įrodyme gavome, kad, jei  $\tilde{H}_0$  neteisinga, prie papildomų stacionarių kintamųjų esantys įvertiniai  $\hat{\boldsymbol{\eta}}_0^{nls}$  yra nesuderinti, jei narys  $n_d^{-1} \mathbf{V}'\boldsymbol{\Xi}_0$  pagal tikimybę neartėja į nulinę matricą. Jei  $\tilde{H}_0$  yra teisinga, įvertiniai  $\hat{\boldsymbol{\eta}}_0^{nls}$  yra suderinti. Vadinasi, testas su panašia į  $T_3$

statistika, tačiau į kurią būtų įtrauktas parametrų  $\boldsymbol{\eta}_0$  MKM ir NMKM įvertinių skirtumas, galbūt būtų didesnės galios. Įveskime keletą pažymėjimų, kad apibrėžtume tokią statistiką. Tegu  $\tilde{\mathbf{V}}$  yra bendra stacionarių kintamųjų duomenų matrica, t.y.:

$$\tilde{\mathbf{V}} := \begin{bmatrix} \mathbf{V} & \boldsymbol{\Xi}_0 \end{bmatrix}.$$

Pagal Cholesky dekompoziciją, tegu  $\mathbf{F}_{\tilde{\mathbf{V}}}$  yra tokia, kad:  $\mathbf{F}_{\tilde{\mathbf{V}}} \mathbf{F}_{\tilde{\mathbf{V}}}^{\prime} = n_d^{-1} \tilde{\mathbf{V}}^{\prime} \tilde{\mathbf{V}}$ . Tegu  $\hat{\boldsymbol{\psi}}_0 := (\hat{\boldsymbol{\gamma}}^{\prime}, \hat{\boldsymbol{\eta}}_0^{\prime nls})^{\prime}$ . Pažymėkime funkciją  $\mathbf{f}_0 : \Lambda \times \mathbb{R}^{d_0} \rightarrow \mathbb{R}^{d+1+d_0}$  tokią, kad  $\mathbf{f}_0(\hat{\boldsymbol{\psi}}_0) := (\mathbf{f}(\hat{\boldsymbol{\gamma}})^{\prime}, \hat{\boldsymbol{\eta}}_0^{\prime nls})^{\prime}$ . Apibrėžkime atsitiktinį vektorių  $\mathbf{h}_4$  taip:

$$\mathbf{h}_4 := \frac{\sqrt{n_d}}{\hat{\sigma}_u} \mathbf{F}_{\tilde{\mathbf{V}}}^{\prime} \left( (\hat{\boldsymbol{\beta}}_{0,d}^{\prime}, \hat{\boldsymbol{\eta}}_0^{\prime})^{\prime} - \mathbf{f}_0(\hat{\boldsymbol{\psi}}_0) \right).$$

$\mathbf{h}_4$  kovariacijų matricos įvertinys  $\hat{\boldsymbol{\Sigma}}_{\mathbf{h}_4}$  yra:

$$\hat{\boldsymbol{\Sigma}}_{\mathbf{h}_4} := \mathbf{I}_{d+1+d_0} - n_d \mathbf{F}_{\tilde{\mathbf{V}}}^{\prime} \mathbf{D}_{\mathbf{f}_0, \hat{\boldsymbol{\gamma}}} (\mathbf{D}_{\mathbf{f}_0, \hat{\boldsymbol{\gamma}}}^{\prime} \tilde{\mathbf{V}}^{\prime} \tilde{\mathbf{V}} \mathbf{D}_{\mathbf{f}_0, \hat{\boldsymbol{\gamma}}})^{-1} \mathbf{D}_{\mathbf{f}_0, \hat{\boldsymbol{\gamma}}}^{\prime} \mathbf{F}_{\tilde{\mathbf{V}}}. \quad (3.11)$$

Čia  $\mathbf{D}_{\mathbf{f}_0, \hat{\boldsymbol{\gamma}}}$  yra (2.21) apibrėžtos matricos  $\mathbf{D}_{\tilde{\mathbf{f}}, \hat{\boldsymbol{\gamma}}}$  pirmosios  $d+1+d_0$  eilutės ir pirmieji  $r+d_0$  stulpeliai. Statistika  $T_4$  yra skaičiuojama taip:

$$T_4 := \mathbf{h}_4^{\prime} \hat{\boldsymbol{\Sigma}}_{\mathbf{h}_4} \mathbf{h}_4. \quad (3.12)$$

**Teiginys 3.2** *Tai pačiai duomenų matricai  $\tilde{\mathbf{V}}$  ir tiems patiems įverčiams  $\hat{\boldsymbol{\beta}}_{0,d}$  ir  $\hat{\boldsymbol{\gamma}}$ , statistikos  $T_3$  ir  $T_4$  yra lygios.*

Teiginio 3.2 įrodymas yra visiškai algebrinis, jis pateiktas priede D. Įrodyme parodoma, kad įvertiniai prie papildomų stacionarių kintamųjų į statistiką  $T_4$  iš tikrųjų neįeina, t.y., jie padauginami iš nulio. Vadinas, tokio tipo statistikoje papildomos informacijos iš šių įvertinių suderinamumo prie  $\tilde{H}_0$  ir nesuderinamumo prie  $\tilde{H}_1$  negaunama.

Teiginys 3.2 yra tik įdomus pastebėjimas, kuris tačiau veda prie naudingo kito teiginio. Pastebėkime, kad į statistikų  $T_3$  ir  $T_4$  apibrėžimus įtraukiami papildomų stacionarių kintamųjų duomenys, tačiau neįtraukiami integruotų kintamųjų duomenys. Tai gana didelis jų trūkumas, nes, norint suskaičiuoti šias statistikas, reikia žinoti, kurie papildomi kintamieji yra stacionarūs, o kurie – integruoti. Vadinas, jei tai nėra žinoma, reikia atlikinėti integruotumo tikrinimo statistinius testus. Tai apribojimo funkcijos adekvatumo testą daro nepatrauklų bei prideda rizikos, kad bus padaryta pirmos ar antros rūšies klaida, testuojant kintamųjų stacionarumą-integruotumą. Todėl reikalinga tokia testo statistika, į kurią simetriškai įeitų visi modelio kintamieji. Toliau tokia statistika ir bus apibrėžta.

Apibrėšime statistiką  $T_5$ , kuri nuo statistikos  $T_4$  skirsis tik tuo, kad į ją bus įtraukti visi modelio paaiškinantieji kintamieji bei visų parametrų įverčiai. Pagal Cholesky dekompoziciją, tegu  $\mathbf{F}_{\tilde{\mathbf{Z}}}$  yra tokia matrica, kad  $\mathbf{F}_{\tilde{\mathbf{Z}}} \mathbf{F}_{\tilde{\mathbf{Z}}}^{\prime} = n_d^{-1} \tilde{\mathbf{Z}}^{\prime} \tilde{\mathbf{Z}}$ . Apibrėžkime  $\mathbf{h}_5$ ,  $\hat{\boldsymbol{\Sigma}}_{\mathbf{h}_5}$  ir statistiką  $T_5$

taip:

$$\begin{aligned} \mathbf{h}_5 &:= \frac{\sqrt{n_d}}{\hat{\sigma}_u^2} \mathbf{F}'_{\tilde{\mathbf{Z}}} (\hat{\Gamma} - \tilde{\mathbf{f}}(\hat{\psi})), \\ \hat{\Sigma}_{\mathbf{h}_5} &:= \mathbf{I}_{\tilde{d}} - n_d \mathbf{F}'_{\tilde{\mathbf{Z}}} \mathbf{D}_{\tilde{\mathbf{f}}, \hat{\gamma}} (\mathbf{D}'_{\tilde{\mathbf{f}}, \hat{\gamma}} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{D}_{\tilde{\mathbf{f}}, \hat{\gamma}})^{-1} \mathbf{D}'_{\tilde{\mathbf{f}}, \hat{\gamma}} \mathbf{F}_{\tilde{\mathbf{Z}}}, \\ T_5 &:= \mathbf{h}_5' \hat{\Sigma}_{\mathbf{h}_5} \mathbf{h}_5. \end{aligned}$$

**Teiginys 3.3** *Jei galioja prielaidos N1-N5, tai:*

- jei  $\tilde{H}_0$  teisinga, tai  $T_5 - T_3 \xrightarrow{p} 0$ , kai  $n_d \rightarrow \infty$ ;
- jei  $\tilde{H}_1$  teisinga, tai  $n_d^{-1} (T_5 - T_3) \xrightarrow{p} 0$ , kai  $n_d \rightarrow \infty$ .

Teiginio 3.3 įrodymas nukeltas į priedą E. Priede E taip pat parodyta, kad visi įvertiniai, išskyrus  $\hat{\beta}_{0,d}$  ir  $\mathbf{f}(\hat{\gamma})$ , įeinantys į statistiką  $T_5$ , yra padauginami iš nulių.

Iš teiginio 3.3 galima nesunkiai išvesti statistikos  $T_5$  asimptotinį elgesį nulinės ir alternatyvios hipotezės atvejais. Remiantis teiginiu 3.1 ir [7] teiginiu 7.3 (Proposition 7.3, p. 184), iš teiginio 3.3 išplaukia, kad  $T_5 \xrightarrow{d} \chi^2(d+1-r)$ , kai  $n_d \rightarrow \infty$ , jei teisinga  $\tilde{H}_0$ . Jei  $\tilde{H}_0$  neteisinga, tai  $n_d^{-1} T_3 \xrightarrow{p} c$ , kur  $c$  yra teigiamas skaičius, todėl iš teiginio 3.3 išplaukia, kad  $n_d^{-1} T_5 \xrightarrow{p} c$ , kai  $n_d \rightarrow \infty$ . Vadinasi,  $T_5 \xrightarrow{p} \infty$ , kai  $n_d \rightarrow \infty$ . Formaliai užrašykime šį teiginį.

**Teiginys 3.4** *Jei galioja prielaidos N1-N5, tai:*

- jei  $\tilde{H}_0$  teisinga, tai  $T_5 \xrightarrow{d} \chi^2(d+1-r)$ , kai  $n_d \rightarrow \infty$ ;
- jei  $\tilde{H}_1$  teisinga, tai  $T_5 \xrightarrow{p} \infty$ , kai  $n_d \rightarrow \infty$ .

Į statistiką  $T_5$  visi modelio kintamieji įeina simetriškai, t.y., norint ją suskaičiuoti, nebūtina žinoti, kurie papildomi kintamieji yra stacionarūs, o kurie – integruoti. Matricoje  $\tilde{\mathbf{Z}}$  kintamieji gali būti išdėstyti bet kokia tvarka. Suprantama,  $\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})$  vieta visų įvertinių vektoriuje turi atitikti matricos  $\mathbf{V}$  vietą duomenų matricoje  $\tilde{\mathbf{Z}}$ . Vietoj likusių įvertinių skirtumo galima įstatyti bet kokius skaičius. Be to, statistika  $T_5$  yra natūralus 2.3 skyrelyje apibrėžtos statistikos  $T_1$  apibendrinimas.

## 4 Imitacinė analizė

Šiame skyriuje aprašomi dviejų pagrindinių tikslų įgyvendinimo rezultatai. Pirmas tikslas yra empiriškai patikrinti 2 ir 3 skyriuose aprašytų rezultatų teisingumą. Pirma, reikia įsitikinti, ar tikrai testo statistikos nulinės hipotezės atveju asimptotiškai yra  $\chi^2$  atsitiktiniai dydžiai su konkrečiu laisvės laipsnių skaičiumi. Antra, reikia patikrinti gautą rezultatą, kad neteisingos nulinės hipotezės atveju testo statistikos pagal tikimybę artėja į begalybę.

Straipsnyje [12] pateikiamas kitas apribojimo funkcijos adekvatumo statistinis testas, kurį pagal autoriaus pavardę vadinsime Miller'io testu. Antras šio skyriaus tikslas yra konkretiems duomenis generuojantiems procesams palyginti nagrinėjamo ir Miller'io testų galią. Abiejų testų galia įvertinama naudojantis Monte Carlo metodu.

Skyrelyje 4.1 aprašomi naudoti duomenis generuojantys procesai. Rezultato, kad nulinės hipotezės galiojimo atveju aprašytos statistikos pagal pasiskirstymą artėja į  $\chi^2$  atsitiktinį dydį, tikrinimas aprašomas 4.2 skyrelyje. Skyrelyje 4.3 parodoma, kad neteisingos nulinės hipotezės atveju testo statistikos pagal tikimybę artėja į begalybę. Miller'io testas aprašomas 4.4 skyrelyje. Šiame skyrelyje taip pat patikrinama, ar tikrai šio testo statistika pagal pasiskirstymą konverguoja į nurodytą atsitiktinį dydį, kai nulinė hipotezė yra teisinga. Skyrelyje 4.5 palyginama abiejų testų galia.

### 4.1 Duomenis generuojantys procesai

Šiame skyrelyje aprašomi naudoti duomenis generuojantys procesai. Aukšto dažnio procesų  $v$  ir  $x$  realizacijos generuotos pagal tokią struktūrą:

$$v_\tau = av_{\tau-1} + \varepsilon_\tau, \quad x_\tau = \sum_{i=1}^{\tau} v_i, \quad \varepsilon_\tau \sim N(0, 1), \quad v_0 = 0, \quad \tau = 1, \dots, nm.$$

Žemo dažnio proceso  $y$  realizacijos buvo generuojamos pagal (2.4) modelio formą:

$$y_t = \sum_{i=0}^d \beta_i v_{tm-i} + \beta_d x_{tm-d-1} + u_t, \quad u_t \sim N(0, \sigma_u^2), \quad t \in \{t_1, \dots, n\}. \quad (4.1)$$

Liekanos  $u_t$  ir  $\varepsilon_\tau$  generuotos kaip nepriklausomos tarpusavyje ir neautokoreliuotos. Be to,  $E(\varepsilon_\tau | v_{\tau-1}, v_{\tau-2}, \dots) = 0$ . Parametrų  $\beta_{0,d} = (\beta_0, \dots, \beta_d)'$  ir  $\sigma_u^2$  reikšmės bus apibrėžtos vėliau šiame skyrelyje.

Modelio su papildomais paaiškinančiais kintamaisiais atveju prie  $y_t$  išraiškos (4.1) pridedamas laisvasis narys  $\alpha$  ir du stacionarūs procesai  $\xi_{01}$  ir  $\xi_{02}$  tokie, kad būtų koreliuoti tarpusavyje ir su procesu  $v$ :

$$\xi_{01,t} = v_{tm} + \varepsilon_{01,t}, \quad \xi_{02,t} = v_{tm} + \xi_{01,t} + \varepsilon_{02,t}, \quad \boldsymbol{\varepsilon}_{0,t} = (\varepsilon_{01,t}, \varepsilon_{02,t})' \sim N(\mathbf{0}, \mathbf{I}_2).$$

Liekanos  $\boldsymbol{\varepsilon}_{0,t}$  generuotos nepriklausomai nuo liekanų  $u_t$  ir  $\varepsilon_\tau$ . Taip pat pridedami du inte-

gruoti procesai  $\xi_{11}$  ir  $\xi_{12}$  tokie, kad:

$$\xi_{11,t} = \sum_{i=1}^t \xi_{01,i}, \quad \xi_{12,t} = \sum_{i=1}^t \xi_{02,i}.$$

Pocesas  $y$  generuotas taip:

$$y_t = \alpha + \sum_{i=0}^d \beta_i v_{tm-i} + \beta_d x_{tm-d-1} + \eta_{01} \xi_{01,t} + \eta_{02} \xi_{02,t} + \eta_{11} \xi_{11,t} + \eta_{12} \xi_{12,t} + u_t,$$

$$(\alpha, \eta_{01}, \eta_{02}, \eta_{11}, \eta_{12}) = (1, 1, 1, 1, 1), \quad u_t \sim N(0, \sigma_u^2), \quad t \in \{t_1, \dots, n\}.$$

Aprašyti procesai generuojami su tokiais galimais parametru  $a$ ,  $m$  ir  $d$  variantais:

$$a \in \{0.5, 0.9\}; \quad m \in \{12, 24\};$$

$$d \in \{11, 23\}, \text{ jei } m = 12; \quad d \in \{23, 47\}, \text{ jei } m = 24.$$

Koeficientai  $\beta_{0,d}$  yra reikšmės vienos iš trijų toliau apibrėžtų apribojimo funkcijų  $f_1$ ,  $f_2$  ir  $f_3$ .

$$\beta_i = f_1(\gamma, i+1) = \gamma_1 \frac{\exp\left(\gamma_2 \frac{i+1}{100} + \gamma_3 \left(\frac{i+1}{100}\right)^2\right)}{\sum_{j=0}^d \exp\left(\gamma_2 \frac{j+1}{100} + \gamma_3 \left(\frac{j+1}{100}\right)^2\right)}, \quad i = 0, \dots, d,$$

$$\gamma' := (\gamma_1, \gamma_2, \gamma_3) = (10, 2, -10), \quad \sigma_u^2 = 1.$$

$$\beta_i = f_2(\gamma, i+1) = \gamma_1 \frac{i+1}{100} \exp\left(\gamma_2 \frac{i+1}{100} + \gamma_3 \left(\frac{i+1}{100}\right)^2\right), \quad i = 0, \dots, d,$$

$$\gamma' := (\gamma_1, \gamma_2, \gamma_3) = (10, -10, -10), \quad \sigma_u^2 = 1.$$

$$\beta_i = f_3(\gamma, i+1) = \gamma_1 \frac{i+1}{d} + \gamma_2 \sin\left(\gamma_3 \frac{i+1}{d} \pi\right), \quad i = 0, \dots, d,$$

$$\gamma' := (\gamma_1, \gamma_2, \gamma_3) = (1, 1, 1),$$

$$\sigma_u^2 = \begin{cases} 1, & \text{jei } d = 11; \\ 4, & \text{jei } d = 23; \\ 16, & \text{jei } d = 47. \end{cases}$$

$f_1$  yra dažnai literatūroje taikoma „Almon lag” apribojimo funkcija. Panaši į  $f_2$  funkcija naudojama straipsnyje [8]. Parametrai  $\gamma$  vertinami naudojant funkciją  $f_1$ . Vadinasi, jei koeficientai  $\beta_{0,d}$  yra generuojami pagal  $f_1$ , tai  $f_1$  yra teisingai parinkta apribojimo funkcija. Jeigu  $\beta_{0,d}$  aprašomi  $f_2$  ir  $f_3$  funkcijomis, tai apribojimo funkcija  $f_1$  pasirinkta neteisingai. Parametru  $\gamma$  reikšmės funkcijoms  $f_2$  ir  $f_3$  yra parinktos taip, kad funkcijos  $f_1$  grafikas  $\{(i, f_1(\gamma, i))\}_{i=1, \dots, d+1}$  kažkurioms  $\gamma$  reikšmėms galėtų būti panašus į funkcijų  $f_2$  ir

$f_3$  grafikus, t.y., norima, kad neteisinga nulinė hipotezė būtų gana „artima“ teisingai alternatyvai. Taip daroma dėl to, kad vienas iš imitacinės analizės tikslų yra palyginti aprašyto testo galią su Miller’io testo galia, ko neišeitų padaryti, jei testų galios būtų artimos vienetui daugumai parametrų  $n_d$ ,  $a$ ,  $m$  ir  $d$  reikšmių. Dėl tos pačios priežasties atitinkamai parenkamos  $\sigma_u^2$  reikšmės. 1 pav. pateikti funkcijų  $f_j$  grafikai  $\{(i, f_j(\gamma, i))\}_{i=1, \dots, d+1}$ ,  $j = 2, 3$ , visoms nagrinėjamoms parametrų  $m$  ir  $d$  reikšmėms. Taip pat pateikti funkcijos  $f_1$  grafikai  $\{(i, f_1(\gamma_0, i))\}_{i=1, \dots, d+1}$ , kur  $\gamma_0 \approx \text{plim}(\hat{\gamma})$ , kai vietoj  $f_2$  ar  $f_3$  neteisingai parenkama apribojimo funkcija  $f_1$ . Koeficientai  $\gamma_0$  gauti, kai autoregresinis parametras  $a = 0,5$ .

## 4.2 Testo statistikų empiriniai skirstiniai, kai nulinė hipotezė teisinga

Šio skyrelio tikslas yra Monte Carlo metodu patvirtinti, kad 2 ir 3 skyriuose apibrėžtos testo statistikos, esant teisingai parinktai apribojimo funkcijai, pagal pasiskirstymą artėja į  $\chi^2(d+1-r)$  atsitiktinį dydį<sup>9</sup>. Vadinas, esant pakankamai dideliui imties dydžiui  $n_d$ , testo statistikos pasiskirstymo funkcija turi mažai skirtis nuo  $\chi^2$  atsitiktinio dydžio pasiskirstymo funkcijos. Tikra statistikos pasiskirstymo funkcija konkrečiam  $n_d$  nėra žinoma, tačiau ją kiek norima tiksliai galima įvertinti naudojantis Monte Carlo metodu.

Statistikų ir  $\chi^2(d+1-r)$  atsitiktinio dydžio pasiskirstymo funkcijų panašumą matuokime palygindami jas keliuose pasirinktuose taškuose. Tegū  $F_{\chi^2(d+1-r)}$  yra  $\chi^2(d+1-r)$  atsitiktinio dydžio pasiskirstymo funkcija. Tada, jei atsitiktinis dydis  $T_i$  yra apytiksliai taip pat pasiskirstęs kaip ir  $\chi^2(d+1-r)$ , tai  $P(T_i < F_{\chi^2(d+1-r)}^{-1}(p)) \approx p$ ,  $\forall p \in (0, 1)$ . Pasirinkus Monte Carlo kartojimų skaičių  $rep$ , gaunami testo statistikų rinkiniai  $\{T_{i,1}, \dots, T_{i,rep}\}$ ,  $i = 1, 2, 3$ . Natūralus tikimybės  $P(T_i < F_{\chi^2(d+1-r)}^{-1}(p))$  įvertinys  $\hat{P}(T_i < F_{\chi^2(d+1-r)}^{-1}(p))$  yra:

$$\hat{P}(T_i < F_{\chi^2(d+1-r)}^{-1}(p)) := \frac{1}{rep} \sum_{j=1}^{rep} \mathbb{1}\{T_{i,j} < F_{\chi^2(d+1-r)}^{-1}(p)\}, \quad (4.2)$$

kur  $\mathbb{1}\{T_{i,j} < F_{\chi^2(d+1-r)}^{-1}(p)\}$  yra indikatorinė funkcija tokia, kad

$$\mathbb{1}\{T_{i,j} < F_{\chi^2(d+1-r)}^{-1}(p)\} = \begin{cases} 1, & \text{jei } T_{i,j} < F_{\chi^2(d+1-r)}^{-1}(p); \\ 0, & \text{jei } T_{i,j} \geq F_{\chi^2(d+1-r)}^{-1}(p). \end{cases}$$

Kaip pakankamai didelis, imties dydis pasirinktas  $n_d = 2000$ . Lentelėje 1 pateikti (4.2) apibrėžtų tikimybių įverčiai statistikai  $T_1$  šioms  $p$  reikšmėms:

$$p \in \{0.01, 0.05, 0.1, 0.3, 0.5, 0.7, 0.9, 0.95, 0.99\}.$$

Parametrus  $\beta_{0,d}$  generuojanti funkcija yra  $f_1$  ir NMKM įvertiniai vertinami su teisingai

---

<sup>9</sup> Parametrų  $\beta_{0,d}$  skaičius  $d+1$  yra vienas iš 4.1 skyrelyje nurodytų  $d$  reikšmių. Funkcijos  $f_1(\gamma, i)$  parametrų  $\gamma$  skaičius  $r = 3$ .



parinkta apribojimo funkcija  $f_1$ , kurios parametrų skaičius  $r = 3$ . Monte Carlo kartojimų skaičius  $rep = 4\,000$ .

1 lentelė. Tikimybės  $\hat{P}(T_1 < F_{\chi^2(d+1-3)}^{-1}(p))$  statistikai  $T_1$ , kai  $n_d = 2\,000$ ,  $rep = 4\,000$  ir NMKM įvertiniai  $\hat{\gamma}$  gaunami naudojant teisingai parinktą apribojimo funkciją  $f_1(\gamma, i)$ .

$a$	$m$	$d$	$p$								
			0,01	0,05	0,1	0,3	0,5	0,7	0,9	0,95	0,99
0,5	12	11	0,012	0,052	0,099	0,289	0,486	0,704	0,904	0,954	0,990
		23	0,006	0,046	0,096	0,304	0,493	0,692	0,894	0,950	0,990
	24	23	0,012	0,051	0,100	0,296	0,501	0,697	0,895	0,946	0,990
		47	0,009	0,050	0,110	0,292	0,500	0,696	0,894	0,948	0,990
0,9	12	11	0,009	0,048	0,092	0,300	0,500	0,700	0,899	0,952	0,989
		23	0,012	0,056	0,098	0,298	0,500	0,706	0,898	0,945	0,986
	24	23	0,009	0,050	0,109	0,298	0,500	0,699	0,904	0,949	0,988
		47	0,012	0,050	0,099	0,300	0,490	0,686	0,886	0,942	0,987

Iš 1 lentelės galima spręsti, kad, kai imties dydis  $n_d = 2\,000$ , statistikos  $T_1$  empirinės pasiskirstymo funkcijos beveik nesiskiria nuo  $\chi^2(d+1-r)$  pasiskirstymo funkcijos visoms pasirinktoms parametrų  $m$ ,  $d$  ir  $a$  reikšmėms. Analogiškai tikimybių įvertiniai statistikai  $T_2$  pateikti 2 lentelėje. Esant tokiam dideliui  $n_d$ , Statistikų  $T_1$  ir  $T_2$  realizacijos tiems patiems duomenims skiriasi labai nedaug. Tą atspindi 1 ir 2 lentelėse pateiktų skaičių panašumas.

2 lentelė. Tikimybės  $\hat{P}(T_2 < F_{\chi^2(d+1-3)}^{-1}(p))$  statistikai  $T_2$ , kai  $n_d = 2\,000$ ,  $rep = 4\,000$  ir NMKM įvertiniai  $\hat{\gamma}$  gaunami naudojant teisingai parinktą apribojimo funkciją  $f_1(\gamma, i)$ .

$a$	$m$	$d$	$p$								
			0,01	0,05	0,1	0,3	0,5	0,7	0,9	0,95	0,99
0,5	12	11	0,012	0,052	0,099	0,289	0,488	0,704	0,904	0,954	0,990
		23	0,006	0,046	0,096	0,304	0,494	0,693	0,894	0,950	0,990
	24	23	0,012	0,051	0,100	0,296	0,502	0,697	0,896	0,946	0,990
		47	0,010	0,050	0,111	0,295	0,502	0,698	0,894	0,948	0,990
0,9	12	11	0,009	0,048	0,092	0,300	0,500	0,700	0,899	0,952	0,989
		23	0,012	0,056	0,098	0,298	0,500	0,708	0,898	0,945	0,986
	24	23	0,009	0,050	0,109	0,299	0,501	0,700	0,904	0,949	0,988
		47	0,012	0,051	0,099	0,302	0,492	0,688	0,887	0,942	0,987

Tikimybių įverčiai (4.2) statistikai  $T_3$  pateikti 3 lentelėje. Į modelį papildomai įtraukiamas laisvasis narys ir po du stacionarius ir integruotus kintamuosius, kaip apibrėžta 4.1 skyrelyje. Iš 3 lentelės matyti, kad gautos tikimybės yra artimos tikrosioms. 2 pav. priede II pateikti statistikos  $T_3$  empirinės tankio funkcijos grafikai, gauti iš tų pačių  $T_3$  realizacijų, kurioms skaičiuotos 3 lentelės tikimybės. Taip pat pateikiami  $\chi^2(d+1-r)$  atsitiktinio dydžio tankio funkcijos grafikai, visais atvejais beveik sutampantys su  $T_3$  tankio funkcijos grafikais. Analogiškai tankio funkcijų grafikai statistikoms  $T_1$  ir  $T_2$  yra ne mažiau artimi  $\chi^2(d+1-r)$  tankio funkcijos grafikams, todėl, nenorint dubliuoti informacijos, nepateikiami.

Paskutinis šio skyrelio tikslas yra empiriškai patikrinti teiginio 3.3 galiojimą  $\tilde{H}_0$  atveju, t.y., kad  $T_5 - T_3 \xrightarrow{p} 0$ , kai  $n_d \rightarrow \infty$ . Kaip jau minėta, iš šio teiginio išplaukia teiginys 3.4

3 lentelė. Tikimybės  $\hat{P}(T_3 < F_{\chi^2(d+1-3)}^{-1}(p))$  statistikai  $T_3$ , kai  $n_d = 2000$ ,  $rep = 4000$  ir NMKM įvertiniai  $\hat{\gamma}$  gaunami naudojant teisingai parinktą apribojimo funkciją  $f_1(\gamma, i)$ .

$a$	$m$	$d$	$p$								
			0,01	0,05	0,1	0,3	0,5	0,7	0,9	0,95	0,99
0,5	12	11	0,011	0,049	0,098	0,303	0,508	0,706	0,894	0,942	0,986
		23	0,012	0,049	0,102	0,292	0,484	0,691	0,894	0,946	0,990
	24	23	0,010	0,054	0,108	0,306	0,502	0,695	0,895	0,947	0,988
		47	0,009	0,052	0,103	0,295	0,489	0,691	0,899	0,947	0,990
0,9	12	11	0,009	0,049	0,099	0,301	0,516	0,707	0,907	0,955	0,987
		23	0,010	0,051	0,099	0,308	0,505	0,712	0,904	0,947	0,989
	24	23	0,011	0,050	0,099	0,304	0,505	0,699	0,894	0,947	0,990
		47	0,009	0,046	0,098	0,287	0,495	0,701	0,896	0,953	0,992

apie statistikos  $T_5$  asimptotinį elgesį. Jeigu  $E(T_5 - T_3)^2 \rightarrow 0$ , kai  $n_d \rightarrow \infty$ , tai  $T_5 - T_3 \xrightarrow{p} 0$ , kai  $n_d \rightarrow \infty$ . Empiriškai patikrinkime, kad  $E(T_5 - T_3)^2 \rightarrow 0$ , kai  $n_d \rightarrow \infty$ . Gavus statistikų  $T_3$  ir  $T_5$  realizacijų rinkinius  $\{T_{3,1}, \dots, T_{3,rep}\}$  ir  $\{T_{5,1}, \dots, T_{5,rep}\}$ , skaičiuojamas jų vidutinis kvadratinis nuokrypis  $mse(T_5, T_3)$ :

$$mse(T_5, T_3) := \frac{1}{rep} \sum_{i=1}^{rep} (T_{5,i} - T_{3,i})^2.$$

$mse(T_5, T_3)$  yra  $E(T_5 - T_3)^2$  Monte Carlo metodo įvertinys. 4 lentelėje pateiktos gautos  $\sqrt{mse(T_5, T_3)}$  reikšmės, kai statistikos skaičiuojamos duomenis generuojant su imties dydžiais  $n_d \in \{75, 125, 200, 500, 1000, 2000\}$ , Monte Carlo kartojimų skaičius  $rep = 1000$ .

4 lentelė.  $\sqrt{mse(T_5, T_3)}$  reikšmės skirtingiems imties dydžiams, kai  $rep = 1000$  ir NMKM įvertiniai  $\hat{\gamma}$  gaunami naudojant teisingai parinktą apribojimo funkciją  $f_1(\gamma, i)$ .

$a$	$m$	$d$	$n_d$					
			75	125	200	500	1000	2000
0,5	12	11	0,934	0,477	0,262	0,103	0,048	0,025
		23	2,856	1,354	0,759	0,255	0,126	0,060
	24	23	2,655	1,106	0,681	0,228	0,114	0,055
		47	15,905	3,542	1,701	0,549	0,250	0,120
0,9	12	11	0,915	0,505	0,267	0,095	0,050	0,026
		23	3,104	1,337	0,785	0,278	0,120	0,060
	24	23	2,572	1,153	0,613	0,234	0,108	0,055
		47	16,629	3,810	1,706	0,554	0,253	0,121

Iš 4 lentelės galima spręsti, kad  $\sqrt{mse(T_5, T_3)}$  reikšmės mažėja, didėjant imties dydžiui  $n_d$ . Tai patvirtina teiginio, kad  $T_5 - T_3 \xrightarrow{p} 0$ , kai  $n_d \rightarrow \infty$ , galiojimą teisingos nulinės hipotezės atveju.  $\sqrt{mse(T_5, T_3)}$  reikšmės taip pat parodo, kiek maždaug vidutiniškai  $T_5$  skiriasi nuo  $T_3$  kiekvienoje imtyje<sup>10</sup>. Iš 4 lentelės paskutinio stulpelio matome, kad statistikos  $T_5$  ir  $T_3$  yra praktiškai lygios, kai  $n_d = 2000$ .

<sup>10</sup>Čia sakoma „maždaug“, nes kiek vidutiniškai  $T_5$  skiriasi nuo  $T_3$  parodytų vidurkio  $E|T_5 - T_3|$  įvertis.

### 4.3 Testo statistikų asimptotinis elgesys, kai nulinė hipotezė neteisinga

Skyriuose 2 ir 3 statistikoms  $T_i$ ,  $i = 1, 3, 5$  gautas rezultatas, kad, jei nulinė hipotezė neteisinga,  $T_i \xrightarrow{p} \infty$ , kai  $n_d \rightarrow \infty$ ,  $i = 1, 3, 5$ . Nors formaliai statistikai  $T_2$  tokio teiginio nepavyko įrodyti, greičiausiai jis yra teisingas ir šiai statistikai. Šiame skyrelyje aprašomas šių rezultatų empirinis patikrinimas.

Aprašysime naudotą metodą. Pasirenkamas didelis imties dydis  $n$ , kuriam sugeneruojamas vienas iš 4.1 skyrelyje aprašytų duomenis generuojančių procesų. Tegu mažesni imties dydžiai  $n_1, \dots, n_k$  yra tokie, kad  $n_1 < n_2 < \dots < n_k < n$ . Kiekvienam  $n_j$ ,  $j = 1, \dots, k$ , nuo imties pradžios iki  $n_j$ -ojo stebėjimo suskaičiuojamos statistikos  $\{T_i(n_1), \dots, T_i(n_k)\}$ ,  $i = 1, 2, 3, 5$ . Čia  $T(n_j)$  žymi, kad statistika  $T$  skaičiuota duomenų imčiai, kurios dydis yra  $n_j$ . Lieka nubrėžti grafikus  $G_i := \{(n_j, T_i(n_j))\}_{j=1, \dots, k}$ ,  $i = 1, 2, 3, 5$ . Jei apribojimo funkcija yra pasirinkta neteisingai, šie grafikai turi iliustruoti teiginio, kad  $T_i \xrightarrow{p} \infty$ , kai  $n_d \rightarrow \infty$ , teisingumą.

Taip pat įvertinamas statistikų vidurkis imties dydžiams  $n_1, \dots, n_k$ . Monte Carlo kartojimų skaičiui  $rep$  gaunami statistikų rinkiniai  $\{T_{i,1}(n_j), \dots, T_{i,rep}(n_j)\}$ ,  $i = 1, 2, 3, 5$ ,  $j = 1, \dots, k$ . Skaičiuojami statistikų vidurkių įverčiai  $\bar{T}_i(n_j) = 1/rep \sum_{l=1}^{rep} T_{i,l}(n_j)$ ,  $i = 1, 2, 3, 5$ ,  $j = 1, \dots, k$ . Šiems įverčiams gaunami grafikai  $\bar{G}_i := \{(n_j, \bar{T}_i(n_j))\}_{j=1, \dots, k}$ ,  $i = 1, 2, 3, 5$ .

Pasirinktos tokios 4.1 skyrelyje aprašytų DGP reikšmės:  $a = 0.5$ ,  $m = 12$ ,  $d = 23$ . Koeficientai  $\beta_{0,d}$  tenkina apribojimą  $f_2$ , bet vertinami naudojant funkciją  $f_1$ , kaip apibrėžta 4.1 skyrelyje. Didžiausias imties dydis pasirinktas  $n_k = 20\,000$ , skirtumas tarp imties dydžių  $n_j - n_{j-1} = 200$ ,  $j = 1, \dots, k$ ,  $n_0 = 0$ . Procesas kartojamas penkis kartus, t.y., gaunama po penkis grafikų  $G_i$ ,  $i = 1, 2, 3, 5$ , realizacijas, kurios pateiktos 3 pav. priede II. Storesne linija taip pat pateikti grafikai  $\bar{G}_i$ ,  $i = 1, 2, 3, 5$ , kai Monte Carlo kartojimų skaičius  $rep = 100$ .

Iš 3 pav. matome, kad neteisingos nulinės hipotezės atveju visų statistikų reikšmės didėja, augant imties dydžiui. Kintantis atstumas tarp skirtingų grafiko  $G_1$  realizacijų paaškinamas tuom, kad iš (A.44),  $T_1 = O_p(n_d) + O_p(n_d^{1/2}) + O_p(1)$ . Būtent nariai  $O_p(n_d^{1/2}) + O_p(1)$  daugiausia lemia šį kintantį atstumą. Toks pats paaškinimas galioja ir statistikoms  $T_2$ ,  $T_3$  ir  $T_5$ .

### 4.4 Miller'io parametrų apribojimo funkcijos adekvatumo testas ir jo empirinio reikšmingumo tyrimas

Šiame skyrelyje trumpai aprašomas Miller'io apribojimo funkcijos adekvatumo testas. Taip pat pateikiama nedidelė Miller'io testo empirinio reikšmingumo analizė. Remiantis V. Kvedaro pastebėjimu, iš [12] lentelės 2 galima numanyti, kad testo statistika prie nulinės hipotezės neturi  $\chi^2$  skirstinio su nurodytu laisvės laipsnių skaičiumi, kurį, pagal [12] teiginį 5 (Proposition 5) privalo turėti. [12] lentelėje 2 pateiktos testo empirinio reikšmingumo reikšmės tik mažiems imties dydžiams (25, 50, 100), todėl, norint patikrinti, ar Miller'io testo statistika yra asimptotiškai pasiskirsčiusi pagal  $\chi^2$  skirstinį su konkrečiu laisvės laipsnių

skaičiumi, reikia atlikti Monte Carlo eksperimentą su didesniais imties dydžiais.

Trumpai aprašysime [12] pateiktą statistinį testą. Lygiai kaip ir mūsų nagrinėjamas, Miller'io testas gali būti naudojamas tiek integruotų, tiek stacionarių skirtingo dažnio kintamųjų atveju. Taip pat Miller'io testas gali būti naudojamas, kai į dviejų kintamųjų modelių įtraukiami kiti paaiškinantieji kintamieji. Šiame ir kitame skyreliuose apsiribojama baziniu (4.1) modeliu be papildomų kintamųjų. [12] nagrinėjamas tik  $d + 1 = m$  atvejis, tačiau nėra priežasčių, kodėl Miller'io testas negali būti taikomas be šio apribojimo. Tegu pradinis modelis matriciniu pavidalu yra toks, kaip apibrėžta (2.18):

$$\mathbf{y} = \mathbf{V}\beta_{0,d} + \mathbf{X}\beta_d + \mathbf{u}. \quad (4.3)$$

Parametrus  $\beta_{0,d}$  apiboti naudojama funkcija  $\mathbf{f}(\gamma)$ :

$$\mathbf{y} = \mathbf{V}\mathbf{f}(\gamma) + \mathbf{X}\beta_d + \mathbf{e}.$$

Gavus parametrų  $\gamma$  ir  $\beta_d$  įverčius  $\hat{\gamma}$  ir  $\hat{\beta}_d$ , įvertinamos liekanos  $\mathbf{e}$ :

$$\hat{\mathbf{e}} := \mathbf{y} - \mathbf{V}\mathbf{f}(\hat{\gamma}) - \mathbf{X}\hat{\beta}_d.$$

Miller'io testas paremtas tokio regresinio modelio sudarymu:

$$\hat{\mathbf{e}} = (\mathbf{V}\mathbf{f}(\hat{\gamma}))\zeta_0 + (\mathbf{V}\mathbf{W})\zeta_1 + \mathbf{X}\zeta_2 + \boldsymbol{\varepsilon}_e. \quad (4.4)$$

Čia  $\mathbf{W}$ , kaip teigiama [12], yra  $(d + 1) \times q$  laisvai pasirenkamų svorių matrica. Miller'io testas paremtas hipotezės, kad  $\zeta_1 = \mathbf{0}$ , testavimu<sup>11</sup>. Jeigu yra parinkta teisinga apribojimo funkcija, tuomet  $\zeta_1 = \mathbf{0}$ . Jei apribojimo funkcija yra parinkta blogai, tuomet jeigu dalį įvertintų liekanų  $\hat{\mathbf{e}}$  dispersijos paaiškina kintamieji  $\mathbf{V}\mathbf{W}$ , tai  $\zeta_1 \neq \mathbf{0}$ .

Straipsnyje [12] tiksliai nėra pateikta hipotezės, kad  $\zeta_1 = \mathbf{0}$ , testo statistikos. Tačiau iš [12] teiginio 5 įrodymo galima suprasti, kad tai tiesiog Wald testo statistika, kuri toliau ir apibrėžta. Tegu  $q \times (q + 2)$  išrinkimo matrica  $\mathbf{P}$  yra tokia kad  $\mathbf{P}(\zeta_0, \zeta_1', \zeta_2)' = \zeta_1$ . Gaunami parametrų  $\zeta_0$ ,  $\zeta_1$  ir  $\zeta_2$  MKM įverčiai  $\hat{\zeta}_0$ ,  $\hat{\zeta}_1$  ir  $\hat{\zeta}_2$ . Taip pat gaunamas įprastinis liekanų  $\boldsymbol{\varepsilon}_e$  dispersijos  $\sigma_{\boldsymbol{\varepsilon}_e}^2$  įvertis  $\hat{\sigma}_{\boldsymbol{\varepsilon}_e}^2$ , kurio skaičiavime, kaip įprasta, atsižvelgiama į vertinamų parametrų skaičių. Tegu  $\mathbf{V}^*$  yra  $n_d \times (q + 2)$  bendra duomenų matrica (4.4) regresijoje, t.y.,

$$\mathbf{V}^* := \begin{bmatrix} \mathbf{V}\mathbf{f}(\hat{\gamma}), & \mathbf{V}\mathbf{W}, & \mathbf{X} \end{bmatrix}.$$

Tuomet Miller'io testo statistika  $T_M$  yra:

$$T_M := \frac{1}{\hat{\sigma}_{\boldsymbol{\varepsilon}_e}^2} \hat{\zeta}_1' \left[ \mathbf{P}(\mathbf{V}^{*'} \mathbf{V}^*)^{-1} \mathbf{P}' \right]^{-1} \hat{\zeta}_1. \quad (4.5)$$

<sup>11</sup> Iš tikrųjų, [12] testuojama hipotezė, kad  $\zeta_1 = \mathbf{0}$  ir  $\zeta_2 = 0$ , tačiau mūsų atveju parametras  $\beta_d$  prie  $\mathbf{X}$  nėra apribojamas (panašu, kad ir [12] jis nėra apribojamas), todėl  $\zeta_2 = 0$  tiek prie nulinės, tiek prie alternatyvios hipotezių. Todėl nėra priežasties kartu tikrinti, kad  $\zeta_2 = 0$ , ir taip mažinti testo galią.

Statistika  $T_M$  yra įprastinė Wald testo statistika hipotezei, kad  $\zeta_1 = \mathbf{0}$ , tikrinti (4.4) modelyje. Pagal [12], esant teisingai parinktai apribojimo funkcijai,  $T_M \xrightarrow{d} \chi^2(q)$ , kai  $n_d \rightarrow \infty$ , kur  $q$  yra matricos  $\mathbf{W}$  stulpelių skaičius.

Norint įsitikinti ir įtikinti, kad  $T_M$  statistika yra teisingai apibrėžta, taip pat atliktas hipotezės, kad  $\zeta_1 = \mathbf{0}$ , testas tokiai kontrolinei regresijai:

$$\varepsilon_W = (\mathbf{V}\mathbf{f}(\hat{\gamma}))\zeta_0 + (\mathbf{V}\mathbf{W})\zeta_1 + \mathbf{X}\zeta_2 + \varepsilon_W, \quad (\zeta_0, \zeta_1', \zeta_2) = (0, \mathbf{0}, 0), \quad \varepsilon_{W,t} \sim N(0, 1), \quad (4.6)$$

kur  $\varepsilon_W$  yra generuotas nepriklausomai nuo proceso  $v$  ir yra n.v.p. Skaičiuojame statistiką  $T_W$ , analogišką statistikai  $T_M$ :

$$T_W = \frac{1}{\hat{\sigma}_{\varepsilon_W}^2} \hat{\zeta}_1' \left[ \mathbf{P} (\tilde{\mathbf{V}}' \tilde{\mathbf{V}})^{-1} \mathbf{P}' \right]^{-1} \hat{\zeta}_1. \quad (4.7)$$

Šiuo atveju įverčiai  $\hat{\sigma}_{\varepsilon_W}^2$ ,  $\hat{\zeta}_1$  yra gauti vertinant (4.6) regresijos parametrus. Jei  $T_W$  statistika apibrėžta teisingai, tai tokiai regresijai teiginys, kad  $T_W \xrightarrow{d} \chi^2(q)$ , kai  $n_d \rightarrow \infty$ , turi galioti.

Monte Carlo eksperimentas atliktas, kai  $m = 12$ ,  $d = 11$ ,  $a = 0.5$ ,  $\sigma_u^2 = 1$ , imties dydžiams  $n_d \in \{25, 50, 100, 200, 500, 1000\}$ , kartojimų skaičius  $rep = 4000$ . Naudojama „Almon lag“ apribojimo funkcija  $f_1$  su trimis hiper-parametrais, kaip apibrėžta 4.1 skyrelyje. Su šia apribojimo funkcija generuojami ir parametrai  $\beta_{0,d}$ . Sviurių matrica  $\mathbf{W}$  atitinka [12] naudotos sviurių matricos paskutinius šešis stulpelius. Taigi  $q = 6$ . Šie svoriai nurodyti [12] lentelėje 1 ir yra tokie, kad kiekvieno matricos  $\mathbf{W}$  stulpelio suma lygi vienetui. Sviurių matrica nenaudojama lygiai tokia pati [12] dėl išskylančios multikolinearumo problemos, kada MKM įverčiai  $\hat{\zeta}$  negali būti suskaičiuoti<sup>12</sup>. Primintina, kad sviurių matrica  $\mathbf{W}$ , kaip teigiama [12], yra laisvai pasirenkama.

Gautus rezultatus lengviausia apibūdinti grafiškai lyginant skirtingiems imties dydžiams gautas empirines statistikų  $T_M$  ir  $T_W$  tankio funkcijas su  $\chi^2(6)$  tankio funkcija. Šios tankio funkcijos pateiktos 4 pav. priede II. Iš 4 pav. galima teigti, kad statistika  $T_M$  pagal pasiskirstymą į  $\chi^2(6)$  atsitiktinį dydį nekonverguoja. Taip pat galima teigti, kad statistikos  $T_W$  pasiskirstymas didesniems imties dydžiams yra labai artimas  $\chi^2(6)$  pasiskirstymui. Todėl  $T_W$  sudaryta teisingai, t.y.,  $T_W$  yra Wald testo statistika paramerų  $\zeta_1$  lygybės nuliui hipotezei tikrinti. Reikia paminėti, kad tokios pačios išvados apie Miller'io testo statistikos pasiskirstymą  $\tilde{H}_0$  atveju būtų daromos, jei (4.3) modelyje nebūtų integruoto kintamojo  $\mathbf{X}$ , t.y., būtų generuojami stacionarūs procesai, kas atitiktų [8] nagrinėtą modelį.

Modelyje (4.4) sviurių matricos  $\mathbf{W}$  galima ir nenaudoti, t.y., imti  $\mathbf{W} := \mathbf{I}_{d+1}$ . Tuomet parametru  $\zeta_1$  skaičius būtų lygus  $d + 1$ . Tada, pagal [12] teiginį 5,  $T_M \xrightarrow{d} \chi^2(d + 1)$ , jei  $\tilde{H}_0$  teisinga. Tačiau Monte Carlo eksperimentu<sup>13</sup> toks skirstinys negaunamas. Visais atvejais  $T_M$  empirinė tankio funkcija gaunama panaši į  $\chi^2$  tankio funkciją su mažesniu už  $d + 1$  laisvės laipsnių skaičiumi, tačiau nėra visiškai aišku, su koku tiksliai.

<sup>12</sup>[12] taip pat minima multikolinearumo problema, tačiau nevisiškai aišku, tiksliai kaip ji yra išsprendžiama.

<sup>13</sup>Šio Monte Carlo eksperimento rezultatai darbai nėra esminiai, todėl nepateikiami.

Reikia pasakyti, kad šiame skyrelyje nėra teigiama, kad [12] teiginys 5 yra neteisingas. Tačiau jeigu Monte Carlo eksperimentai atlikti teisingai, tuomet kyla abejonių dėl teiginio 5 teisingumo.

## 4.5 Apribojimo funkcijos adekvatumo testų galios palyginimas

Šiame skyrelyje palyginama nagrinėjamo ir Miller'io testų galia ir koreguota galia. Apsiribojama (4.1) modeliu be papildomų paaiškinančiųjų kintamųjų, tiems patiems generuotiems duomenims skaičiuojant statistikas  $T_1$ ,  $T_2$  ir  $T_M$ .

Miller'io teste naudojamamos svorių matricos dimensija yra  $(d+1) \times q$ . Taigi skirtingiems  $d$  reikia apibrėžti vis kitokias svorių matricas. Atveju  $d = 11$  skyrelyje 4.4 buvo naudota tokia svorių matrica, kokia apibrėžta [12] lentelėje 1. Testo galios Monte Carlo eksperimente  $d = 11$  atveju naudota ta pati svorių matrica  $\mathbf{W}$ . Kai  $d = 23$  arba  $d = 47$ , atitinkamai apibrėžtos tokios svorių matricos  $\mathbf{W}_{24}$  ir  $\mathbf{W}_{48}$ :

$$\mathbf{W}'_{24} := \begin{bmatrix} \mathbf{W}' & \mathbf{W}' \end{bmatrix}, \quad \mathbf{W}'_{48} := \begin{bmatrix} \mathbf{W}' & \mathbf{W}' & \mathbf{W}' & \mathbf{W}' \end{bmatrix}.$$

Visais atvejais svorių matricų stulpelių skaičius  $q = 6$ .

Testo galia yra tikimybė atmesti neteisingą nulinę hipotezę  $\tilde{H}_0$ . Tegu pasirinktas reikšmingumo lygmuo  $\alpha^*$ . Statistikoms  $T_1$  ir  $T_2$  hipotezę  $\tilde{H}_0$  atmetame, jei  $T_i > F_{\chi^2(d+1-r)}^{-1}(1 - \alpha^*)$ . Statistikai  $T_M$  hipotezę  $\tilde{H}_0$  atmetame, jei  $T_M > F_{\chi^2(q)}^{-1}(1 - \alpha^*)$ . Monte Carlo eksperimentas atliktas 4.1 skyrelyje aprašytiems duomenis generuojantiems procesams, kada koeficientai  $\beta_{0,d}$  yra generuojami funkcijų  $f_2$  ir  $f_3$ , bet NMKM metodu vertinami, naudojant neteisingai parinktą apribojimo funkciją  $f_1$ . Testo galia įvertinama imant  $\tilde{H}_0$  atmetimų dalį nuo kartojimų skaičiaus  $rep = 4000$ .

Lentelėje 5 priede III pateikti aprašyto Monte Carlo eksperimento rezultatai, kai  $\alpha^* = 0,05$ . Matome, kad statistikų  $T_1$  ir  $T_2$  galia yra panaši, tačiau  $T_1$  galia dažniau yra didesnė už  $T_2$  galią. Taip pat matome, kad augant imties dydžiui, testo galia didėja. Esant fiksuotiems dydžiams  $m$ ,  $d$  ir  $n_d$ , bet keičiant autoregresinį parametą  $a$  iš 0,5 į 0,9, galia statistikoms  $T_1$  ir  $T_2$  yra didesnė  $a = 0,9$  atveju. Tikėtina, kad taip yra dėl tikslesnių modelio parametų įvertinių, kai  $a = 0,9$ .

Iš 5 lentelės matome, kad visais duomenis generuojančių procesų atvejais statistikoms  $T_1$  ir  $T_2$  galia yra didesnė už Miller'io testo galią. Tačiau toks testų galios palyginimas nėra visiškai korektiškas dėl statistikų empirinių skirstinių neatitikimo asimptotiniams baigtinėje imtyje, jei nulinė hipotezė teisinga. Todėl reikalinga palyginti koreguotas testų galias, kai hipotezės atmetimo kritinės reikšmės gaunamos Monte Carlo metodu, kuriuo įvertinamas statistikų pasiskirstymas, kai nulinė hipotezė teisinga. Visgi tokios galimybės neturi testuotojas, kuomet turima tik viena duomenų imtis. Taigi neteisinga nulinė hipotezė bus atmesta dažniau naudojant statistikas  $T_1$  ar  $T_2$  nei statistiką  $T_M$ .

Toliau šiame skyrelyje lyginama tik koreguota testų galia. Trumpai aprašysime naudo-

tą metodą. Tegu  $\bar{F}_{0,T}$  ir  $\bar{F}_{1,T}$  yra statistikos  $T$  išlikimo funkcijos<sup>14</sup> atitinkamai  $\tilde{H}_0$  ir  $\tilde{H}_1$  atvejais. Tuomet pasirinktam reikšmingumo lygmeniui  $\alpha^*$  koreguota galia statistikai  $T$  yra  $\bar{F}_{1,T}(\bar{F}_{0,T}^{-1}(\alpha^*))$ .  $\bar{F}_{0,T}^{-1}(\alpha^*)$  yra tikslus statistikos  $T$  pasiskirstymo  $1 - \alpha^*$  lygmens kvantilis, kai  $\tilde{H}_0$  teisinga. Koreguota galia įvertinama, Monte Carlo metodu gavus funkcijų  $\bar{F}_{0,T}$  ir  $\bar{F}_{1,T}$  įverčius.

Lentelėje 6 priede III pateikti koreguotos testų galios Monte Carlo eksperimento rezultatai statistikoms  $T_1$ ,  $T_2$  ir  $T_M$ . Reikšmingumo lygmuo  $\alpha^* = 0,05$ , kartojimų skaičius  $rep = 4\,000$ . Matome, kad koreguota testo galia statistikoms  $T_1$  ir  $T_2$  beveik nesiskiria. Vadinasi, nėra pagrindo naudoti sudėtingesnę statistiką  $T_2$  vietoj  $T_1$  net mažose imtyse. Palyginkime gautus rezultatus statistikoms  $T_1$  ir  $T_M$ . Iš 6 lentelės matome, kad dažniau koreguota galia yra didesnė statistikos  $T_M$ , tačiau gana nežymiai. Didesnis nei 0,1 koreguotų galių skirtumas gautas 7 kartus statistikai  $T_1$  ir 5 kartus statistikai  $T_M$ . Likusiems 52 duomenis generuojančių procesų atvejais koreguotų galių skirtumo modulis neviršija 0,1. Įdomu, kad  $d = 47$  koreguota galia statistikai  $T_1$  yra didesnė už  $T_M$  beveik visiems imties dydžiams  $n_d$ .

Testų galios palyginimo išvados gali skirtis pasirinktiems skirtingiems reikšmingumo lygmenims. Koreguota testų galia kiekvienam reikšmingumo lygmeniui  $\alpha^* \in [0, 1]$  dažnai lyginama grafiškai. Grafikas  $\{(\alpha^*, \bar{F}_{1,T}(\bar{F}_{0,T}^{-1}(\alpha^*)))\}_{\alpha^* \in [0,1]}$  straipsnyje [9] vadinamas ROC kreive<sup>15</sup>. Didinant  $\alpha^*$ , mažėja kritinė reikšmė  $\bar{F}_{0,T}^{-1}(\alpha^*)$ , taigi didėja koreguota galia  $\bar{F}_{1,T}(\bar{F}_{0,T}^{-1}(\alpha^*))$ . Viename grafike galima piešti kelias ROC kreives skirtingoms statistikoms ir taip grafiškai palyginti testų galią įvairiems reikšmingumo lygmenims  $\alpha^*$ . Tame pačiame pav. galima iliustruoti ir testo statistikų empirinio ir teorinio asimptotinio pasiskirstymų skirtumus, kai  $\tilde{H}_0$  teisinga<sup>16</sup>. Tegu  $\bar{F}_{a,T}$  yra statistikos  $T$  teorinė asimptotinė pasiskirstymo funkcija, kai  $\tilde{H}_0$  teisinga. Grafiką  $\{(\alpha^*, \bar{F}_{0,T}(\bar{F}_{a,T}^{-1}(\alpha^*)))\}_{\alpha^* \in [0,1]}$  vadinsime P-P kreive<sup>17</sup>, kuri iliustruoja statistikos  $T$  pasiskirstymo nuokrypius baigtinėje imtyje nuo teorinio asimptotinio pasiskirstymo. Kuo šis grafikas labiau panašus į  $45^\circ$  tiesę, tuo labiau sutampa baigtinės imties ir teoriniai asimptotiniai pasiskirstymai.

Pasirinkta 16 skirtingų duomenis generuojančių procesų šiems parametrų variantams:  $n_d \in \{125, 500\}$ ;  $a \in \{0.5, 0.9\}$ ;  $d = 11$ , kai  $m = 12$ ;  $d = 47$ , kai  $m = 24$ . 5 pav. pateikti ROC ir P-P kreivių grafikai statistikoms  $T_1$  ir  $T_M$ , kai ROC kreivėms parametrai  $\beta_{0,d}$  yra funkcijos  $f_2$  reikšmės, 6 pav. – funkcijos  $f_3$  reikšmės. Matome, kad statistikos  $T_1$  P-P kreivės  $n_d = 500$  atveju gana tiksliai sutampa su  $45^\circ$  tiese. Atvirkščiai, statistikos  $T_M$  P-P kreivės rodo jos empirinių skirtstinių neatitikimą teoriniam asimptotiniam  $\chi^2(q)$  skirstiniui visais atvejais. ROC kreivės gautos arba beveik sutampančios, arba besiskiriančios kažkurios statistikos naudai visiems  $\alpha^* \in [0, 1]$ . Apibendrinant, šio Monte Carlo eksperimento rezultatai neleidžia teigti, kad kažkuris parametrų apribojimo funkcijos adekvatumo testas yra geresnis už kitą.

<sup>14</sup>Jei  $F(x) = P(T \leq x)$ ,  $x \in \mathbb{R}$ , yra atsitiktinio dydžio  $T$  pasiskirstymo funkcija, tai funkciją  $\bar{F}(x) = P(T > x)$  vadinsime atsitiktinio dydžio  $T$  išlikimo funkcija.  $\bar{F}^{-1}(\alpha^*)$ ,  $\alpha^* \in [0, 1]$ , žymėsime  $\bar{F}$  atvirkštinę funkciją.

<sup>15</sup>ROC curve – receiver operating characteristic curve, angl.

<sup>16</sup> $T_1$  ir  $T_2$  teorinis asimptotinis pasiskirstymas, kai  $\tilde{H}_0$  teisinga, yra  $\chi^2(d + 1 - r)$ , statistikos  $T_M$  –  $\chi^2(q)$ .

<sup>17</sup>Probability-Probability, angl.

## 5 Išvados

Darbe nagrinėtas parametų apribojimo funkcijos adekvatumo statistinis testas, kuris pristatytas straipsnyje [8]. Testas pritaikytas integruotų kintamųjų regresiniam modeliui. Dviejų skirtingo dažnio kintamųjų regresiniame modelyje [8] testo statistika apibrėžta integruoto paaiškinančiojo kintamojo skirtumams. Taip pat darbe parametų apribojimo funkcijos adekvatumo testas apibendrintas integruotų kintamųjų regresiniam modeliui su papildomais paaiškinančiais kintamaisiais. Apibrėžtos dvi testo statistikos. Į pirmos statistikos apibrėžimą įtraukiami papildomų stacionarių kintamųjų duomenys. Į antros statistikos apibrėžimą simetriškai įtraukiami visų modelio kintamųjų duomenys. Jei nulinė hipotezė teisinga, visoms paminėtoms statistikoms įrodytas jų konvergavimas pagal pasiskirstymą į  $\chi^2$  atsitiktinį dydį su žinomu laisvės laipsnių skaičiumi. Jei nulinė hipotezė neteisinga, įrodytas statistikų divergavimas. Šie matematiniai rezultatai patikrinti empiriškai. Taip pat palyginta nagrinėjamo ir [12] pristatyto testų galia. Gauta, kad nagrinėjamo testo galia yra didesnė visiems nagrinėtiems duomenis generuojantiems procesams. Viena iš šio rezultato priežasčių yra dideli [12] pristatyto testo statistikos teorinio asimptotinio ir empirinio baigtinės imties pasiskirstymų skirtumai. Palyginus koreguotas galias gauta, kad nei vienas testas nėra geresnis už kitą visiems nagrinėtiems duomenis generuojantiems procesams.

Tolimesnis tyrimas galėtų būti vykdomas keliomis kryptimis. Pirma, reikalingas gautų matematinių rezultatų patvirtinimas sušvelninus prielaidas. Taip parametų apribojimo funkcijos adekvatumo testas būtų apibendrintas didesniame duomenis generuojančių procesų ratui. Antra, reikalingi testo statistikos ar parametų vertinimo modifikavimai, kurie padidintų testo galia.



## Literatūra

- [1] E. Andreou, E. Ghysels, A. Kourtellos. Regression models with mixed sampling frequencies, *Journal of Econometrics*, 2010, **158** (2), p. 246–261.
- [2] D. W. K. Andrews. Asymptotic results for generalized Wald tests, *Econometric Theory*, 1987, **3** (03), p. 348-358.
- [3] R. Davidson, J. G. Mackinnon. *Econometric theory and methods*, New York: Oxford University Press, 1999, 688 p.
- [4] E. Ghysels, P. Santa-Clara, R. Valkanov. The MIDAS touch: mixed data sampling regression models, *CIRANO Working Paper*, 2004, 2004s-20.
- [5] E. Ghysels, P. Santa-Clara, R. Valkanov. There is a risk-return trade-off after all, *Journal of Financial Economics*, 2005, **76** (3), p. 509-548.
- [6] E. Ghysels, A. Sinko, R. Valkanov. MIDAS regressions: further results and new directions, *Econometric Reviews*, 2007, **26** (1), p. 53-90.
- [7] J. D. Hamilton. *Time series analysis*, Princeton, New Jersey: Princeton University Press, 1994, 820 p.
- [8] V. Kvedaras, V. Zemlys. Testing the functional constraints on parameters in regressions with variables of different frequency, *Economics Letters*, 2012, **116** (2), p. 250-254.
- [9] C. J. Lloyd. Estimating test power adjusted for size, *Journal of Statistical Computation and Simulation*, 2005, **75** (11), p. 921-934.
- [10] H. Lütkepohl. *Handbook of matrices*, Chichester: John Wiley & Sons, 1996, 304 p.
- [11] H. Lütkepohl. *New introduction to multiply time series analysis*, Berlin Heidelberg: Springer, 2005, 764 p.
- [12] J. I. Miller. Cointegrating MIDAS regressions and a MIDAS test. Department of Economics, University of Missouri-Columbia, 2011, *Working Papers* 1104.
- [13] M. Schatzman. *Numerical analysis: a mathematical introduction*, New York: Oxford University Press, 2002, 512 p.

# I Teiginių įrodymai

## A Teiginio 2.2 įrodymas

Įrodyme reikės  $\mathbf{Z}'\mathbf{Z}$  ir  $\mathbf{Z}'\mathbf{u}$  konvergavimo greičių, kai  $n_d \rightarrow \infty$ . Pastebėkime, kad  $\mathbf{V}'\mathbf{V} = \sum_{t=t_1}^n (\tilde{\mathbf{v}}_t \tilde{\mathbf{v}}_t')$ . Remiantis [7] teiginiu 18.1 (p. 547),

$$n_d^{-1} \mathbf{V}'\mathbf{V} \xrightarrow{p} \mathbf{Q},$$

kur  $\mathbf{Q} := E(\tilde{\mathbf{v}}_t \tilde{\mathbf{v}}_t')$  iš prielaidos P4.

Parodykime, kad  $n_d^{-1/2} \mathbf{V}'\mathbf{u} \xrightarrow{d} N(\mathbf{0}, \sigma_u^2 \mathbf{Q})$ . Šio fakto įrodymas susiveda į [7] teiginio 7.9 (p. 194) (centrinė ribinė teorema vektorinių martingalinių skirtumų sekai) prielaidų patikrinimą. Pažymėkime  $\mathbf{z}_t := \tilde{\mathbf{v}}_t u_t$ . Remiantis prielaida P1,  $E(\tilde{\mathbf{v}}_t u_t) = E\tilde{\mathbf{v}}_t E u_t$ . Remiantis ta pačia prielaida,  $E(u_t | u_{t-1}, v_{t-1}, \dots) = 0$ . Todėl  $\{\mathbf{z}_t\}_{t=t_1}^\infty$  yra vektorinių martingalinių skirtumų seka. Reikia parodyti, kad ši seka tenkina [7] teiginio 7.9 sąlygas. Suskaidykime  $\mathbf{z}_t = (z_{t,1}, \dots, z_{t,d+1})'$ . Iš prielaidos P1,  $E(|z_{t,i_1} z_{t,i_2} z_{t,i_3} z_{t,i_4}|) = E(|v_{t,i_1} v_{t,i_2} v_{t,i_3} v_{t,i_4}|) E u_t^4$ ,  $\forall i_1, i_2, i_3, i_4 = 1, \dots, d+1$ . Iš prielaidos P4 ir [7] teiginio 10.2 (p. 263) išplaukia, kad  $E(|v_{t,i_1} v_{t,i_2} v_{t,i_3} v_{t,i_4}|) < \infty$ . Kadangi  $E u_t^4 < \infty$ , tai  $\mathbf{z}_t$  tenkina [7] teiginio 7.9 baigtinių ketvirtų momentų sąlygą.  $E(\tilde{\mathbf{v}}_t u_t) (\tilde{\mathbf{v}}_t u_t)' = E u_t^2 E(\tilde{\mathbf{v}}_t \tilde{\mathbf{v}}_t') = \sigma_u^2 \mathbf{Q}$ . Kadangi  $\mathbf{Q}$  yra teigiamai apibrėžta, tai ir  $\sigma_u^2 \mathbf{Q}$  yra teigiamai apibrėžta. Lieka parodyti, kad  $n_d^{-1} \sum_{t=t_1}^n (\mathbf{z}_t \mathbf{z}_t') \xrightarrow{p} \sigma_u^2 \mathbf{Q}$ . Galima pasiremti [7] pavyzdžiu 7.15 (p. 194) ir teigti, kad  $z_{t,i} z_{t,j} \xrightarrow{p} \sigma_u^2 Q_{ij}$ ,  $\forall i, j = 1, \dots, d+1$ , kur  $Q_{ij}$  žymi  $\mathbf{Q}$   $i$ -osios eilutės ir  $j$ -ojo stulpelio narį. Iš čia išplaukia norimas rezultatas. Vadinasi, remiantis [7] teiginiu 7.9,

$$n_d^{-1/2} \mathbf{V}'\mathbf{u} = n_d^{-1/2} \sum_{t=t_1}^n \tilde{\mathbf{v}}_t u_t \xrightarrow{d} N(\mathbf{0}, \sigma_u^2 \mathbf{Q}). \quad (\text{A.1})$$

Raskime  $\mathbf{V}'\mathbf{X}$ ,  $\mathbf{X}'\mathbf{X}$  ir  $\mathbf{X}'\mathbf{u}$  asimptotinių elgesį. Pažymėkime

$$\mathbf{v}_t^* = (v_{t,1}^*, \dots, v_{t,m}^*)' := (v_{tm-d-1}, v_{tm-d-2}, \dots, v_{tm-d-m})'.$$

Iš prielaidos P4,  $\tilde{\mathbf{v}}_t = \sum_{j=0}^\infty \mathbf{W}_j \boldsymbol{\varepsilon}_{t-j}$ . Taigi procesą  $\mathbf{v}_t^*$  taip pat galima užrašyti MA( $\infty$ ) forma per  $\boldsymbol{\varepsilon}_t$ :

$$\mathbf{v}_t^* = \sum_{j=0}^\infty \mathbf{W}_j^* \boldsymbol{\varepsilon}_{t-j}.$$

$m \times (d+1)$  koeficientų matricų  $\mathbf{W}_j^*$ ,  $j = 1, 2, \dots$ , narius sudaro matricų  $\mathbf{W}_j$ ,  $j = 1, 2, \dots$ , nariai. Priklausomai nuo  $d$  dydžio, kelios pirmosios koeficientų matricos  $\mathbf{W}_j^*$  gali būti nulinės. Reikia parodyti, kad procesas  $\Delta x_{tm-d-1} := \sum_{i=1}^m v_{t,i}^*$  taip pat užrašomas MA( $\infty$ ) forma. Tegu  $\mathbf{W}_{j,i}^*$  yra  $i$ -oji matricos  $\mathbf{W}_j^*$  eilutė, o  $s_i(\mathbf{W}_j^*)$  žymi matricos  $\mathbf{W}_j^*$   $i$ -ojo stulpelio elementų

sumą. Tegu  $\boldsymbol{\varepsilon}_t = (\varepsilon_{t,1}, \dots, \varepsilon_{t,d+1})'$ . Tada

$$\begin{aligned} \Delta x_{tm-d-1} &= \sum_{i=1}^m v_{t,i}^* = \sum_{i=1}^m \sum_{j=0}^{\infty} \mathbf{W}_{j,i}^* \boldsymbol{\varepsilon}_{t-j} = \sum_{j=0}^{\infty} \sum_{i=1}^m \mathbf{W}_{j,i}^* \boldsymbol{\varepsilon}_{t-j} = \sum_{j=0}^{\infty} \sum_{i=1}^{d+1} s_i(\mathbf{W}_j^*) \varepsilon_{t-j,i} \\ &= \sum_{j=0}^{\infty} [s_1(\mathbf{W}_j^*), \dots, s_{d+1}(\mathbf{W}_j^*)] \boldsymbol{\varepsilon}_{t-j}. \end{aligned} \quad (\text{A.2})$$

Pažymėkime  $\mathbf{s}(\mathbf{W}_j^*) := [s_1(\mathbf{W}_j^*), \dots, s_{d+1}(\mathbf{W}_j^*)]$ . Tada procesas  $(\tilde{\mathbf{v}}_t', \Delta x_{tm-d-1})'$  turi tokią MA( $\infty$ ) formą:

$$\begin{bmatrix} \tilde{\mathbf{v}}_t \\ \Delta x_{tm-d-1} \end{bmatrix} = \sum_{j=0}^{\infty} \begin{bmatrix} \tilde{\mathbf{W}}_j \\ \mathbf{s}(\mathbf{W}_j^*) \end{bmatrix} \boldsymbol{\varepsilon}_{t-j}. \quad (\text{A.3})$$

Kiekvienam  $i = 1, \dots, d+1$ ,

$$\sum_{j=0}^{\infty} (j |s_i(\mathbf{W}_j^*)|) \leq \sum_{j=0}^{\infty} \sum_{k=1}^m (j |W_{j,ki}^*|) = \sum_{k=1}^m \sum_{j=0}^{\infty} (j |W_{j,ki}^*|) < \infty.$$

Taigi procesas  $(\tilde{\mathbf{v}}_t', \Delta x_{tm-d-1})'$  tenkina [7] teiginio 18.1 sąlygas<sup>18</sup>.  $x_{tm-d-1} = \sum_{j=0}^t \Delta x_{jm-d-1}$ , ( $x_\tau = 0$ , kai  $\tau \leq 0$ ), todėl iš minėto teiginio,  $\mathbf{V}'\mathbf{X} = \mathbf{O}_p(n_d)$ ,  $\mathbf{X}'\mathbf{X} = O_p(n_d^2)$ . Rezultatas, kad  $\mathbf{X}'\mathbf{u} = O_p(n_d)$ , gaunamas pasinaudojus [7] teiginiu 18.1, kai  $(\tilde{\mathbf{v}}_t', \Delta x_{tm-d-1}, u_t)'$  užrašomas MA( $\infty$ ) forma:

$$\begin{bmatrix} \tilde{\mathbf{v}}_t \\ \Delta x_{tm-d-1} \\ u_t \end{bmatrix} = \begin{bmatrix} \mathbf{W}_0 & 0 \\ \mathbf{s}(\mathbf{W}_0^*) & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \boldsymbol{\varepsilon}_t \\ u_t \end{bmatrix} + \sum_{j=1}^{\infty} \begin{bmatrix} \mathbf{W}_j & 0 \\ \mathbf{s}(\mathbf{W}_j^*) & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \boldsymbol{\varepsilon}_{t-j} \\ u_{t-j} \end{bmatrix}. \quad (\text{A.4})$$

Remiantis prielaidomis P1 ir P4,  $(\boldsymbol{\varepsilon}_t', u_t)'$  yra n.v.p. atsitiktiniai vektoriai.

Apibrėžkime tokią simetrinę ir diagonalinę  $(d+2) \times (d+2)$  normavimo matricą  $\mathbf{L}$ :

$$\mathbf{L} := \begin{bmatrix} n_d^{1/2} \mathbf{I}_{d+1} & \mathbf{0} \\ \mathbf{0} & n_d \end{bmatrix}. \quad (\text{A.5})$$

Iš [7] teiginio 18.1 ir iš (A.1) gauname:

$$\mathbf{L}^{-1} \mathbf{Z}' \mathbf{u} = \begin{bmatrix} n_d^{-1/2} \mathbf{V}' \mathbf{u} \\ n_d^{-1} \mathbf{X}' \mathbf{u} \end{bmatrix} \xrightarrow{d} \begin{bmatrix} N(\mathbf{0}, \sigma_u^2 \mathbf{Q}) \\ \text{dlim}(n_d^{-1} \mathbf{X}' \mathbf{u}) \end{bmatrix}. \quad (\text{A.6})$$

(A.6) riboje pagal pasiskirtymą  $\text{dlim}(n_d^{-1} \mathbf{X}' \mathbf{u})$  tiesiog žymime tolydų atsitiktinį dydį, kurio pasiskirstymas nurodytas [7] teiginyje 18.1, tačiau šiame įrodyme jo detalizavimas yra nereikalingas. Svarbiausia, kad su tikimybe vienas šis atsitiktinis dydis neįgyja begalybės ar nulio reikšmių. Kada reikės pabrėžti, kad  $n_d^{-1} \mathbf{X}' \mathbf{V}$  ir  $n_d^{-2} \mathbf{X}' \mathbf{X}$  ne tik yra  $\mathbf{O}_p(1)$ , bet nėra

<sup>18</sup>(A.3) koeficientų matricos nėra kvadratinės. Kvadratinėmis jas galima paversti, prijungus prie  $\{\boldsymbol{\varepsilon}_t\}_{t \in \mathbb{Z}}$  kitą n.v.p. atsitiktinių dydžių seką.

$\mathbf{o}_p(1)$ , rašysime  $\text{dlim}(n_d^{-1}\mathbf{X}'\mathbf{V})$  ir  $\text{dlim}(n_d^{-2}\mathbf{X}'\mathbf{X})$ . Šių ribų pagal pasiskirstymą tikslaus detalizavimo įrodyme taip pat nereikės.

## $\tilde{H}_0$ atvejis

Tegu  $\gamma \in \Lambda$  yra toks, kad  $\mathbf{f}(\gamma) = \beta_{0,d}$ . Pažymėkime tikrąjį bendrą parametrų vektorių  $\boldsymbol{\psi} := (\gamma', \beta_d)'$ . Tuomet modelis yra:

$$\mathbf{y} = \mathbf{V}\mathbf{f}(\gamma) + \beta_d\mathbf{X} + \mathbf{u} = \mathbf{Z}\tilde{\mathbf{f}}(\boldsymbol{\psi}) + \mathbf{u}. \quad (\text{A.7})$$

Parodysime, kad  $\hat{\gamma} \xrightarrow{p} \gamma$ . Imkime įvertinių  $\hat{\boldsymbol{\psi}}$  būtiniosios sąlygos (2.23) paskutinę eilutę:

$$\mathbf{X}'(\mathbf{y} - \mathbf{V}\mathbf{f}(\hat{\gamma}) - \mathbf{X}\hat{\beta}_d^{nls}) = 0. \quad (\text{A.8})$$

Įsistatę  $\mathbf{y}$  išraišką iš (A.7) į (A.8) ir padauginę abi puses iš  $n_d^{-2}$ , gauname:

$$n_d^{-2}\mathbf{X}'\mathbf{X}(\hat{\beta}_d^{nls} - \beta_d) = n_d^{-2}\mathbf{X}'\mathbf{V}(\mathbf{f}(\gamma) - \mathbf{f}(\hat{\gamma})) + n_d^{-2}\mathbf{X}'\mathbf{u}. \quad (\text{A.9})$$

Kadangi  $n_d^{-2}\mathbf{X}'\mathbf{V} \xrightarrow{p} \mathbf{0}$ ,  $n_d^{-2}\mathbf{X}'\mathbf{u} \xrightarrow{p} 0$ , perėję prie ribos abiejose (A.9) pusėse, turime:

$$\text{dlim}(n_d^{-2}\mathbf{X}'\mathbf{X})(\beta_d - \text{plim}\hat{\beta}_d^{nls}) = 0. \quad (\text{A.10})$$

Kad (A.10) būtų tenkinama, būtina, kad  $\text{plim}\hat{\beta}_d^{nls} = \beta_d$ . Pasinaudoję šiuo faktu, įrodysime, kad  $\hat{\gamma} \xrightarrow{p} \gamma$ . Būtiniosios sąlygos (2.23) pirmosios  $d + 1$  eilutės, padauginus jas iš  $n_d^{-1}$ , yra:

$$n_d^{-1}\mathbf{D}_{f,\hat{\gamma}}\mathbf{V}'(\mathbf{y} - \mathbf{V}\mathbf{f}(\hat{\gamma}) - \mathbf{X}\hat{\beta}_d^{nls}) = \mathbf{0}. \quad (\text{A.11})$$

Iš (A.7) ir (A.11) turime:

$$n_d^{-1}\mathbf{D}_{f,\hat{\gamma}}\mathbf{V}'\mathbf{V}(\mathbf{f}(\hat{\gamma}) - \mathbf{f}(\gamma)) = n_d^{-1}\mathbf{D}'_{f,\hat{\gamma}}\mathbf{V}'\mathbf{X}(\beta_d - \hat{\beta}_d^{nls}) + n_d^{-1}\mathbf{D}'_{f,\hat{\gamma}}\mathbf{V}'\mathbf{u}. \quad (\text{A.12})$$

Pasinaudoję prielaida P3, pažymėkime  $\gamma_0 := \text{plim}(\hat{\gamma})$ . Iš tolydaus atvaizdžio teoremos,  $\mathbf{D}_{f,\hat{\gamma}} \xrightarrow{p} \mathbf{D}_{f,\gamma_0}$ . Kadangi  $\hat{\beta}_d^{nls} \xrightarrow{p} \beta_d$ ,  $n_d^{-1}\mathbf{V}'\mathbf{u} \xrightarrow{p} \mathbf{0}$ ,  $n_d^{-1}\mathbf{V}'\mathbf{V} \xrightarrow{p} \mathbf{Q}$  ir  $n_d^{-1}\mathbf{V}'\mathbf{X} = \mathbf{O}_p(1)$ , perėję prie ribos (A.12), gauname:

$$\mathbf{D}'_{f,\gamma_0}\mathbf{Q}(\mathbf{f}(\gamma) - \mathbf{f}(\gamma_0)) = \mathbf{0}. \quad (\text{A.13})$$

Akivaizdu, kad  $\gamma_0 = \gamma$  tenkina (A.13), tačiau tai nebūtinai yra vienintelis šios lygybės sprendinys. Reikia pastebėti, kad, jei galioja prielaida P4, minimizuojamos funkcijos, t.y. modelio liekanų kvadratų vidurkio, minimali reikšmė, kai  $\gamma_0 = \gamma$ , artėja į  $\sigma_u^2$ , kai  $n_d \rightarrow \infty$ . Jei  $\gamma_0 \neq \gamma$ , bet  $\gamma_0$  tenkina (A.13) lygybę, tai nesunku parodyti, kad minimizuojamos funkcijos minimali reikšmė augant duomenų skaičių artėtų į  $\sigma_u^2 + (\mathbf{f}(\gamma) - \mathbf{f}(\gamma_0))'\mathbf{Q}(\mathbf{f}(\gamma) - \mathbf{f}(\gamma_0)) > \sigma_u^2$ , o tai reiškia, kad  $\gamma_0$  prieštarautų savo apibrėžimui. Taigi  $\hat{\gamma} \xrightarrow{p} \gamma$ .

Skirtumą  $\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})$  išsireikškime per modelio kintamuosius. Naudojantis [8] pavyzdžiu, pagal tikslios Teiloro eilutės pirmos eilės aproksimaciją taške  $\gamma$ , į kurią pagal tikimybę artėja  $\hat{\gamma}$ , turime tokią lygybę:

$$\mathbf{f}(\hat{\gamma}) = \mathbf{f}(\gamma) + \mathbf{D}_{\mathbf{f},\gamma+}(\hat{\gamma} - \gamma), \quad (\text{A.14})$$

kur  $\gamma+ \in \Lambda$  yra toks taškas, kuriame (A.15) galioja. Jei  $\hat{\gamma} \xrightarrow{p} \gamma$ , tai ir  $\mathbf{f}(\hat{\gamma}) \xrightarrow{p} \mathbf{f}(\gamma)$ . Tuomet, kaip teigiama [8], remiantis vidutinės reikšmės teorema,  $\gamma+ \xrightarrow{p} \gamma$ . Remiantis tolydaus atvaizdžio teorema,  $\mathbf{D}_{\tilde{\mathbf{f}},\gamma+} \xrightarrow{p} \mathbf{D}_{\tilde{\mathbf{f}},\gamma}$ . Pastebėkime, kad iš  $\mathbf{D}_{\tilde{\mathbf{f}},\gamma+}$  apibrėžimo (2.21) seka tokia lygybė:

$$\tilde{\mathbf{f}}(\hat{\psi}) = \tilde{\mathbf{f}}(\psi) + \mathbf{D}_{\tilde{\mathbf{f}},\gamma+}(\hat{\psi} - \psi). \quad (\text{A.15})$$

Pasinaudojus (A.15), modeliu (A.7), būtinoji įvertinių  $\hat{\psi}$  sąlyga yra:

$$\begin{aligned} \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}'(\mathbf{y} - \mathbf{Z}\tilde{\mathbf{f}}(\hat{\psi})) &= \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}'(\mathbf{Z}\tilde{\mathbf{f}}(\psi) + \mathbf{u} - \mathbf{Z}\tilde{\mathbf{f}}(\hat{\psi})) \\ &= \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{\mathbf{f}},\gamma+}(\psi - \hat{\psi}) + \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{u} = 0. \end{aligned} \quad (\text{A.16})$$

Iš (A.16) gauname:

$$\hat{\psi} - \psi = (\mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{\mathbf{f}},\gamma+})^{-1} \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{u}. \quad (\text{A.17})$$

Tada, pasinaudojus (A.15) ir (A.17):

$$\tilde{\mathbf{f}}(\hat{\psi}) - \tilde{\mathbf{f}}(\psi) = \mathbf{D}_{\tilde{\mathbf{f}},\gamma+}(\mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{\mathbf{f}},\gamma+})^{-1} \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{u}. \quad (\text{A.18})$$

Lygybės (A.17) ir (A.18) yra išvestos remiantis [8], kur jos užrašytos modelio su stacionariais kintamaisiais įvertiniams.

$\mathbf{P}$  pažymėkime tokią  $(d+1) \times (d+2)$  matricą, kuri išrenka iš  $d+2$  ilgio vektoriaus pirmuosius  $d+1$  elementus:

$$\mathbf{P} := \begin{bmatrix} \mathbf{I}_{d+1} & \mathbf{0} \end{bmatrix}. \quad (\text{A.19})$$

Nesunku pastebėti, kad  $\mathbf{P}\mathbf{A}$  yra matrica, sudaryta iš pirmųjų  $d+1$  matricos  $\mathbf{A}$  eilučių. Kadangi  $\mathbf{f}(\hat{\gamma}) - \mathbf{f}(\gamma) = \mathbf{P}(\tilde{\mathbf{f}}(\hat{\psi}) - \tilde{\mathbf{f}}(\psi))$  ir  $\mathbf{f}(\gamma) = \beta_{0,d}$ , tai iš (A.18) turime:

$$\mathbf{f}(\hat{\gamma}) - \beta_{0,d} = \mathbf{P} \mathbf{D}_{\tilde{\mathbf{f}},\gamma+}(\mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{\mathbf{f}},\gamma+})^{-1} \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{u}. \quad (\text{A.20})$$

MKM įvertiniams  $\hat{\beta}_{0,d}$  panašią lygybę išsivesti paprasčiau:

$$\begin{aligned} \hat{\beta}_{0,d} &= \mathbf{P}\hat{\beta} = \mathbf{P}(\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{y} = \mathbf{P}\beta + \mathbf{P}(\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{u} \\ &= \beta_{0,d} + \mathbf{P}(\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{u}. \end{aligned} \quad (\text{A.21})$$

Skirtumas  $\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})$  iš (A.20) ir (A.21) gaunamas toks:

$$\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}) = \mathbf{P} \left[ (\mathbf{Z}'\mathbf{Z})^{-1} - \mathbf{D}_{\tilde{\mathbf{f}},\gamma+}(\mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{\mathbf{f}},\gamma+})^{-1} \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \right] \mathbf{Z}'\mathbf{u}. \quad (\text{A.22})$$

Reikia rasti  $\sqrt{n_d} \mathbf{F}'_V(\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))$  asimptotinę pasiskirstymą. Kadangi  $\sqrt{n_d} \mathbf{I}_{d+1} = \mathbf{P}\mathbf{L}$ , iš

(A.22) seka, kad

$$\sqrt{n_d} \mathbf{F}'_V (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})) = \mathbf{F}'_V \mathbf{P} \mathbf{B}_{\hat{\gamma}} \mathbf{L}^{-1} \mathbf{Z}' \mathbf{u}, \quad (\text{A.23})$$

$$\mathbf{B}_{\hat{\gamma}} := \mathbf{L} \left[ (\mathbf{Z}' \mathbf{Z})^{-1} - \mathbf{D}_{\tilde{f}, \gamma+} (\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{f}, \gamma+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \right] \mathbf{L}. \quad (\text{A.24})$$

Iš (A.23) matome, kad  $\sqrt{n_d} \mathbf{F}'_V (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))$  asimptotinio pasiskirstymo išvedimas susiveda į  $\mathbf{F}_V$ ,  $\mathbf{B}_{\hat{\gamma}}$  ir  $\mathbf{L}^{-1} \mathbf{Z}' \mathbf{u}$  asimptotinių pasiskirstymų arba ribų pagal tikimybę radimą.  $\mathbf{L}^{-1} \mathbf{Z}' \mathbf{u}$  ribą pagal pasiskirstymą jau radome (A.6).

Raskime  $\mathbf{B}_{\hat{\gamma}}$  asimptotinę elgesį. Apibrėžkime kitos dimensijos,  $(r+1) \times (r+1)$ , normavimo matricą  $\tilde{\mathbf{L}}$ :

$$\tilde{\mathbf{L}} := \begin{bmatrix} n_d^{1/2} \mathbf{I}_r & \mathbf{0} \\ \mathbf{0} & n_d \end{bmatrix}. \quad (\text{A.25})$$

Iš matricos  $\mathbf{D}_{\tilde{f}, \hat{\gamma}}$  apibrėžimo (2.21),  $\mathbf{D}_{\tilde{f}, \hat{\gamma}}$  yra blokinė-diagonalinė matrica, todėl galima pastebėti, kad galioja tokios lygybės:

$$\mathbf{L} \mathbf{D}_{\tilde{f}, \hat{\gamma}} = \mathbf{D}_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{L}}, \quad \mathbf{L}^{-1} \mathbf{D}_{\tilde{f}, \hat{\gamma}} = \mathbf{D}_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{L}}^{-1}, \quad (\text{A.26})$$

$$\tilde{\mathbf{L}} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} = \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L}, \quad \tilde{\mathbf{L}}^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} = \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L}^{-1}. \quad (\text{A.27})$$

Suprantama, tokios pačios lygybės galioja ir matricai  $\mathbf{D}_{\tilde{f}, \gamma+}$ . Remiantis tokiu matricų  $\mathbf{L}$  ir  $\tilde{\mathbf{L}}$  „perkėlimu“, gauname:

$$\begin{aligned} \mathbf{B}_{\hat{\gamma}} &= \mathbf{L} (\mathbf{Z}' \mathbf{Z})^{-1} \mathbf{L} - \mathbf{L} \mathbf{D}_{\tilde{f}, \gamma+} (\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{f}, \gamma+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L} \\ &= (\mathbf{L}^{-1} \mathbf{Z}' \mathbf{Z} \mathbf{L}^{-1})^{-1} - \mathbf{D}_{\tilde{f}, \gamma+} (\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L}^{-1} \mathbf{Z}' \mathbf{Z} \mathbf{L}^{-1} \mathbf{D}_{\tilde{f}, \gamma+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}}. \end{aligned} \quad (\text{A.28})$$

Kadangi  $\mathbf{V}' \mathbf{X} = \mathbf{O}_p(n_d)$  ir  $\mathbf{X}' \mathbf{X} = \mathbf{O}_p(n_d^2)$ , tai

$$\mathbf{L}^{-1} \mathbf{Z}' \mathbf{Z} \mathbf{L}^{-1} = \begin{bmatrix} n_d^{-1} \mathbf{V}' \mathbf{V} & n_d^{-3/2} \mathbf{V}' \mathbf{X} \\ n_d^{-3/2} \mathbf{X}' \mathbf{V} & n_d^{-2} \mathbf{X}' \mathbf{X} \end{bmatrix} \xrightarrow{d} \begin{bmatrix} \mathbf{Q} & \mathbf{0} \\ \mathbf{0} & \text{dlim}(n_d^{-2} \mathbf{X}' \mathbf{X}) \end{bmatrix}. \quad (\text{A.29})$$

Pasinaudojus  $\mathbf{D}_{\tilde{f}, \hat{\gamma}}$  blokiniu išskaidymu (2.21) lygybėje, matricą  $\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L}^{-1} \mathbf{Z}' \mathbf{Z} \mathbf{L}^{-1} \mathbf{D}_{\tilde{f}, \gamma+}$  galima išskaidyti taip:

$$\begin{aligned} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L}^{-1} \mathbf{Z}' \mathbf{Z} \mathbf{L}^{-1} \mathbf{D}_{\tilde{f}, \gamma+} &= \begin{bmatrix} n_d^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{V}' \mathbf{V} \mathbf{D}_{\tilde{f}, \gamma+} & n_d^{-3/2} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{V}' \mathbf{X} \\ n_d^{-3/2} \mathbf{X}' \mathbf{V} \mathbf{D}_{\tilde{f}, \gamma+} & n_d^{-2} \mathbf{X}' \mathbf{X} \end{bmatrix} \\ &\xrightarrow{d} \begin{bmatrix} \mathbf{D}'_{\tilde{f}, \gamma} \mathbf{Q} \mathbf{D}_{\tilde{f}, \gamma} & \mathbf{0} \\ \mathbf{0} & \text{dlim}(n_d^{-2} \mathbf{X}' \mathbf{X}) \end{bmatrix}. \end{aligned} \quad (\text{A.30})$$

Čia riba pagal pasiskirtymą gauta pasinaudojus Jakobiano  $\mathbf{D}_{\tilde{f}, \gamma}$  tolydumu ir tuom, kad  $\hat{\gamma} \xrightarrow{p} \gamma$  ir  $\gamma+ \xrightarrow{p} \gamma$ . Dar kartą pasinaudojus  $\mathbf{D}_{\tilde{f}, \hat{\gamma}}$  blokiniu išskaidymu (2.21), blokinės

diagonalinės matricos atvirkštinės matricos skaičiavimo taisykle<sup>19</sup>, iš (A.28), (A.29) ir (A.30) gauname:

$$\mathbf{B}_{\hat{\gamma}} \xrightarrow{p} \begin{bmatrix} \mathbf{Q}^{-1} - \mathbf{D}_{f,\gamma} (\mathbf{D}'_{f,\gamma} \mathbf{Q} \mathbf{D}_{f,\gamma})^{-1} \mathbf{D}'_{f,\gamma} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}, \quad (\text{A.31})$$

kur (A.31) matricos apatinis dešinys elementas lygus nuliui, dėl to, kad tai pačiai realizacijai  $\{n_d^{-2} \mathbf{X}' \mathbf{X}\}_{n_d=1}^{\infty}$  galioja:

$$\left( \text{dlim} (n_d^{-2} \mathbf{X}' \mathbf{X}) \right)^{-1} - \left( \text{dlim} (n_d^{-2} \mathbf{X}' \mathbf{X}) \right)^{-1} = 0.$$

(A.31) nuo ribos pagal pasiskirstymą pereita prie ribos pagal tikimybę remiantis tuom, kad pagal [11] teiginį C.1 (p. 683), konvergavimas pagal pasiskirstymą į neatsitiktinį dydį ekvivalentus konvergavimui pagal tikimybę.

Raskime  $\mathbf{F}_V$  ribą pagal tikimybę. Kadangi matrica  $\mathbf{Q}$  yra teigiamai apibrėžta, tai jai galima taikyti Cholesky dekompoziciją:  $\mathbf{Q} = \mathbf{F} \mathbf{F}'$ . Kadangi  $\mathbf{Q} = \text{plim} (n_d^{-1} \mathbf{V}' \mathbf{V})$ , iš [13] lemos 12.1.6 (p. 295)<sup>20</sup>, remiantis tolydaus atvaizdžio teorema,

$$\mathbf{F}_V \xrightarrow{p} \mathbf{F}. \quad (\text{A.32})$$

Gautas  $\mathbf{F}_V$ ,  $\mathbf{B}_{\hat{\gamma}}$  ir  $\mathbf{L}^{-1} \mathbf{Z}' \mathbf{u}$  asimptotinis elgesys, galima pereiti prie  $\sqrt{n_d} \mathbf{F}'_V (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))$  asimptotinio pasiskirstymo išvedimo. Iš (A.6), (A.23), (A.31) ir (A.32) gauname:

$$\begin{aligned} \sqrt{n_d} \mathbf{F}'_V (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})) &\xrightarrow{d} \mathbf{F}' \mathbf{P} \begin{bmatrix} \mathbf{Q}^{-1} - \mathbf{D}_{f,\gamma} (\mathbf{D}'_{f,\gamma} \mathbf{Q} \mathbf{D}_{f,\gamma})^{-1} \mathbf{D}'_{f,\gamma} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} N(\mathbf{0}, \sigma_u^2 \mathbf{Q}) \\ O_p(1) \end{bmatrix} \\ &= \mathbf{F}' \left( \mathbf{Q}^{-1} - \mathbf{D}_{f,\gamma} (\mathbf{D}'_{f,\gamma} \mathbf{Q} \mathbf{D}_{f,\gamma})^{-1} \mathbf{D}'_{f,\gamma} \right) N(\mathbf{0}, \sigma_u^2 \mathbf{Q}). \end{aligned}$$

Taigi

$$\sqrt{n_d} \mathbf{F}'_V (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})) \xrightarrow{d} N(\sigma_u^2 \Sigma_{h_1}),$$

kur, pasinaudodami tuom, kad  $\mathbf{Q} = \mathbf{F} \mathbf{F}'$  ir  $\mathbf{Q}^{-1} = \mathbf{F}'^{-1} \mathbf{F}^{-1}$ , turime:

$$\begin{aligned} \Sigma_{h_1} &= \mathbf{F}' \left( \mathbf{Q}^{-1} - \mathbf{D}_{f,\gamma} (\mathbf{D}'_{f,\gamma} \mathbf{Q} \mathbf{D}_{f,\gamma})^{-1} \mathbf{D}'_{f,\gamma} \right) \mathbf{Q} \left( \mathbf{Q}^{-1} - \mathbf{D}_{f,\gamma} (\mathbf{D}'_{f,\gamma} \mathbf{Q} \mathbf{D}_{f,\gamma})^{-1} \mathbf{D}'_{f,\gamma} \right)' \mathbf{F} \\ &= \mathbf{F}' \mathbf{F}'^{-1} \mathbf{F}^{-1} \mathbf{F} - 2 \mathbf{F}' \mathbf{D}_{f,\gamma} (\mathbf{D}'_{f,\gamma} \mathbf{Q} \mathbf{D}_{f,\gamma})^{-1} \mathbf{D}'_{f,\gamma} \mathbf{F} + \\ &\quad + \mathbf{F}' \mathbf{D}_{f,\gamma} (\mathbf{D}'_{f,\gamma} \mathbf{F} \mathbf{F}' \mathbf{D}_{f,\gamma})^{-1} \mathbf{D}'_{f,\gamma} \mathbf{F} \mathbf{F}' \mathbf{D}_{f,\gamma} (\mathbf{D}'_{f,\gamma} \mathbf{F} \mathbf{F}' \mathbf{D}_{f,\gamma})^{-1} \mathbf{D}'_{f,\gamma} \mathbf{F} \\ &= \mathbf{I}_{d+1} - \mathbf{F}' \mathbf{D}_{f,\gamma} (\mathbf{D}'_{f,\gamma} \mathbf{Q} \mathbf{D}_{f,\gamma})^{-1} \mathbf{D}'_{f,\gamma} \mathbf{F}. \end{aligned} \quad (\text{A.33})$$

Dabar reikia parodyti, kad  $\hat{\sigma}_u^2 \xrightarrow{p} \sigma_u^2$ . Parodžius, kad MKM įvertiniai  $\hat{\mathbf{\Gamma}}$  yra suderinti,

<sup>19</sup>

$$\left( \begin{bmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0} & \mathbf{B} \end{bmatrix} \right)^{-1} = \begin{bmatrix} \mathbf{A}^{-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{B}^{-1} \end{bmatrix}.$$

<sup>20</sup>Cholesky dekompozicija yra tolydi funkcija iš simetrinių teigiamai apibrėžtų matricių aibės į trikampių matricių su teigiamais diagonalės elementais aibę.

galima pasinaudoti [7] skyrelyje 8.2 esančiu įrodymu.  $\hat{\Gamma}$  yra suderinti, nes  $\mathbf{L}(\hat{\Gamma} - \Gamma) = (\mathbf{L}^{-1}\mathbf{Z}'\mathbf{Z}\mathbf{L}^{-1})^{-1}\mathbf{L}^{-1}\mathbf{Z}'\mathbf{u} = \mathbf{O}_p(1)$ , taigi  $(\hat{\Gamma} - \Gamma) \xrightarrow{p} \mathbf{0}$ . Taigi  $\hat{\sigma}_u^2 \xrightarrow{p} \sigma_u^2$ , todėl

$$\mathbf{h}_1 = \frac{\sqrt{n_d}}{\hat{\sigma}_u} \mathbf{F}'_V (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})) \xrightarrow{d} N(\mathbf{0}, \Sigma_{h_1}). \quad (\text{A.34})$$

Raskime  $\Sigma_{h_1}$  rangą. Iš (A.33) matyti, kad  $\mathbf{F}'\mathbf{D}_{f,\gamma}(\mathbf{D}'_{f,\gamma}\mathbf{Q}\mathbf{D}_{f,\gamma})^{-1}\mathbf{D}'_{f,\gamma}\mathbf{F}$  yra idempotentinė. Kadangi  $\mathbf{F}$  ir  $\mathbf{Q}$  yra pilno rango, o  $\text{rank}(\mathbf{D}_{f,\gamma}) = r$ , kur  $r$  yra matricos  $\mathbf{D}_{f,\gamma}$  stulpelių skaičius, tai remiantis [10] matricų sandaugos rangų taisyklėmis:

$$\text{rank}(\mathbf{F}'\mathbf{D}_{f,\gamma}(\mathbf{D}'_{f,\gamma}\mathbf{Q}\mathbf{D}_{f,\gamma})^{-1}\mathbf{D}'_{f,\gamma}\mathbf{F}) = r.$$

Remiantis [10] taisykle 17c (sk. 4.3.1, p. 59)<sup>21</sup>,

$$\text{rank}(\Sigma_{h_1}) = d + 1 - r.$$

Kadangi  $\mathbf{F}'\mathbf{D}_{f,\gamma}(\mathbf{D}'_{f,\gamma}\mathbf{Q}\mathbf{D}_{f,\gamma})^{-1}\mathbf{D}'_{f,\gamma}\mathbf{F}$  yra idempotentinė, tai ir  $\Sigma_{h_1}$  yra idempotentinė.

Iš  $\hat{\Sigma}_{h_1}$  apibrėžimo (2.27) turime:

$$\begin{aligned} \hat{\Sigma}_{h_1} &= \mathbf{I}_{d+1} - \mathbf{F}'_V \mathbf{D}_{f,\hat{\gamma}} (\mathbf{D}'_{f,\hat{\gamma}} n_d^{-1} \mathbf{V}' \mathbf{V} \mathbf{D}_{f,\hat{\gamma}})^{-1} \mathbf{D}'_{f,\hat{\gamma}} \mathbf{F}_V \\ &= \mathbf{I}_{d+1} - \mathbf{F}'_V \mathbf{D}_{f,\hat{\gamma}} (\mathbf{D}'_{f,\hat{\gamma}} \mathbf{F}_V \mathbf{F}'_V \mathbf{D}_{f,\hat{\gamma}})^{-1} \mathbf{D}'_{f,\hat{\gamma}} \mathbf{F}_V. \end{aligned}$$

Taigi  $\hat{\Sigma}_{h_1}$  taip pat yra idempotentinė ir  $\text{rank}(\hat{\Sigma}_{h_1}) = d + 1 - r$ . Be to, kadangi  $\mathbf{F}_V \xrightarrow{p} \mathbf{F}$  ir  $\mathbf{D}_{f,\hat{\gamma}} \xrightarrow{p} \mathbf{D}_{f,\gamma}$ , remiantis tolydaus atvaizdžio teorema,  $\hat{\Sigma}_{h_1} \xrightarrow{p} \Sigma_{h_1}$ . Remiantis [10] taisykle 3b (sk. 9.8, p. 138), simetrinės ir idempotentinės matricos apibendrinta atvirkštinė matrica lygi jai pačiai. Galima pasiremti [2] teorema 1, iš kur ir gauname, kad

$$T_1 = \mathbf{h}'_1 \hat{\Sigma}_{h_1} \mathbf{h}_1 \xrightarrow{d} \chi^2(d + 1 - r).$$

## $\tilde{H}_1$ atvejis

Likusioje įrodymo dalyje tarkime, kad  $\tilde{H}_0$  negalioja. Tada  $\beta_{0,d} - \mathbf{f}(\gamma) \neq \mathbf{0}$ ,  $\forall \gamma \in \Lambda$ . Nagrinėkime atsitiktinį dydį  $\hat{\sigma}_u^2 n_d^{-1} T_1$ .

$$\hat{\sigma}_u^2 n_d^{-1} T_1 = \hat{\sigma}_u n_d^{-1/2} \mathbf{h}'_1 \hat{\Sigma}_{h_1} \mathbf{h}_1 \hat{\sigma}_u n_d^{-1/2} = (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))' \mathbf{F}_V \hat{\Sigma}_{h_1} \mathbf{F}'_V (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})). \quad (\text{A.35})$$

Parodysime, kad  $\hat{\sigma}_u^2 n_d^{-1} T_1$  pagal tikimybę artėja į teigiamą skaičių.

Panašiai kaip ir  $\tilde{H}_0$  atveju išsireikšime atsitiktinį vektorių  $(\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))$  per modelio kintamuosius. Pažymėkime  $\gamma_0 := \text{plim}(\hat{\gamma})$ . Remiantis prielaida P3,  $\gamma_0$  egzistuoja. Šiuo

<sup>21</sup> Jei  $\mathbf{A}$  yra idempotentinė ir  $\text{rank}(\mathbf{A}) = r$ , tai  $\text{rank}(\mathbf{I}_{d+1} - \mathbf{A}) = d + 1 - r$ .



atveju nagrinėjamą modelį galima užrašyti taip:

$$\begin{aligned}\mathbf{y} &= \mathbf{V} \mathbf{f}(\gamma_0) + \mathbf{X} \beta_d + \mathbf{e}, \\ \mathbf{e} &:= \mathbf{u} + \mathbf{V}(\beta_{0,d} - \mathbf{f}(\gamma_0)).\end{aligned}$$

Naudojantis [8] pavyzdžiu, pagal tikslią Teiloro eilutės pirmos eilės aproksimaciją taške  $\gamma_0$ :

$$\mathbf{f}(\hat{\gamma}) = \mathbf{f}(\gamma_0) + \mathbf{D}_{\mathbf{f},\gamma_+}(\hat{\gamma} - \gamma_0). \quad (\text{A.36})$$

Kadangi  $\tilde{H}_1$  atveju tikro parametrų vektoriaus nėra, imkime  $\boldsymbol{\psi} := (\gamma'_0, \beta_d)'$ . Tada iš (A.36) seka:

$$\tilde{\mathbf{f}}(\hat{\boldsymbol{\psi}}) - \tilde{\mathbf{f}}(\boldsymbol{\psi}) = \mathbf{D}_{\tilde{\mathbf{f}},\gamma_+}(\hat{\boldsymbol{\psi}} - \boldsymbol{\psi}). \quad (\text{A.37})$$

Lygybės (A.37) paskutinė eilutė yra tiesiog  $\hat{\beta}_d - \beta_d = \hat{\beta}_d - \beta_d$ . Tuomet įvertinių  $\hat{\boldsymbol{\psi}}$  būtinoji sąlyga yra:

$$\begin{aligned}\mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}'(\mathbf{y} - \mathbf{Z} \tilde{\mathbf{f}}(\hat{\boldsymbol{\psi}})) &= \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}'(\mathbf{Z} \tilde{\mathbf{f}}(\boldsymbol{\psi}) + \mathbf{e} - \mathbf{Z} \tilde{\mathbf{f}}(\hat{\boldsymbol{\psi}})) \\ &= \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{\mathbf{f}},\gamma_+}(\boldsymbol{\psi} - \hat{\boldsymbol{\psi}}) + \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{e} = \mathbf{0}.\end{aligned} \quad (\text{A.38})$$

Iš (A.37) ir (A.38) gauname:

$$\begin{aligned}\tilde{\mathbf{f}}(\hat{\boldsymbol{\psi}}) - \tilde{\mathbf{f}}(\boldsymbol{\psi}) &= \mathbf{D}_{\tilde{\mathbf{f}},\gamma_+}(\mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{\mathbf{f}},\gamma_+})^{-1} \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{e} \\ &= \mathbf{D}_{\tilde{\mathbf{f}},\gamma_+}(\mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{\mathbf{f}},\gamma_+})^{-1} \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{V}(\beta_{0,d} - \mathbf{f}(\gamma_0)) + \\ &+ \mathbf{D}_{\tilde{\mathbf{f}},\gamma_+}(\mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{\mathbf{f}},\gamma_+})^{-1} \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{u}.\end{aligned} \quad (\text{A.39})$$

Pažymėkime

$$\Delta_{\tilde{\mathbf{f}},\hat{\gamma}} := \mathbf{D}_{\tilde{\mathbf{f}},\gamma_+}(\mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{\mathbf{f}},\gamma_+})^{-1} \mathbf{D}'_{\tilde{\mathbf{f}},\hat{\gamma}}.$$

Kadangi  $\mathbf{f}(\hat{\gamma}) - \mathbf{f}(\gamma_0) = \mathbf{P}(\tilde{\mathbf{f}}(\hat{\boldsymbol{\psi}}) - \tilde{\mathbf{f}}(\boldsymbol{\psi}))$ , tai iš (A.39):

$$\mathbf{f}(\hat{\gamma}) - \mathbf{f}(\gamma_0) = \mathbf{P} \Delta_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{V}(\beta_{0,d} - \mathbf{f}(\gamma_0)) + \mathbf{P} \Delta_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{u}. \quad (\text{A.40})$$

MKM įvertiniams  $\hat{\beta}_{0,d}$  lieka galioti (A.21):

$$\hat{\beta}_{0,d} = \beta_{0,d} + \mathbf{P}(\mathbf{Z}' \mathbf{Z})^{-1} \mathbf{Z}' \mathbf{u}. \quad (\text{A.41})$$

Taigi iš (A.40) ir (A.41) gauname tokią  $\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})$  išraišką:

$$\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}) = [\mathbf{I}_{d+1} + \mathbf{P} \Delta_{\tilde{\mathbf{f}},\hat{\gamma}} \mathbf{Z}' \mathbf{V}] (\beta_{0,d} - \mathbf{f}(\gamma_0)) + \mathbf{P}[(\mathbf{Z}' \mathbf{Z})^{-1} - \Delta_{\tilde{\mathbf{f}},\hat{\gamma}}] \mathbf{Z}' \mathbf{u}. \quad (\text{A.42})$$

Pastebėjus, kad  $\mathbf{u}' \mathbf{Z}((\mathbf{Z}' \mathbf{Z})^{-1} - \Delta'_{\tilde{\mathbf{f}},\hat{\gamma}}) \mathbf{P}' = \mathbf{u}' \mathbf{Z} \mathbf{L}^{-1} \mathbf{B}'_{\hat{\gamma}} \mathbf{L}^{-1} \mathbf{P}'$  ir  $\mathbf{L}^{-1} \mathbf{P}' = \mathbf{I}_{d+1} n_d^{-1/2}$ , išraiška

(A.35) tampa tokia:

$$\begin{aligned} \hat{\sigma}_u^2 n_d^{-1} T_1 = & \left[ (\beta_{0,d} - \mathbf{f}(\gamma_0))' (\mathbf{I}_{d+1} - \mathbf{V}' \mathbf{Z} \Delta'_{\tilde{f}, \hat{\gamma}} \mathbf{P}') + \mathbf{u}' \mathbf{Z} n_d^{-1/2} \mathbf{L}^{-1} \mathbf{B}'_{\hat{\gamma}} \mathbf{P}' \right] \times \\ & \times \mathbf{F}_V \hat{\Sigma}_{h_1} \mathbf{F}_V' \left[ \mathbf{P} \mathbf{B}_{\hat{\gamma}} n_d^{-1/2} \mathbf{L}^{-1} \mathbf{Z}' \mathbf{u} + (\mathbf{I}_{d+1} - \mathbf{P} \Delta_{\tilde{f}, \hat{\gamma}} \mathbf{Z}' \mathbf{V}) (\beta_{0,d} - \mathbf{f}(\gamma_0)) \right]. \end{aligned} \quad (\text{A.43})$$

Ieškokime  $\hat{\sigma}_u^2 n_d^{-1} T_1$  ribos pagal tikimybę. Kadangi  $\mathbf{B}_{\hat{\gamma}} = \mathbf{O}_p(1)$ ,  $n_d^{-1/2} \mathbf{L}^{-1} \mathbf{Z}' \mathbf{u} = \mathbf{O}_p(n_d^{-1/2})$ , ir, kaip vėliau bus parodyta,  $\mathbf{V}' \mathbf{Z} \Delta'_{\tilde{f}, \hat{\gamma}} = \mathbf{O}_p(1)$ , tai (A.43) susiprastina:

$$\begin{aligned} \hat{\sigma}_u^2 n_d^{-1} T_1 = & (\beta_{0,d} - \mathbf{f}(\gamma_0))' (\mathbf{I}_{d+1} - \mathbf{V}' \mathbf{Z} \Delta'_{\tilde{f}, \hat{\gamma}} \mathbf{P}') \mathbf{F}_V \hat{\Sigma}_{h_1} \mathbf{F}_V' \times \\ & \times (\mathbf{I}_{d+1} - \mathbf{P} \Delta_{\tilde{f}, \hat{\gamma}} \mathbf{Z}' \mathbf{V}) (\beta_{0,d} - \mathbf{f}(\gamma_0)) + \mathbf{O}_p(n_d^{-1/2}) + \mathbf{O}_p(n_d^{-1}). \end{aligned} \quad (\text{A.44})$$

Raskime  $\mathbf{P} \Delta_{\tilde{f}, \hat{\gamma}} \mathbf{Z}' \mathbf{V}$  ribą pagal tikimybę.

$$\begin{aligned} \mathbf{P} \Delta_{\tilde{f}, \hat{\gamma}} \mathbf{Z}' \mathbf{V} = & \mathbf{P} \mathbf{L}^{-1} \mathbf{L} \mathbf{D}_{\tilde{f}, \gamma_+} (\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{Z}' \mathbf{Z} \mathbf{D}_{\tilde{f}, \gamma_+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L} \mathbf{L}^{-1} \mathbf{Z}' \mathbf{V} \\ = & \mathbf{P} \mathbf{D}_{\tilde{f}, \gamma_+} (\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L}^{-1} \mathbf{Z}' \mathbf{Z} \mathbf{L}^{-1} \mathbf{D}_{\tilde{f}, \gamma_+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} n_d^{-1/2} \mathbf{L}^{-1} \mathbf{Z}' \mathbf{V}. \end{aligned} \quad (\text{A.45})$$

Kadangi  $\hat{\gamma} \xrightarrow{p} \gamma_0$  ir  $\gamma_+ \xrightarrow{p} \gamma_0$ , iš (A.30) ir  $\mathbf{P}$  apibrėžimo (A.19) turime:

$$\mathbf{P} \mathbf{D}_{\tilde{f}, \gamma_+} (\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L}^{-1} \mathbf{Z}' \mathbf{Z} \mathbf{L}^{-1} \mathbf{D}_{\tilde{f}, \gamma_+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \xrightarrow{p} \left[ \mathbf{D}_{f, \gamma_0} (\mathbf{D}'_{f, \gamma_0} \mathbf{Q} \mathbf{D}_{f, \gamma_0})^{-1} \mathbf{D}'_{f, \gamma_0}, \mathbf{0} \right]. \quad (\text{A.46})$$

Kadangi  $\mathbf{X}' \mathbf{V} = \mathbf{O}_p(n_d)$ , tai

$$n_d^{-1/2} \mathbf{L}^{-1} \mathbf{Z}' \mathbf{V} = \begin{bmatrix} n_d^{-1} \mathbf{V}' \mathbf{V} \\ n_d^{-3/2} \mathbf{X}' \mathbf{V} \end{bmatrix} \xrightarrow{p} \begin{bmatrix} \mathbf{Q} \\ \mathbf{0} \end{bmatrix}. \quad (\text{A.47})$$

Taigi iš (A.45), (A.46) ir (A.47) gauname:

$$\mathbf{P} \Delta_{\tilde{f}, \hat{\gamma}} \mathbf{Z}' \mathbf{V} \xrightarrow{p} \mathbf{D}_{f, \gamma_0} (\mathbf{D}'_{f, \gamma_0} \mathbf{Q} \mathbf{D}_{f, \gamma_0})^{-1} \mathbf{D}'_{f, \gamma_0} \mathbf{Q} = \Delta \mathbf{Q} \quad (\text{A.48})$$

kur  $\Delta := \mathbf{D}_{f, \gamma_0} (\mathbf{D}'_{f, \gamma_0} \mathbf{Q} \mathbf{D}_{f, \gamma_0})^{-1} \mathbf{D}'_{f, \gamma_0}$ . Pažymėkime  $\mathbf{A} := \mathbf{F}' \Delta \mathbf{F}$ . Turime  $\hat{\Sigma}_{h_1} \xrightarrow{p} \mathbf{I}_{d+1} - \mathbf{A}$ . Pastebėkime, kad matrica  $\mathbf{A}$  yra idempotentinė ir simetrinė. Imkime kvadratinėje formoje (A.44) esančią matricą. Jos ribą pagal tikimybę galima suprastinti:

$$\begin{aligned} & (\mathbf{I}_{d+1} - \mathbf{V}' \mathbf{Z} \Delta'_{\tilde{f}, \hat{\gamma}} \mathbf{P}') \mathbf{F}_V \hat{\Sigma}_{h_1} \mathbf{F}_V' (\mathbf{I}_{d+1} - \mathbf{P} \Delta_{\tilde{f}, \hat{\gamma}} \mathbf{Z}' \mathbf{V}) \xrightarrow{p} \\ & \xrightarrow{p} (\mathbf{I}_{d+1} - \mathbf{Q} \Delta) \mathbf{F} (\mathbf{I}_{d+1} - \mathbf{A}) \mathbf{F}' (\mathbf{I}_{d+1} - \Delta \mathbf{Q}) \\ & = (\mathbf{F} - \mathbf{F} \mathbf{F}' \Delta \mathbf{F}) (\mathbf{I}_{d+1} - \mathbf{A}) (\mathbf{F}' - \mathbf{F}' \Delta \mathbf{F} \mathbf{F}') \\ & = \mathbf{F} (\mathbf{I}_{d+1} - \mathbf{A}) (\mathbf{I}_{d+1} - \mathbf{A}) (\mathbf{I}_{d+1} - \mathbf{A}) \mathbf{F}' \\ & = \mathbf{F} (\mathbf{I}_{d+1} - \mathbf{A}) \mathbf{F}' = \mathbf{Q} - \mathbf{Q} \Delta \mathbf{Q}. \end{aligned} \quad (\text{A.49})$$

Taigi, iš (A.44) ir (A.49) turime:

$$\hat{\sigma}_u^2 n_d^{-1} T_1 \xrightarrow{p} (\beta_{0,d} - \mathbf{f}(\gamma_0))' (\mathbf{Q} - \mathbf{Q} \Delta \mathbf{Q}) (\beta_{0,d} - \mathbf{f}(\gamma_0)). \quad (\text{A.50})$$

Kadangi  $\mathbf{Q}$  yra teigiamai apibrėžta, tai  $(\beta_{0,d} - \mathbf{f}(\gamma_0))' \mathbf{Q} (\beta_{0,d} - \mathbf{f}(\gamma_0)) > 0$ . Toliau parodysimė, kad  $(\beta_{0,d} - \mathbf{f}(\gamma_0))' \mathbf{Q} \Delta \mathbf{Q} (\beta_{0,d} - \mathbf{f}(\gamma_0)) = 0$ .

Iš NMKM įvertinių būtinosios sąlygos (2.23) paskutinės eilutės turime:

$$\mathbf{X}'(\mathbf{y} - \mathbf{V}\mathbf{f}(\hat{\gamma}) - \mathbf{X}\hat{\beta}_d^{nls}) = 0. \quad (\text{A.51})$$

Kadangi  $\mathbf{y} = \mathbf{V}\beta_{0,d} + \mathbf{X}\beta_d + \mathbf{u}$ , tai lygybę (A.51) padauginę iš  $n_d^{-2}$ , gauname:

$$n_d^{-2} \mathbf{X}' \mathbf{X} (\beta_d - \hat{\beta}_d^{nls}) = n_d^{-2} \mathbf{X}' \mathbf{V} (\mathbf{f}(\hat{\gamma}) - \beta_{0,d}) - n_d^{-2} \mathbf{X}' \mathbf{u}. \quad (\text{A.52})$$

Dešinioji (A.52) lygybės pusė pagal tikimybę artėja į nulį. Kadangi  $n_d^{-2} \mathbf{X}' \mathbf{X} \neq o_p(1)$ , tai, kad (A.52) galiotų ir riboje, būtina, kad  $\hat{\beta}_d^{nls} \xrightarrow{p} \beta_d$ . Taigi  $\hat{\beta}_d^{nls}$  yra suderintas net ir esant neteisingai apribojimo funkcijai. Iš NMKM įvertinių būtinosios sąlygos (2.23) pirmųjų  $d+1$  eilučių turime:

$$n_d^{-1} \mathbf{D}'_{f,\hat{\gamma}} \mathbf{V}' (\mathbf{y} - \mathbf{V}\mathbf{f}(\hat{\gamma}) - \mathbf{X}\hat{\beta}_d^{nls}) = 0. \quad (\text{A.53})$$

Įsistatę į (A.53) išraišką  $\mathbf{y} = \mathbf{V}\beta_{0,d} + \mathbf{X}\beta_d + \mathbf{u}$ , gauname:

$$n_d^{-1} \mathbf{D}'_{f,\hat{\gamma}} \mathbf{V}' \mathbf{V} (\beta_{0,d} - \mathbf{f}(\hat{\gamma})) = n_d^{-1} \mathbf{D}'_{f,\hat{\gamma}} \mathbf{V}' \mathbf{X} (\hat{\beta}_d^{nls} - \beta_d) - n_d^{-1} \mathbf{D}'_{f,\hat{\gamma}} \mathbf{V}' \mathbf{u}. \quad (\text{A.54})$$

Dešinioji (A.54) lygybės pusė artėja į nulį, nes  $\hat{\beta}_d^{nls} \xrightarrow{p} \beta_d$ ,  $\mathbf{V}' \mathbf{X} = \mathbf{O}_p(n_d)$  ir  $\mathbf{V}' \mathbf{u} = \mathbf{O}_p(n_d)$ . Kadangi  $\hat{\gamma} \xrightarrow{p} \gamma_0$  ir  $n_d^{-1} \mathbf{V}' \mathbf{V} \xrightarrow{p} \mathbf{Q}$ , tai (A.54) lygybė riboje pagal tikimybę yra:

$$\mathbf{D}'_{f,\gamma_0} \mathbf{Q} (\beta_{0,d} - \mathbf{f}(\gamma_0)) = 0. \quad (\text{A.55})$$

Vadinasi,  $\hat{\gamma}$  artėja į tokį parametrų vektorių  $\gamma_0$ , kuriam tenkinama (A.55). Iš (A.55) gauname, kad

$$\begin{aligned} & (\beta_{0,d} - \mathbf{f}(\gamma_0))' \mathbf{Q} \Delta \mathbf{Q} (\beta_{0,d} - \mathbf{f}(\gamma_0)) = \\ & = (\beta_{0,d} - \mathbf{f}(\gamma_0))' \mathbf{Q} \mathbf{D}_{f,\gamma_0} (\mathbf{D}'_{f,\gamma_0} \mathbf{Q} \mathbf{D}_{f,\gamma_0})^{-1} \mathbf{D}'_{f,\gamma_0} \mathbf{Q} (\beta_{0,d} - \mathbf{f}(\gamma_0)) = 0. \end{aligned}$$

Taigi<sup>22</sup> iš (A.50),  $\hat{\sigma}_u^2 n_d^{-1} T_1 \xrightarrow{p} (\beta_{0,d} - \mathbf{f}(\gamma_0))' \mathbf{Q} (\beta_{0,d} - \mathbf{f}(\gamma_0)) > 0$ . Todėl  $T_1 \xrightarrow{p} \infty$ , kai  $n_d \rightarrow \infty$ . □

## B Teiginio 2.3 įrodymas

### $\tilde{H}_0$ atvejis

Tegu galioja  $\tilde{H}_0$ . Reikia parodyti, kad  $\mathbf{h}_2$  asimptotiškai pasiskirstęs pagal normalųjį dėsnį, rasti asimptotinę  $\mathbf{h}_2$  kovariacijų matricą  $\Sigma_{\mathbf{h}_2}$  ir parodyti, kad  $\hat{\Sigma}_{\mathbf{h}_2} \xrightarrow{p} \Sigma_{\mathbf{h}_2}$ . Įrodžius,

---

<sup>22</sup> Šį rezultatą galima gauti ir kitu būdu. Kadangi  $\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}) \xrightarrow{p} \beta_{0,d} - \mathbf{f}(\gamma_0)$ , tai, perėjus prie ribos (A.44) abejose pusėse, būtina, kad  $\mathbf{P} \Delta_{\hat{f},\hat{\gamma}} \mathbf{Z}' \mathbf{V} (\beta_{0,d} - \mathbf{f}(\gamma_0)) \xrightarrow{p} \mathbf{0}$ . Tada iš (A.48),  $\Delta \mathbf{Q} (\beta_{0,d} - \mathbf{f}(\gamma_0)) = \mathbf{0}$ . Tokiu būdu nereikia naudotis NMKM įvertinių būtinaja sąlyga.

kad  $\text{rank}(\hat{\Sigma}_{h_2}) = \text{rank}(\Sigma_{h_2}) = d + 1 - r$ , galima pasiremti [2] teorema 1.

Pagal Cholesky dekompoziciją, tegu matrica  $\mathbf{F}$  yra tokia, kad  $\mathbf{F}\mathbf{F}' = \mathbf{Q}$ . Priede A pagrįsta, kad  $\mathbf{F}_V \xrightarrow{p} \mathbf{F}$  ir  $n_d^{-1}\mathbf{V}'\mathbf{V} \xrightarrow{p} \mathbf{Q}$ . Kadangi  $\mathbf{h}_2 = \mathbf{F}_V^{-1}\mathbf{h}_1$ , tai iš (A.34) ir tolydaus atvaizdžio teoremos gauname:

$$\mathbf{h}_2 \xrightarrow{d} N(\mathbf{0}, \mathbf{F}'^{-1}\Sigma_{h_1}\mathbf{F}^{-1}), \text{ kur} \\ \Sigma_{h_1} = \mathbf{I}_{d+1} - \mathbf{F}'\mathbf{D}_{f,\gamma}(\mathbf{D}'_{f,\gamma}\mathbf{Q}\mathbf{D}_{f,\gamma})^{-1}\mathbf{D}'_{f,\gamma}\mathbf{F}.$$

Čia  $\gamma$  yra toks, kad  $\beta_{0,d} = \mathbf{f}(\gamma)$ . Pažymėkime  $\Sigma_{h_2} := \mathbf{F}'^{-1}\Sigma_{h_1}\mathbf{F}^{-1}$ . Iš  $\Sigma_{h_1}$  išraiškos turime:

$$\Sigma_{h_2} = \mathbf{F}'^{-1}\mathbf{F}^{-1} - \mathbf{F}'^{-1}\mathbf{F}'\mathbf{D}_{f,\gamma}(\mathbf{D}'_{f,\gamma}\mathbf{Q}\mathbf{D}_{f,\gamma})^{-1}\mathbf{D}'_{f,\gamma}\mathbf{F}\mathbf{F}^{-1} \\ = \mathbf{Q}^{-1} - \mathbf{D}_{f,\gamma}(\mathbf{D}'_{f,\gamma}\mathbf{Q}\mathbf{D}_{f,\gamma})^{-1}\mathbf{D}'_{f,\gamma}. \quad (\text{B.1})$$

Parodykime, kad  $\hat{\Sigma}_{h_2} \xrightarrow{p} \Sigma_{h_2}$ . Matrica  $\mathbf{P}\mathbf{L}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{L}\mathbf{P}'$  yra pirmieji  $d + 1$  matricos  $\mathbf{L}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{L}$  eilutės ir stulpeliai. Iš (A.29) turime:

$$\mathbf{P}\mathbf{L}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{L}\mathbf{P}' \xrightarrow{p} \mathbf{Q}^{-1}.$$

Iš (A.30) ir  $\mathbf{D}_{\tilde{f},\tilde{\gamma}}$  apibrėžimo (2.21) turime:

$$\mathbf{P}\mathbf{L}\Delta_{\tilde{f},\tilde{\gamma}}\mathbf{L}\mathbf{P}' = \mathbf{P}\mathbf{D}_{\tilde{f},\tilde{\gamma}}(\mathbf{D}'_{\tilde{f},\tilde{\gamma}}\mathbf{L}^{-1}\mathbf{Z}'\mathbf{Z}\mathbf{L}^{-1}\mathbf{D}_{\tilde{f},\tilde{\gamma}})^{-1}\mathbf{D}'_{\tilde{f},\tilde{\gamma}}\mathbf{P}' \xrightarrow{p} \mathbf{D}_{f,\gamma}(\mathbf{D}'_{f,\gamma}\mathbf{Q}\mathbf{D}_{f,\gamma})^{-1}\mathbf{D}'_{f,\gamma}.$$

Taigi  $\hat{\Sigma}_{h_2} \xrightarrow{p} \Sigma_{h_2}$ .

Liko parodyti, kad  $\text{rank}(\hat{\Sigma}_{h_2}) = \text{rank}(\Sigma_{h_2}) = d + 1 - r$ . Kadangi  $\Sigma_{h_2} = \mathbf{F}'^{-1}\Sigma_{h_1}\mathbf{F}^{-1}$  ir  $\mathbf{F}$  yra pilno rango, tai, remiantis [10] taisykle 10 (sk. 4.3.1, p. 58),  $\text{rank}(\Sigma_{h_2}) = \text{rank}(\Sigma_{h_1}) = d + 1 - r$ . Sunkiau yra įrodyti, kad  $\text{rank}(\hat{\Sigma}_{h_2}) = d + 1 - r$ . Matricos  $\mathbf{L}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{L} = (\mathbf{L}^{-1}\mathbf{Z}'\mathbf{Z}\mathbf{L}^{-1})^{-1}$  blokinis išskaidymas yra toks:

$$(\mathbf{L}^{-1}\mathbf{Z}'\mathbf{Z}\mathbf{L}^{-1})^{-1} = \left( \begin{bmatrix} n_d^{-1}\mathbf{V}'\mathbf{V} & n_d^{-3/2}\mathbf{V}'\mathbf{X} \\ n_d^{-3/2}\mathbf{X}'\mathbf{V} & n_d^{-2}\mathbf{X}'\mathbf{X} \end{bmatrix} \right)^{-1}.$$

$\mathbf{P}(\mathbf{L}^{-1}\mathbf{Z}'\mathbf{Z}\mathbf{L}^{-1})^{-1}\mathbf{P}'$  yra viršutinis kairysis matricos  $(\mathbf{L}^{-1}\mathbf{Z}'\mathbf{Z}\mathbf{L}^{-1})^{-1}$  blokas. Remiantis blokinės atvirkštinės matricos skaičiavimo taisykle 2b iš [10] (sk. 9.11.3, p. 148), gauname:

$$\mathbf{A}_1 := \mathbf{P}\mathbf{L}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{L}\mathbf{P}' = \left( n_d^{-1}\mathbf{V}'\mathbf{V} - n_d^{-3/2}\mathbf{V}'\mathbf{X}(n_d^{-2}\mathbf{X}'\mathbf{X})^{-1}n_d^{-3/2}\mathbf{X}'\mathbf{V} \right)^{-1}.$$

Čia reikia pasakyti, kad, kadangi  $\mathbf{L}^{-1}\mathbf{Z}'\mathbf{Z}\mathbf{L}^{-1}$  yra simetrinė ir teigiamai apibrėžta, tai matrica  $n_d^{-1}\mathbf{V}'\mathbf{V} - n_d^{-3/2}\mathbf{V}'\mathbf{X}(n_d^{-2}\mathbf{X}'\mathbf{X})^{-1}n_d^{-3/2}\mathbf{X}'\mathbf{V}$  yra simetrinė ir teigiamai apibrėžta<sup>23</sup>, todėl turi atvirkštinę matricą, kuri taip pat yra teigiamai apibrėžta. Remiantis  $\mathbf{D}_{\tilde{f},\tilde{\gamma}}$  apibrėžimu

<sup>23</sup>Knygoje [10] šio fakto nėra, tačiau jį galima rasti bet kurioje iš šių nuorodų:

- [http://en.wikipedia.org/wiki/Schur\\_complement](http://en.wikipedia.org/wiki/Schur_complement)
- <http://www.cis.upenn.edu/~jean/schur-comp.pdf>
- <http://www.colorado.edu/engineering/cas/courses.d/IFEM.d/IFEM.AppP.d/IFEM.AppP.pdf>

(2.21), matricą  $D'_{\tilde{f},\hat{\gamma}} L^{-1} Z' Z L^{-1} D_{\tilde{f},\hat{\gamma}}$  suskaidome į dalis taip:

$$D'_{\tilde{f},\hat{\gamma}} L^{-1} Z' Z L^{-1} D_{\tilde{f},\hat{\gamma}} = \begin{bmatrix} D'_{f,\hat{\gamma}} n_d^{-1} V' V D_{f,\hat{\gamma}} & D'_{f,\hat{\gamma}} n_d^{-3/2} V' X \\ n_d^{-3/2} X' V D_{f,\hat{\gamma}} & n_d^{-2} X' X \end{bmatrix}.$$

Matricos  $(D'_{\tilde{f},\hat{\gamma}} L^{-1} Z' Z L^{-1} D_{\tilde{f},\hat{\gamma}})^{-1}$  viršutinis kairysis blokas  $A_2$ , remiantis taisykle 2b iš [10] (sk. 9.11.3, p. 148) yra :

$$\begin{aligned} A_2 &= \left( D'_{f,\hat{\gamma}} n_d^{-1} V' V D_{f,\hat{\gamma}} - D'_{f,\hat{\gamma}} n_d^{-3/2} V' X (n_d^{-2} X' X)^{-1} n_d^{-3/2} X' V D_{f,\hat{\gamma}} \right)^{-1} \\ &= \left( D'_{f,\hat{\gamma}} \left( n_d^{-1} V' V - n_d^{-3/2} V' X (n_d^{-2} X' X)^{-1} n_d^{-3/2} X' V \right) D_{f,\hat{\gamma}} \right)^{-1} \\ &= (D'_{f,\hat{\gamma}} A_1^{-1} D_{f,\hat{\gamma}})^{-1}. \end{aligned}$$

Iš  $D_{\tilde{f},\hat{\gamma}}$  apibrėžimo (2.21):

$$P L \Delta_{\tilde{f},\hat{\gamma}} L P' = D_{f,\hat{\gamma}} A_2 D'_{f,\hat{\gamma}}.$$

Taigi  $\hat{\Sigma}_{h_2}$  galima užrašyti tokiu pavidalu:

$$\hat{\Sigma}_{h_2} = A_1 - D_{f,\hat{\gamma}} (D'_{f,\hat{\gamma}} A_1^{-1} D_{f,\hat{\gamma}})^{-1} D'_{f,\hat{\gamma}}. \quad (B.2)$$

Kadangi  $A_1$  teigiamai apibrėžta, pagal Cholesky dekompoziciją,  $\exists F_{A_1}$  tokia, kad  $A_1 = F_{A_1} F'_{A_1}$ . Kadangi  $F_{A_1}$  yra pilno rango, tai ir  $F_{A_1}^{-1}$  yra pilno rango, todėl

$$\text{rank}(F_{A_1}^{-1} \hat{\Sigma}_{h_2} F_{A_1}'^{-1}) = \text{rank}(\hat{\Sigma}_{h_2}).$$

Raskime  $F_{A_1}^{-1} \hat{\Sigma}_{h_2} F_{A_1}'^{-1}$  rangą. Iš (B.2) turime:

$$F_{A_1}^{-1} \hat{\Sigma}_{h_2} F_{A_1}'^{-1} = I_{d+1} - F_{A_1}^{-1} D_{f,\hat{\gamma}} (D'_{f,\hat{\gamma}} F_{A_1}'^{-1} F_{A_1}^{-1} D_{f,\hat{\gamma}})^{-1} D'_{f,\hat{\gamma}} F_{A_1}'^{-1}. \quad (B.3)$$

(B.3) gauto skirtumo antroji matrica yra idempotentinė ir jos rangas lygus  $r$ . Remiantis [10] 17c taisykle (sk. 4.3.1, p. 59),

$$\text{rank}(F_{A_1}^{-1} \hat{\Sigma}_{h_2} F_{A_1}'^{-1}) = d + 1 - r.$$

Taigi  $\text{rank}(\hat{\Sigma}_{h_2}) = \text{rank}(\Sigma_{h_2}) = d + 1 - r$ .

Lieka pasiremti [2] teorema 1, iš kur gauname, kad

$$T_2 = h_2' \hat{\Sigma}_{h_2}^- h_2 \xrightarrow{d} \chi^2(d + 1 - r).$$

## $\tilde{H}_1$ atvejis

Tegu galioja  $\tilde{H}_1$ . Lygybės (A.44) analogas statistikai  $T_2$  nesunkiai gaunamas toks:

$$\begin{aligned} \hat{\sigma}_u^2 n_d^{-1} T_2 &= (\beta_{0,d} - \mathbf{f}(\gamma_0))' (I_{d+1} - \mathbf{V}' \mathbf{Z} \Delta'_{\tilde{\mathbf{f}}, \hat{\gamma}} \mathbf{P}') \hat{\Sigma}_{h_2}^- \times \\ &\times (I_{d+1} - \mathbf{P} \Delta_{\tilde{\mathbf{f}}, \hat{\gamma}} \mathbf{Z}' \mathbf{V}) (\beta_{0,d} - \mathbf{f}(\gamma_0)) + O_p(n_d^{-1/2}) + O_p(n_d^{-1}). \end{aligned} \quad (\text{B.4})$$

Priminsime, kad  $\gamma_0 := \text{plim} \hat{\gamma}$ . Iš (B.1):

$$\text{plim} \hat{\Sigma}_{h_2} = \mathbf{Q}^{-1} - \mathbf{D}_{\mathbf{f}, \gamma_0} (\mathbf{D}'_{\mathbf{f}, \gamma_0} \mathbf{Q} \mathbf{D}_{\mathbf{f}, \gamma_0})^{-1} \mathbf{D}'_{\mathbf{f}, \gamma_0}.$$

Taigi  $\Sigma_{h_2, \gamma_0} = \text{plim} \hat{\Sigma}_{h_2}$ .

Parodysime, kad  $\hat{\Sigma}_{h_2}^- \xrightarrow{p} \Sigma_{h_2, \gamma_0}^-$ . Reikia parodyti, kad  $\text{rank}(\Sigma_{h_2, \gamma_0}) = d+1-r$ , ir pasiremti [2] teorema 2.  $\mathbf{F}$  yra pilno rango, todėl  $\text{rank}(\Sigma_{h_2, \gamma_0}) = \text{rank}(\mathbf{F}' \Sigma_{h_2, \gamma_0} \mathbf{F})$ , o

$$\mathbf{F}' \Sigma_{h_2, \gamma_0} \mathbf{F} = I_{d+1} - \mathbf{F}' \mathbf{D}_{\mathbf{f}, \gamma_0} (\mathbf{D}'_{\mathbf{f}, \gamma_0} \mathbf{Q} \mathbf{D}_{\mathbf{f}, \gamma_0})^{-1} \mathbf{D}'_{\mathbf{f}, \gamma_0} \mathbf{F}. \quad (\text{B.5})$$

Matrica  $\mathbf{F}' \Sigma_{h_2, \gamma_0} \mathbf{F}$  yra idempotentinė ir jos rangas lygus  $d+1-r$ . Kadangi  $\hat{\Sigma}_{h_2}$  ir  $\Sigma_{h_2, \gamma_0}$  rangai sutampa, tai galima pasiremti [2] teorema 2 ir teigti, kad  $\hat{\Sigma}_{h_2}^- \xrightarrow{p} \Sigma_{h_2, \gamma_0}^-$ . Bendru atveju apibendrintoms atvirkštinėms matricoms tai nebūtinai yra teisinga.

Paėmę (B.4) kvadratinės formos matricą ir perėję prie ribos pagal tikimybę, pasinaudoję (A.48), gauname:

$$\begin{aligned} & (I_{d+1} - \mathbf{V}' \mathbf{Z} \Delta'_{\tilde{\mathbf{f}}, \hat{\gamma}} \mathbf{P}') \hat{\Sigma}_{h_2}^- (I_{d+1} - \mathbf{P} \Delta_{\tilde{\mathbf{f}}, \hat{\gamma}} \mathbf{Z}' \mathbf{V}) \xrightarrow{p} (I_{d+1} - \mathbf{Q} \Delta) \Sigma_{h_2, \gamma_0}^- (I_{d+1} - \Delta \mathbf{Q}) \\ &= \Sigma_{h_2, \gamma_0}^- - \Sigma_{h_2, \gamma_0}^- \Delta \mathbf{Q} - \mathbf{Q} \Delta \Sigma_{h_2, \gamma_0}^- + \mathbf{Q} \Delta \Sigma_{h_2, \gamma_0}^- \Delta \mathbf{Q}. \end{aligned} \quad (\text{B.6})$$

Iš (A.55) žinome, kad  $\Delta \mathbf{Q}(\beta_{0,d} - \mathbf{f}(\gamma_0)) = \mathbf{0}$ . Taigi iš (B.4) ir (B.6):

$$\hat{\sigma}_u^2 n_d^{-1} T_2 \xrightarrow{p} (\beta_{0,d} - \mathbf{f}(\gamma_0))' \Sigma_{h_2, \gamma_0}^- (\beta_{0,d} - \mathbf{f}(\gamma_0)). \quad (\text{B.7})$$

Liko pagrįsti, kad  $\Sigma_{h_2, \gamma_0}^-$  yra neneigiamai apibrėžta. Iš (B.5) žinome, kad  $\mathbf{F}' \Sigma_{h_2, \gamma_0} \mathbf{F}$  yra simetrinė ir idempotentinė, todėl, remiantis [10] taisykle 3c (sk. 9.8, p. 138), yra neneigiamai apibrėžta. Kadangi  $\Sigma_{h_2, \gamma_0} = \mathbf{F}'^{-1} (\mathbf{F}' \Sigma_{h_2, \gamma_0} \mathbf{F}) \mathbf{F}^{-1}$ , tai  $\Sigma_{h_2, \gamma_0}$  yra neneigiamai apibrėžta pagal [10] taisyklę 10a (sk. 9.12.1, p. 152). Kadangi  $\Sigma_{h_2, \gamma_0}$  yra simetrinė, tai ir  $\Sigma_{h_2, \gamma_0}^-$  yra simetrinė pagal [10] taisyklę 8b (sk. 3.6.2, p. 34). Todėl  $\Sigma_{h_2, \gamma_0}^-$  tenkina lygybę  $\Sigma_{h_2, \gamma_0}^- = \Sigma_{h_2, \gamma_0}^- \Sigma_{h_2, \gamma_0} \Sigma_{h_2, \gamma_0}^-$ , iš ko seka, kad  $\Sigma_{h_2, \gamma_0}^-$  yra neneigiamai apibrėžta ([10] taisyklė 10a iš sk. 9.12.1, p. 152). Iš (B.7),  $\hat{\sigma}_u^2 n_d^{-1} T_2$  pagal tikimybę artėja į neneigiamą skaičių.

Šioje vietoje tenka įrodymą pabaigti. Galima parodyti, kad jei  $(\beta_{0,d} - \mathbf{f}(\gamma_0))' \Sigma_{h_2, \gamma_0}^- (\beta_{0,d} - \mathbf{f}(\gamma_0)) > 0$ , tai ir  $(\beta_{0,d} - \mathbf{f}(\gamma_0))' \Sigma_{h_2, \gamma_0}^- (\beta_{0,d} - \mathbf{f}(\gamma_0)) > 0$ , tačiau neaišku, kaip patikrinti pirmąją sąlygą. □

## C Teiginio 3.1 įrodymas

Įrodymo struktūra panaši į 2.2 teiginio įrodymo struktūrą.  $\tilde{H}_0$  atveju parodžius, kad NMKM įvertiniai yra suderinti, įrodoma, kad MKM ir NMKM įvertinių skirtumas  $\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})$ , padauginus iš  $\sqrt{n_d}\mathbf{F}'_A$ , asimptotiškai pasiskirstęs pagal normalųjį dėsnį. Tuo pačiu randama šio atsitiktinio vektoriaus kovariacijų matrica  $\Sigma_{h_3}$ . Tada nesunku parodyti, kad  $\hat{\Sigma}_{h_3} \xrightarrow{p} \Sigma_{h_3}$ , ir kad  $\text{rank}(\hat{\Sigma}_{h_3}) = \text{rank}(\Sigma_{h_3}) = d + 1 - r$ . Iš to seka, kad  $T_3 \xrightarrow{p} \chi^2(d + 1 - r)$ . Jei yra teisinga  $\tilde{H}_1$ , panašiai kaip ir 2.2 teiginio atveju, parodoma, kad  $n_d^{-1}T_3$  pagal tikimybę artėja į teigiamą skaičių. Vadinasi,  $T_3 \xrightarrow{p} \infty$ .

Pasiremami priedu A, raskime sumų  $\tilde{\mathbf{Z}}'\tilde{\mathbf{Z}}$  ir  $\tilde{\mathbf{Z}}'\mathbf{u}$  asimptotinę elgesį. Suskaidykime matricą  $\tilde{\mathbf{Z}}$  į tris dalis taip:

$$\tilde{\mathbf{Z}} = \begin{bmatrix} \tilde{\mathbf{V}} & \mathbf{1} & \tilde{\mathbf{X}} \end{bmatrix}, \quad \tilde{\mathbf{V}} := \begin{bmatrix} \mathbf{V} & \Xi_0 \end{bmatrix}, \quad \tilde{\mathbf{X}} := \begin{bmatrix} \mathbf{X} & \Xi_1 \end{bmatrix}. \quad (\text{C.1})$$

Taigi matricą  $\tilde{\mathbf{V}}$  sudaro stacionarūs kintamieji, kurių yra  $d + 1 + d_0$ , o matricą  $\tilde{\mathbf{X}}$  sudaro integruoti kintamieji, kurių yra  $d_1 + 1$ . Sudarykime  $(d + 1 + d_0) \times (\tilde{d} - 2)$  dimensijos matricą  $\mathbf{P}_0$  tokią:

$$\mathbf{P}_0 := \begin{bmatrix} \mathbf{I}_{d+1+d_0} & \mathbf{0} \end{bmatrix}.$$

Turime  $\mathbf{P}_0\tilde{\mathbf{v}}_t = (v_{tm}, \dots, v_{tm-d}, \xi'_{0,t})'$ . Proceso  $\mathbf{P}_0\tilde{\mathbf{v}}_t$  kovariacijų matrica  $\tilde{\mathbf{Q}}$  yra:

$$\tilde{\mathbf{Q}} := \mathbf{P}_0 \mathbf{E}(\tilde{\mathbf{v}}_t \tilde{\mathbf{v}}'_t) \mathbf{P}_0'.$$

$\tilde{\mathbf{Q}}$  yra pirmieji  $d + 1$  matricos  $\mathbf{E}(\tilde{\mathbf{v}}_t \tilde{\mathbf{v}}'_t)$  eilutės ir stulpeliai. Iš prielaidos N4,  $\mathbf{E}(\tilde{\mathbf{v}}_t \tilde{\mathbf{v}}'_t)$  yra teigiamai apibrėžta, todėl, remiantis [10] taisykle 12 (sk. 5.3.2, p. 75),  $\tilde{\mathbf{Q}}$  yra teigiamai apibrėžta. Kitos [7] teiginio 7.9 (p. 194) sąlygos patvirtinamos kaip ir priede A. Taigi, pasiremiant priedu A, galima teigti, kad

$$n_d^{-1/2} \tilde{\mathbf{V}}' \mathbf{u} = n_d^{-1/2} \sum_{t=t_1}^n \mathbf{P}_0 \tilde{\mathbf{v}}_t u_t \xrightarrow{d} N(\mathbf{0}, \sigma_u^2 \tilde{\mathbf{Q}}).$$

Iš [7] teiginio 18.1 (p. 547):

$$n_d^{-1} \tilde{\mathbf{V}}' \tilde{\mathbf{V}} = n_d^{-1} \sum_{t=t_1}^n \mathbf{P}_0 \tilde{\mathbf{v}}_t \tilde{\mathbf{v}}'_t \mathbf{P}_0' \xrightarrow{p} \mathbf{P}_0 \mathbf{E}(\tilde{\mathbf{v}}_t \tilde{\mathbf{v}}'_t) \mathbf{P}_0' = \tilde{\mathbf{Q}}.$$

Taip pat iš [7] 18.1 teiginio,  $\tilde{\mathbf{V}}' \mathbf{1} = \mathcal{O}_p(n_d^{1/2})$ .

Raskime  $\tilde{\mathbf{X}}' \tilde{\mathbf{V}}$ ,  $\tilde{\mathbf{X}}' \mathbf{1}$ ,  $\tilde{\mathbf{X}}' \tilde{\mathbf{X}}$  ir  $\tilde{\mathbf{X}}' \mathbf{u}$  konvergavimo greičius. Kaip ir priede A, procesas  $(\tilde{\mathbf{v}}'_t, x_{tm-d-1} - x_{tm-d-m})'$  užrašomas MA( $\infty$ ) forma. Parodymas, kad ši forma tenkina [7] 18.1 teiginio sąlygas, iš esmės nesiskiria nuo pateikto priede A. Vadinasi, galima pasiremti [7] teiginiu 18.1, iš kurio  $\tilde{\mathbf{X}}' \tilde{\mathbf{X}} = \mathcal{O}_p(n_d^2)$ ,  $\tilde{\mathbf{X}}' \tilde{\mathbf{V}} = \mathcal{O}_p(n_d)$ . Iš to paties teiginio,  $\tilde{\mathbf{X}}' \mathbf{1} = \mathcal{O}_p(n_d^{3/2})$ . Kaip pagrįsta priede A,  $(\tilde{\mathbf{v}}'_t, x_{tm-d-1} - x_{tm-d-m}, u_t)'$  MA( $\infty$ ) forma tenkina [7] teiginio 18.1 sąlygas, todėl  $\tilde{\mathbf{X}}' \mathbf{u} = \mathcal{O}_p(n_d)$ . Be to,  $n_d^{-1/2} \tilde{\mathbf{V}}' \mathbf{1}$ ,  $n_d^{-3/2} \tilde{\mathbf{X}}' \mathbf{1}$ ,  $n_d^{-1} \tilde{\mathbf{V}}' \tilde{\mathbf{X}}$ ,  $n_d^{-2} \tilde{\mathbf{X}}' \tilde{\mathbf{X}}$

ir  $n_d^{-1} \tilde{\mathbf{X}}' \mathbf{u}$  nėra  $\mathbf{o}_p(1)$ . Kaip ir teiginio 2.2 įrodyme, iš su integruotais nariais susijusių sumų bus reikalingi tik konvergavimo greičiai, tiksliai nedetalizuojant asimptotinių skirstinių.

Modelio (3.4) atveju reikia apibrėžti tokią  $\tilde{d} \times \tilde{d}$ . normavimo matricą  $\mathbf{L}$ :

$$\mathbf{L} := \begin{bmatrix} \sqrt{n_d} \mathbf{I}_{d+d_0+1} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \sqrt{n_d} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & n_d \mathbf{I}_{d_1+1} \end{bmatrix} = \begin{bmatrix} \sqrt{n_d} \mathbf{I}_{d+d_0+2} & \mathbf{0} \\ \mathbf{0} & n_d \mathbf{I}_{d_1+1} \end{bmatrix}.$$

Čia  $\sqrt{n_d} \mathbf{I}_{d+d_0+2}$  atitinka stacionarius kintamuosius ir laisvąjį narį, o  $n_d \mathbf{I}_{d_1+1}$  atitinka integruotus kintamuosius matricoje  $\tilde{\mathbf{Z}}$ . Iš centrinės ribinės teoremos n.v.p. atsitiktiniams dydžiams,  $n_d^{-1/2} \mathbf{1}' \mathbf{u} \xrightarrow{d} N(0, \sigma_u^2)$ . Taigi,

$$\mathbf{L}^{-1} \tilde{\mathbf{Z}}' \mathbf{u} = \begin{bmatrix} n_d^{-1/2} \tilde{\mathbf{V}}' \mathbf{u} \\ n_d^{-1/2} \mathbf{1}' \mathbf{u} \\ n_d^{-1} \tilde{\mathbf{X}}' \mathbf{u} \end{bmatrix} \xrightarrow{d} \begin{bmatrix} N(0, \sigma_u^2 \tilde{\mathbf{Q}}) \\ N(0, \sigma_u^2) \\ \text{dlim}(n_d^{-1} \tilde{\mathbf{X}}' \mathbf{u}) \end{bmatrix}. \quad (\text{C.2})$$

## $\tilde{H}_0$ atvejis

Tegu galioja  $\tilde{H}_0$ . Tegu  $\gamma \in \Lambda$  yra toks, kad  $\mathbf{f}(\gamma) = \beta_{0,d}$ . Parodysiu, kad  $\hat{\gamma} \xrightarrow{p} \gamma$ . Pažymėkime  $\mathbf{f}_0 : \Lambda \times \mathbb{R}^{d_0} \rightarrow \mathbb{R}^{d+1+d_0}$  tokią funkciją, kad  $\mathbf{f}_0(\psi_0) = \mathbf{P}_0 \tilde{\mathbf{f}}(\psi)$ , kur  $\psi_0 := (\gamma', \eta'_0)'$  yra parametrai prie stacionarių modelio kintamųjų. Tegu  $\psi_1 := (\beta_d, \eta'_1)'$  yra parametrai prie integruotų kintamųjų. Tada (3.4) modelis, esant teisingai  $\tilde{H}_0$ , užrašomas taip:

$$\mathbf{y} = \tilde{\mathbf{V}} \mathbf{f}_0(\psi_0) + \mathbf{1}\alpha + \tilde{\mathbf{X}} \psi_1 + \mathbf{u}. \quad (\text{C.3})$$

Iš įvertinių  $\hat{\psi}$  būtiniosios sąlygos (3.7) paskutinių  $d_1 + 1$  lygybių, padauginę jas iš  $n_d^{-2}$  ir pasinaudoję (C.3), gauname tokią lygybę, kurią tenkina įvertiniai  $\hat{\psi}$ :

$$n_d^{-2} \tilde{\mathbf{X}}' \tilde{\mathbf{X}}(\psi_1 - \hat{\psi}_1) = n_d^{-2} \left[ -\tilde{\mathbf{X}}' \mathbf{u} + \tilde{\mathbf{X}}' \tilde{\mathbf{V}}(\mathbf{f}_0(\hat{\psi}_0) - \mathbf{f}_0(\psi_0)) + \tilde{\mathbf{X}}' \mathbf{1}(\hat{\alpha}^{nls} - \alpha) \right]. \quad (\text{C.4})$$

Kadangi  $\tilde{\mathbf{X}}' \mathbf{1} = \mathbf{O}_p(n_d^{3/2})$ ,  $\tilde{\mathbf{X}}' \mathbf{u} = \mathbf{O}_p(n_d)$ ,  $\tilde{\mathbf{X}}' \tilde{\mathbf{V}} = \mathbf{O}_p(n_d)$  ir egzistuoja plim $\hat{\psi}$ , tai dešinė (C.4) lygybės pusė pagal tikimybę artėja į  $\mathbf{0}$ . Perėjus prie ribos (C.4) abiejose pusėse, gauname:

$$\text{dlim}(n_d^{-2} \tilde{\mathbf{X}}' \tilde{\mathbf{X}})(\psi_1 - \text{plim} \hat{\psi}_1) = \mathbf{0}.$$

Kadangi  $\text{dlim}(n_d^{-2} \tilde{\mathbf{X}}' \tilde{\mathbf{X}})$  nėra  $\mathbf{o}_p(1)$ , tai  $\hat{\psi}_1 \xrightarrow{p} \psi_1$ . Iš įvertinių  $\hat{\psi}$  būtiniosios sąlygos (3.7) pirmųjų  $d + 1 + d_0$  lygybių, pasinaudoję (C.3), turime:

$$\begin{aligned} n_d^{-1} \mathbf{D}'_{f_0, \hat{\gamma}} \tilde{\mathbf{V}}' \tilde{\mathbf{V}}(\mathbf{f}_0(\psi_0) - \mathbf{f}_0(\hat{\psi}_0)) &= n_d^{-1} \left[ -\mathbf{D}'_{f_0, \hat{\gamma}} \tilde{\mathbf{V}}' \mathbf{u} + \mathbf{D}'_{f_0, \hat{\gamma}} \tilde{\mathbf{V}}' \mathbf{1}(\hat{\alpha}^{nls} - \alpha) + \right. \\ &\quad \left. + \mathbf{D}'_{f_0, \hat{\gamma}} \tilde{\mathbf{V}}' \tilde{\mathbf{X}}(\hat{\psi}_1 - \psi_1) \right]. \end{aligned} \quad (\text{C.5})$$

Čia  $\mathbf{D}_{f_0, \hat{\gamma}}$  yra matrica sudaryta iš matricos  $\mathbf{D}_{\tilde{f}, \hat{\gamma}}$  pirmųjų  $d + 1 + d_0$  eilučių ir pirmųjų  $r + d_0$  stulpelių. Pasinaudoję prielaida N3, turime, kad  $\exists \text{plim} \hat{\alpha}^{nls}$  ir  $\exists \text{plim} \mathbf{D}_{f_0, \hat{\gamma}}$ . Kadangi



$\mathbf{V}'\mathbf{u} = \mathbf{O}_p(n_d^{1/2})$ ,  $\mathbf{V}'\mathbf{1} = \mathbf{O}_p(n_d^{1/2})$ ,  $\tilde{\mathbf{V}}'\tilde{\mathbf{X}} = \mathbf{O}_p(n_d)$  ir  $\hat{\boldsymbol{\psi}}_1 \xrightarrow{p} \boldsymbol{\psi}_1$ , perėję prie ribos (C.5) lygybėje pagal tikimybę, turime:

$$\text{plim}(\mathbf{D}'_{f_0, \hat{\gamma}}) \tilde{\mathbf{Q}}(f_0(\boldsymbol{\psi}_0) - f_0(\text{plim}\hat{\boldsymbol{\psi}}_0)) = \mathbf{0}.$$

Iš tų pačių argumentų kaip ir priede A išplaukia, kad  $\hat{\boldsymbol{\psi}}_0 \xrightarrow{p} \boldsymbol{\psi}_0$ , taigi ir  $\hat{\gamma} \xrightarrow{p} \gamma$ .

Skirtumą  $\hat{\boldsymbol{\beta}}_{0,d} - \mathbf{f}(\hat{\gamma})$  išsireikškime per modelio kintamuosius. Kaip ir teiginio 2.2 įrodyme, pagal tikslios Teiloro eilutės pirmos eilės aproksimaciją taške  $\gamma$ , į kurią pagal tikimybę artėja  $\hat{\gamma}$ , turime tokią lygybę:

$$\mathbf{f}(\hat{\gamma}) = \mathbf{f}(\gamma) + \mathbf{D}_{f, \gamma+}(\hat{\gamma} - \gamma). \quad (\text{C.6})$$

(C.6) papildymas visiems modelio įvertiniams  $\hat{\boldsymbol{\psi}}$  yra:

$$\tilde{\mathbf{f}}(\hat{\boldsymbol{\psi}}) = \tilde{\mathbf{f}}(\boldsymbol{\psi}) + \mathbf{D}_{\tilde{f}, \gamma+}(\hat{\boldsymbol{\psi}} - \boldsymbol{\psi}). \quad (\text{C.7})$$

Kadangi  $\mathbf{y} = \tilde{\mathbf{Z}}\tilde{\mathbf{f}}(\hat{\boldsymbol{\psi}}) + \mathbf{u}$ , iš įvertinių  $\hat{\boldsymbol{\psi}}$  būtiniosios sąlygos (3.7), pasinaudoję (C.7) gauname:

$$\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{Z}}'(\mathbf{y} - \tilde{\mathbf{Z}}\tilde{\mathbf{f}}(\hat{\boldsymbol{\psi}})) = \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{D}_{\tilde{f}, \gamma+}(\boldsymbol{\psi} - \hat{\boldsymbol{\psi}}) + \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{Z}}' \mathbf{u} = \mathbf{0}. \quad (\text{C.8})$$

Iš (C.7) ir (C.8):

$$\tilde{\mathbf{f}}(\hat{\boldsymbol{\psi}}) - \tilde{\mathbf{f}}(\boldsymbol{\psi}) = \mathbf{D}_{\tilde{f}, \gamma+}(\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{D}_{\tilde{f}, \gamma+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{Z}}' \mathbf{u}. \quad (\text{C.9})$$

Tegu išrinkimo matrica  $\mathbf{P}$  yra tokia, kad  $\mathbf{f}(\gamma) = \mathbf{P}\tilde{\mathbf{f}}(\boldsymbol{\psi})$ . Kadangi  $\mathbf{P}\tilde{\mathbf{f}}(\boldsymbol{\psi}) = \boldsymbol{\beta}_{0,d}$ , tai iš (C.9) gauname:

$$\mathbf{f}(\hat{\gamma}) - \boldsymbol{\beta}_{0,d} = \mathbf{P}\mathbf{D}_{\tilde{f}, \gamma+}(\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{D}_{\tilde{f}, \gamma+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{Z}}' \mathbf{u}. \quad (\text{C.10})$$

MKM įvertiniams  $\hat{\boldsymbol{\Gamma}}$  gauname:

$$\begin{aligned} \hat{\boldsymbol{\beta}}_{0,d} &= \mathbf{P}\hat{\boldsymbol{\Gamma}} = \mathbf{P}(\tilde{\mathbf{Z}}'\tilde{\mathbf{Z}})^{-1} \tilde{\mathbf{Z}}'\mathbf{y} = \mathbf{P}\boldsymbol{\Gamma} + \mathbf{P}(\tilde{\mathbf{Z}}'\tilde{\mathbf{Z}})^{-1} \tilde{\mathbf{Z}}'\mathbf{u} \\ &= \boldsymbol{\beta}_{0,d} + \mathbf{P}(\tilde{\mathbf{Z}}'\tilde{\mathbf{Z}})^{-1} \tilde{\mathbf{Z}}'\mathbf{u}. \end{aligned} \quad (\text{C.11})$$

Iš (C.10) ir (C.11) turime tokį skirtumo  $\hat{\boldsymbol{\beta}}_{0,d} - \mathbf{f}(\hat{\gamma})$  pavidalą:

$$\hat{\boldsymbol{\beta}}_{0,d} - \mathbf{f}(\hat{\gamma}) = \mathbf{P} \left[ (\tilde{\mathbf{Z}}'\tilde{\mathbf{Z}})^{-1} - \mathbf{D}_{\tilde{f}, \gamma+}(\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{D}_{\tilde{f}, \gamma+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \right] \tilde{\mathbf{Z}}'\mathbf{u}. \quad (\text{C.12})$$

Mums reikia rasti  $\sqrt{n_d}\mathbf{F}'_{\hat{\mathbf{A}}}(\hat{\boldsymbol{\beta}}_{0,d} - \mathbf{f}(\hat{\gamma}))$  asimptotinę pasiskirstymą. Kadangi  $\sqrt{n_d}\mathbf{I}_{d+1} = \mathbf{P}\mathbf{L}$ , iš (C.12) turime:

$$\sqrt{n_d}\mathbf{F}'_{\hat{\mathbf{A}}}(\hat{\boldsymbol{\beta}}_{0,d} - \mathbf{f}(\hat{\gamma})) = \mathbf{F}'_{\hat{\mathbf{A}}}\mathbf{P}\mathbf{B}_{\hat{\gamma}}\mathbf{L}^{-1}\tilde{\mathbf{Z}}'\mathbf{u}, \quad (\text{C.13})$$

kur

$$\mathbf{B}_{\hat{\gamma}} := \mathbf{L} \left[ (\tilde{\mathbf{Z}}' \tilde{\mathbf{Z}})^{-1} - \mathbf{D}_{\tilde{f}, \gamma+} (\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{D}_{\tilde{f}, \gamma+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \right] \mathbf{L}. \quad (\text{C.14})$$

Kaip matome, šiek tiek kitaip nei priede A apibrėžus matricas  $\mathbf{F}_{\hat{A}}$ ,  $\mathbf{P}$ ,  $\mathbf{L}$  ir  $\mathbf{B}_{\hat{\gamma}}$ , išraiška (C.13) sutampa su (A.23).

Rasime atsitiktinės matricos  $\mathbf{B}_{\hat{\gamma}}$  ribą pagal tikimybę. Kaip ir teiginio 2.2 įrodyme, naudojantis dėl  $\mathbf{D}_{\tilde{f}, \hat{\gamma}}$  blokinės diagonalinės struktūros galiojančiu normavimo matricų „perkėlimu“, gauname:

$$\begin{aligned} \mathbf{B}_{\hat{\gamma}} &= \mathbf{L} (\tilde{\mathbf{Z}}' \tilde{\mathbf{Z}})^{-1} \mathbf{L} - \mathbf{L} \mathbf{D}_{\tilde{f}, \gamma+} (\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{D}_{\tilde{f}, \gamma+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L} \\ &= (\mathbf{L}^{-1} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{L}^{-1})^{-1} - \mathbf{D}_{\tilde{f}, \gamma+} (\mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L}^{-1} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{L}^{-1} \mathbf{D}_{\tilde{f}, \gamma+})^{-1} \mathbf{D}'_{\tilde{f}, \hat{\gamma}}. \end{aligned} \quad (\text{C.15})$$

Iš matricos  $\tilde{\mathbf{Z}}$  išdėstymo (C.1) turime:

$$\begin{aligned} \mathbf{L}^{-1} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{L}^{-1} &= \begin{bmatrix} n_d^{-1} \tilde{\mathbf{V}}' \tilde{\mathbf{V}} & n_d^{-1} \tilde{\mathbf{V}}' \mathbf{1} & n_d^{-3/2} \tilde{\mathbf{V}}' \tilde{\mathbf{X}} \\ n_d^{-1} \mathbf{1}' \tilde{\mathbf{V}} & 1 & n_d^{-3/2} \mathbf{1}' \tilde{\mathbf{X}} \\ n_d^{-3/2} \tilde{\mathbf{X}}' \tilde{\mathbf{V}} & n_d^{-3/2} \tilde{\mathbf{X}}' \mathbf{1} & n_d^{-2} \tilde{\mathbf{X}}' \tilde{\mathbf{X}} \end{bmatrix} \xrightarrow{d} \\ &\xrightarrow{d} \begin{bmatrix} \tilde{\mathbf{Q}} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & 1 & \text{dlim}(n_d^{-3/2} \mathbf{1}' \tilde{\mathbf{X}}) \\ \mathbf{0} & \text{dlim}(n_d^{-3/2} \tilde{\mathbf{X}}' \mathbf{1}) & \text{dlim}(n_d^{-2} \tilde{\mathbf{X}}' \tilde{\mathbf{X}}) \end{bmatrix}, \end{aligned} \quad (\text{C.16})$$

kur, pereinant prie ribos, pasinaudota rastais procesų konvergavimo greičiais. Atitinkamai (C.16) matricų išdėstymui, suskaidykime Jakobianą  $\mathbf{D}_{\tilde{f}, \hat{\gamma}}$  taip:

$$\mathbf{D}_{\tilde{f}, \hat{\gamma}} = \begin{bmatrix} \mathbf{D}_{f_0, \hat{\gamma}} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & 1 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{I}_{d_1+1} \end{bmatrix}, \quad \mathbf{D}_{f_0, \hat{\gamma}} := \begin{bmatrix} \mathbf{D}_{f, \hat{\gamma}} & \mathbf{0} \\ \mathbf{0} & \mathbf{I}_{d_0} \end{bmatrix}. \quad (\text{C.17})$$

Tada, remiantis tuo, kad  $\hat{\gamma} \xrightarrow{p} \gamma$ ,  $\gamma+ \xrightarrow{p} \gamma$  iš vidutinės reikšmės teoremos, gauname:

$$\begin{aligned} \mathbf{D}'_{\tilde{f}, \hat{\gamma}} \mathbf{L}^{-1} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{L}^{-1} \mathbf{D}_{\tilde{f}, \gamma+} &= \begin{bmatrix} n_d^{-1} \mathbf{D}'_{f_0, \hat{\gamma}} \tilde{\mathbf{V}}' \tilde{\mathbf{V}} \mathbf{D}_{f_0, \gamma} & n_d^{-1} \mathbf{D}'_{f_0, \hat{\gamma}} \tilde{\mathbf{V}}' \mathbf{1} & n_d^{-3/2} \mathbf{D}'_{f_0, \hat{\gamma}} \tilde{\mathbf{V}}' \tilde{\mathbf{X}} \\ n_d^{-1} \mathbf{1}' \tilde{\mathbf{V}} \mathbf{D}_{f_0, \gamma} & 1 & n_d^{-3/2} \mathbf{1}' \tilde{\mathbf{X}} \\ n_d^{-3/2} \tilde{\mathbf{X}}' \tilde{\mathbf{V}} \mathbf{D}_{f_0, \gamma} & n_d^{-3/2} \tilde{\mathbf{X}}' \mathbf{1} & n_d^{-2} \tilde{\mathbf{X}}' \tilde{\mathbf{X}} \end{bmatrix} \\ &\xrightarrow{d} \begin{bmatrix} \mathbf{D}'_{\tilde{f}_0, \gamma} \tilde{\mathbf{Q}} \mathbf{D}_{\tilde{f}_0, \gamma} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & 1 & \text{dlim}(n_d^{-3/2} \mathbf{1}' \tilde{\mathbf{X}}) \\ \mathbf{0} & \text{dlim}(n_d^{-3/2} \tilde{\mathbf{X}}' \mathbf{1}) & \text{dlim}(n_d^{-2} \tilde{\mathbf{X}}' \tilde{\mathbf{X}}) \end{bmatrix}. \end{aligned} \quad (\text{C.18})$$

Prielaida N5 užtikrina (C.16) ir (C.18) ribose gautų matricų apatinio dešiniojo bloko apverčiamumą. Taigi iš (C.15), (C.16), (C.17), ir (C.18) gauname:

$$\mathbf{B}_{\hat{\gamma}} \xrightarrow{p} \begin{bmatrix} \tilde{\mathbf{Q}}^{-1} - \mathbf{D}_{\tilde{f}_0, \gamma} (\mathbf{D}'_{\tilde{f}_0, \gamma} \tilde{\mathbf{Q}} \mathbf{D}_{\tilde{f}_0, \gamma})^{-1} \mathbf{D}'_{\tilde{f}_0, \gamma} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} \end{bmatrix}. \quad (\text{C.19})$$

Kadangi matrica  $\mathbf{B}_{\hat{\gamma}}$  pagal pasiskirstymą konverguoja į neatsitiktinę matricą, tai šiuo atveju konvergavimas pagal pasiskirstymą taip pat yra konvergavimas pagal tikimybę.

Radome atsitiktinio vektoriaus  $\mathbf{L}^{-1}\tilde{\mathbf{Z}}'\mathbf{u}$  asimptotinį pasiskirstymą ir atsitiktinės matricos  $\mathbf{B}_{\hat{\gamma}}$  ribą pagal tikimybę. Dabar gaukime MKM ir NMKM įvertinių, esančių prie stacionarių kintamųjų, skirtumo asimptotinį pasiskirstymą. Pažymėkime  $\hat{\mathbf{\Gamma}}_0 := (\hat{\beta}'_{0,d}, \hat{\boldsymbol{\eta}}'_0)$ . Kadangi  $\sqrt{n_d}(\hat{\mathbf{\Gamma}}_0 - \mathbf{f}_0(\hat{\boldsymbol{\psi}}_0)) = \mathbf{P}_0\mathbf{L}(\hat{\mathbf{\Gamma}} - \tilde{\mathbf{f}}(\hat{\boldsymbol{\psi}}))$ , tai  $\sqrt{n_d}(\hat{\mathbf{\Gamma}}_0 - \mathbf{f}_0(\hat{\boldsymbol{\psi}}_0)) = \mathbf{P}_0\mathbf{B}_{\hat{\gamma}}\mathbf{L}^{-1}\tilde{\mathbf{Z}}'\mathbf{u}$ . Iš (C.2) ir (C.19) gauname:

$$\sqrt{n_d}(\hat{\mathbf{\Gamma}}_0 - \mathbf{f}_0(\hat{\boldsymbol{\psi}}_0)) \xrightarrow{d} \left[ \tilde{\mathbf{Q}}^{-1} - \mathbf{D}_{\tilde{f}_0,\gamma}(\mathbf{D}'_{\tilde{f}_0,\gamma}\tilde{\mathbf{Q}}\mathbf{D}_{\tilde{f}_0,\gamma})^{-1}\mathbf{D}'_{\tilde{f}_0,\gamma} \right] N(\mathbf{0}, \sigma_u^2\tilde{\mathbf{Q}}) = N(\mathbf{0}, \sigma_u^2\boldsymbol{\Sigma}_0),$$

kur

$$\begin{aligned} \boldsymbol{\Sigma}_0 &= \left[ \tilde{\mathbf{Q}}^{-1} - \mathbf{D}_{\tilde{f}_0,\gamma}(\mathbf{D}'_{\tilde{f}_0,\gamma}\tilde{\mathbf{Q}}\mathbf{D}_{\tilde{f}_0,\gamma})^{-1}\mathbf{D}'_{\tilde{f}_0,\gamma} \right] \tilde{\mathbf{Q}} \left[ \tilde{\mathbf{Q}}^{-1} - \mathbf{D}_{\tilde{f}_0,\gamma}(\mathbf{D}'_{\tilde{f}_0,\gamma}\tilde{\mathbf{Q}}\mathbf{D}_{\tilde{f}_0,\gamma})^{-1}\mathbf{D}'_{\tilde{f}_0,\gamma} \right]' \\ &= \tilde{\mathbf{Q}}^{-1} - 2\mathbf{D}_{\tilde{f}_0,\gamma}(\mathbf{D}'_{\tilde{f}_0,\gamma}\tilde{\mathbf{Q}}\mathbf{D}_{\tilde{f}_0,\gamma})^{-1}\mathbf{D}'_{\tilde{f}_0,\gamma} + \\ &\quad + \mathbf{D}_{\tilde{f}_0,\gamma}(\mathbf{D}'_{\tilde{f}_0,\gamma}\tilde{\mathbf{Q}}\mathbf{D}_{\tilde{f}_0,\gamma})^{-1}(\mathbf{D}'_{\tilde{f}_0,\gamma}\tilde{\mathbf{Q}}\mathbf{D}_{\tilde{f}_0,\gamma})(\mathbf{D}'_{\tilde{f}_0,\gamma}\tilde{\mathbf{Q}}\mathbf{D}_{\tilde{f}_0,\gamma})^{-1}\mathbf{D}'_{\tilde{f}_0,\gamma} \\ &= \tilde{\mathbf{Q}}^{-1} - \mathbf{D}_{\tilde{f}_0,\gamma}(\mathbf{D}'_{\tilde{f}_0,\gamma}\tilde{\mathbf{Q}}\mathbf{D}_{\tilde{f}_0,\gamma})^{-1}\mathbf{D}'_{\tilde{f}_0,\gamma}. \end{aligned} \quad (\text{C.20})$$

$\sqrt{n_d}(\beta_{0,d} - \mathbf{f}(\hat{\boldsymbol{\gamma}}))$  asimptotinė kovariacijų matrica yra (C.20) gautos asimptotinės kovariacijų matricos pirmosios  $d+1$  eilutės ir stulpeliai. Atitinkamai matricą  $\tilde{\mathbf{Q}}$  suskaidykime į dalis:

$$\tilde{\mathbf{Q}} = \begin{bmatrix} \mathbf{Q}_{11} & \mathbf{Q}_{12} \\ \mathbf{Q}'_{12} & \mathbf{Q}_{22} \end{bmatrix}$$

Jei  $\mathbf{A}^{-1}$  pažymėsime viršutinį kairįjį matricos  $\tilde{\mathbf{Q}}^{-1}$   $(d+1) \times (d+1)$  bloką, tai, remiantis [10] taisykle 2b (sk. 9.11.3, p. 148), gauname:

$$\mathbf{A}^{-1} = (\mathbf{Q}_{11} - \mathbf{Q}_{12}\mathbf{Q}_{22}^{-1}\mathbf{Q}'_{12})^{-1}. \quad (\text{C.21})$$

Kadangi  $\mathbf{Q}$  yra teigiamai apibrėžta ir simetrinė, tai priede B pagrįsta, kad  $\mathbf{Q}_{22}$  ir  $\mathbf{Q}_{11} - \mathbf{Q}_{12}\mathbf{Q}_{22}^{-1}\mathbf{Q}'_{12}$  yra teigiamai apibrėžtos, taigi turi savo atvirkštines matricas. Matrica  $\mathbf{A}^{-1}$ , kaip teigiamai apibrėžtos ir simetrinės matricos  $\tilde{\mathbf{Q}}^{-1}$  blokas, taip pat yra teigiamai apibrėžta. Matrica  $\mathbf{A}^{-1}$  yra simetrinė, nes  $\mathbf{A} := (\mathbf{A}^{-1})^{-1}$  yra simetrinė.

Pasinaudodami  $\mathbf{D}_{f_0,\gamma}$  išskaidymu (C.17), gauname, kad  $(\mathbf{D}'_{f_0,\gamma}\tilde{\mathbf{Q}}\mathbf{D}_{f_0,\gamma})^{-1}$  yra tokia blokinė matrica:

$$(\mathbf{D}'_{f_0,\gamma}\tilde{\mathbf{Q}}\mathbf{D}_{f_0,\gamma})^{-1} = \left( \begin{bmatrix} \mathbf{D}'_{f,\gamma}\mathbf{Q}_{11}\mathbf{D}_{f,\gamma} & \mathbf{D}'_{f,\gamma}\mathbf{Q}_{12} \\ \mathbf{Q}'_{12}\mathbf{D}_{f,\gamma} & \mathbf{Q}_{22} \end{bmatrix} \right)^{-1}. \quad (\text{C.22})$$

Pagal tą pačią [10] taisyklę 2b, viršutinis kairysis  $(d+1) \times (d+1)$  šios matricos blokas  $\mathbf{A}_D$  yra:

$$\begin{aligned} \mathbf{A}_D &= (\mathbf{D}'_{f,\gamma}\mathbf{Q}_{11}\mathbf{D}_{f,\gamma} - \mathbf{D}'_{f,\gamma}\mathbf{Q}_{12}\mathbf{Q}_{22}^{-1}\mathbf{Q}'_{12}\mathbf{D}_{f,\gamma})^{-1} = \\ &= (\mathbf{D}'_{f,\gamma}(\mathbf{Q}_{11} - \mathbf{Q}_{12}\mathbf{Q}_{22}^{-1}\mathbf{Q}'_{12})\mathbf{D}_{f,\gamma})^{-1} = (\mathbf{D}'_{f,\gamma}\mathbf{A}\mathbf{D}_{f,\gamma})^{-1}. \end{aligned} \quad (\text{C.23})$$

Iš (C.23) ir (C.17), viršutinis kairysis matricos  $D_{\tilde{f}_0, \gamma} (D'_{\tilde{f}_0, \gamma} \tilde{Q} D_{\tilde{f}_0, \gamma})^{-1} D'_{\tilde{f}_0, \gamma}$  blokas yra  $D_{f, \gamma} (D'_{f, \gamma} A D_{f, \gamma})^{-1} D'_{f, \gamma}$ .

Išsivedę tokias lygybes ir pasinaudoję (C.20) bei tuom, kad  $\hat{\sigma}_u^2 \xrightarrow{p} \sigma_u^2$ ,<sup>24</sup> gauname ieškomą vektoriaus  $\sqrt{n_d}/\hat{\sigma}_u^2 (\hat{\beta}_{0,d} - f(\hat{\gamma}))$  asimptotiniį skirstinį:

$$\sqrt{n_d}/\hat{\sigma}_u^2 (\hat{\beta}_{0,d} - f(\hat{\gamma})) \xrightarrow{d} N \left( \mathbf{0}, A^{-1} - D_{f, \gamma} (D'_{f, \gamma} A D_{f, \gamma})^{-1} D'_{f, \gamma} \right). \quad (C.24)$$

Kadangi  $A$  yra teigiamai apibrėžta, pagal Cholesky dekompoziciją  $A$  galima išskaidyti:  $A = F_A F'_A$ . Iš (3.8) apibrėžimo imkime  $\hat{A}$ . Pastebėkime, kad  $\hat{A} \xrightarrow{p} A$ , nes:

$$\begin{aligned} \hat{A} &= n_d^{-1} (V'V - V'\Xi_0 (\Xi'_0 \Xi_0)^{-1} \Xi'_0 V) \\ &= n_d^{-1} V'V - n_d^{-1} V'\Xi_0 (n_d^{-1} \Xi'_0 \Xi_0)^{-1} n_d^{-1} \Xi'_0 V \xrightarrow{p} Q_{11} - Q_{12} Q_{22}^{-1} Q'_{12} = A. \end{aligned} \quad (C.25)$$

Iš (C.25) ir Cholesky dekompozicijos tolydumo,  $F_{\hat{A}} \xrightarrow{p} F_A$ . Todėl iš (C.24):

$$h_3 = \sqrt{n_d}/\hat{\sigma}_u^2 F'_A (\hat{\beta}_{0,d} - f(\hat{\gamma})) \xrightarrow{d} N(\mathbf{0}, \Sigma_{h_3}), \quad (C.26)$$

kur

$$\begin{aligned} \Sigma_{h_3} &= F'_A \left( A^{-1} - D_{f, \gamma} (D'_{f, \gamma} A D_{f, \gamma})^{-1} D'_{f, \gamma} \right) F_A \\ &= F'_A F_A^{-1} F_A - F'_A D_{f, \gamma} (D'_{f, \gamma} F_A F'_A D_{f, \gamma})^{-1} D'_{f, \gamma} F_A \\ &= I_{d+1} - F'_A D_{f, \gamma} (D'_{f, \gamma} F_A F'_A D_{f, \gamma})^{-1} D'_{f, \gamma} F_A. \end{aligned}$$

Nesunku pastebėti, kad  $\Sigma_{h_3}$  ir  $\hat{\Sigma}_{h_3}$  yra idempotentinės, taigi jų apibendrintos atvirkštinės matricos lygios joms pačioms. Be to,  $\text{rank}(\hat{\Sigma}_{h_3}) = \text{rank}(\Sigma_{h_3}) = d+1-r$ . Kadangi  $F_{\hat{A}} \xrightarrow{p} F_A$  ir  $D_{f, \hat{\gamma}} \xrightarrow{p} D_{f, \gamma}$ , tai, remiantis tolydaus atvaizdžio teorema,  $\hat{\Sigma}_{h_3} \xrightarrow{p} \Sigma_{h_3}$ . Dabar galima pasiremti [2] teorema 1, iš kur ir gauname, kad

$$T_3 = h'_3 \hat{\Sigma}_{h_3} h_3 \xrightarrow{d} \chi^2(d+1-r).$$

## $\tilde{H}_1$ atvejis

Likusioje įrodymo dalyje tegu galioja  $\tilde{H}_1$ . Nagrinėkime atsitiktinį dydį  $\hat{\sigma}_u^2 n_d^{-1} T_3$ .

$$\hat{\sigma}_u^2 n_d^{-1} T_3 = \hat{\sigma}_u n_d^{-1/2} h'_3 \hat{\Sigma}_{h_3} h_3 \hat{\sigma}_u n_d^{-1/2} = (\hat{\beta}_{0,d} - f(\hat{\gamma}))' F_{\hat{A}} \hat{\Sigma}_{h_3} F'_{\hat{A}} (\hat{\beta}_{0,d} - f(\hat{\gamma})). \quad (C.27)$$

Pažymėkime  $\gamma_0 := \text{plim} \hat{\gamma}$ . Remiantis prielaida N3,  $\gamma_0$  egzistuoja. Kadangi  $\hat{\beta}_{0,d} \xrightarrow{p} \beta_{0,d}$ , tai perėjus prie ribos abejose (C.27) pusėse gauname:

$$\text{plim} (\hat{\sigma}_u^2 n_d^{-1} T_3) = (\beta_{0,d} - f(\gamma_0))' \text{plim} (F_{\hat{A}} \hat{\Sigma}_{h_3} F'_{\hat{A}}) (\beta_{0,d} - f(\gamma_0)). \quad (C.28)$$

<sup>24</sup>Kaip ir priede A, iš  $\hat{\Gamma}$  suderinamumo išplaukia, kad  $\hat{\sigma}_u^2 \xrightarrow{p} \sigma_u^2$ .

Čia<sup>25</sup> pasinaudota tolydaus atvaizdžio teorema. Kadangi  $\mathbf{F}_{\hat{A}} \xrightarrow{p} \mathbf{F}_A$ , tai iš tolydaus atvaizdžio teoremos išplaukia:

$$\text{plim}(\mathbf{F}_{\hat{A}} \hat{\Sigma}_{h_3} \mathbf{F}_{\hat{A}}') = \mathbf{F}_A \text{plim}(\hat{\Sigma}_{h_3}) \mathbf{F}_A'.$$

Kadangi  $\gamma \xrightarrow{p} \gamma_0$  ir  $\mathbf{F}_{\hat{A}} \xrightarrow{p} \mathbf{F}_A$ , tai

$$\begin{aligned} \hat{\Sigma}_{h_3} &= \mathbf{I}_{d+1} - \mathbf{F}_{\hat{A}}' \mathbf{D}_{f, \hat{\gamma}} (\mathbf{D}_{f, \hat{\gamma}}' \hat{\mathbf{A}} \mathbf{D}_{f, \hat{\gamma}})^{-1} \mathbf{D}_{f, \hat{\gamma}}' \mathbf{F}_{\hat{A}} \\ &\xrightarrow{p} \mathbf{I}_{d+1} - \mathbf{F}_A' \mathbf{D}_{f, \gamma_0} (\mathbf{D}_{f, \gamma_0}' \mathbf{A} \mathbf{D}_{f, \gamma_0})^{-1} \mathbf{D}_{f, \gamma_0}' \mathbf{F}_A. \end{aligned} \quad (\text{C.29})$$

Pažymėkime

$$\Delta := \mathbf{D}_{f, \gamma_0} (\mathbf{D}_{f, \gamma_0}' \mathbf{A} \mathbf{D}_{f, \gamma_0})^{-1} \mathbf{D}_{f, \gamma_0}'.$$

Iš (C.28) ir (C.29) gauname:

$$\begin{aligned} \hat{\sigma}_u^2 n_d^{-1} T_3 &\xrightarrow{p} (\beta_{0,d} - \mathbf{f}(\gamma_0))' \mathbf{F}_A (\mathbf{I}_{d+1} - \mathbf{F}_A' \Delta \mathbf{F}_A) \mathbf{F}_A' (\beta_{0,d} - \mathbf{f}(\gamma_0)) \\ &= (\beta_{0,d} - \mathbf{f}(\gamma_0))' \mathbf{A} (\beta_{0,d} - \mathbf{f}(\gamma_0)) - (\beta_{0,d} - \mathbf{f}(\gamma_0))' \mathbf{A} \Delta \mathbf{A} (\beta_{0,d} - \mathbf{f}(\gamma_0)). \end{aligned} \quad (\text{C.30})$$

Pastebėkime, kad (C.30) rezultatas yra analogiškas priedo A rezultataui (A.50), jei vietoj  $\mathbf{Q}$  įsistatytume  $\mathbf{A}$ . Galima tikėtis, kad ir šiuo atveju  $(\beta_{0,d} - \mathbf{f}(\gamma_0))' \mathbf{A} \Delta \mathbf{A} (\beta_{0,d} - \mathbf{f}(\gamma_0)) = 0$ , kas toliau ir bus parodyta. Iš NMKM įvertinių būtinosios sąlygos (3.7) lygybių įvertiniams  $\hat{\psi}_1 = (\hat{\beta}_d^{nls}, \hat{\eta}_1^{nls})'$ :

$$\tilde{\mathbf{X}}'(\mathbf{y} - \mathbf{V} \mathbf{f}(\hat{\gamma}) - \Xi_0 \hat{\eta}_0^{nls} - \mathbf{1} \hat{\alpha}^{nls} - \tilde{\mathbf{X}} \hat{\psi}_1) = 0, \quad (\text{C.31})$$

I (C.31) įsistatę  $\mathbf{y}$  išraišką  $\mathbf{y} = \mathbf{V} \beta_{0,d} + \Xi_0 \eta_0 + \mathbf{1} \alpha + \tilde{\mathbf{X}} \psi_1 + \mathbf{u}$ , turime tokią lygybę:

$$\begin{aligned} n_d^{-2} \tilde{\mathbf{X}}' \tilde{\mathbf{X}} (\hat{\psi}_1 - \psi_1) &= n_d^{-2} \tilde{\mathbf{X}}' \mathbf{V} (\beta_{0,d} - \mathbf{f}(\hat{\gamma})) + n_d^{-2} \tilde{\mathbf{X}}' \Xi_0 (\eta_0 - \hat{\eta}_0^{nls}) \\ &\quad + n_d^{-2} \tilde{\mathbf{X}}' \mathbf{1} (\alpha - \hat{\alpha}^{nls}) + n_d^{-2} \tilde{\mathbf{X}}' \mathbf{u}. \end{aligned} \quad (\text{C.32})$$

Dešinioji (C.32) lygybės pusė pagal tikimybę artėja į nulį. Kadangi  $n_d^{-2} \tilde{\mathbf{X}}' \tilde{\mathbf{X}}$  yra  $\mathbf{O}_p(1)$  ir nėra  $\mathbf{o}_p(1)$ , tai, kad (C.32) galiojūt ir riboje, būtina, kad  $\hat{\psi}_1 \xrightarrow{p} \psi_1$ . Taigi įvertiniai prie integruotų kintamųjų yra suderinti ir  $\tilde{H}_1$  atveju. Iš NMKM įvertinių būtinosios sąlygos (3.7) tų eilučių, kurios atitinka įvertininius  $\hat{\eta}_0^{nls}$  panašiai išsivedame tokią lygybę:

$$\begin{aligned} n_d^{-1} \Xi_0' \Xi_0 (\hat{\eta}_0^{nls} - \eta_0) &= n_d^{-1} \Xi_0' \mathbf{V} (\beta_{0,d} - \mathbf{f}(\hat{\gamma})) + n_d^{-1} \Xi_0' \mathbf{1} (\alpha - \hat{\alpha}^{nls}) + \\ &\quad + n_d^{-1} \Xi_0' \tilde{\mathbf{X}} (\psi_1 - \hat{\psi}_1) + n_d^{-1} \Xi_0' \mathbf{u}. \end{aligned} \quad (\text{C.33})$$

Kadangi  $\hat{\psi}_1 \xrightarrow{p} \psi_1$ ,  $\Xi_0' \tilde{\mathbf{X}} = \mathbf{O}_p(n_d)$ ,  $\Xi_0' \mathbf{1} = \mathbf{O}_p(n_d^{1/2})$  ir  $\Xi_0' \mathbf{u} = \mathbf{O}_p(n_d^{1/2})$ , tai dešinioji (C.33)

<sup>25</sup> Čia reikia pakomentuoti. Teiginio 2.2 įrodyme buvo eita ilgesniu keliu ir ieškoma  $\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})$  išraiškos per modelio kintamuosius ir galų gale gautas rezultatas, kuris galėjo būti gautas žymiai greičiau. Nors pradinis šio įrodymo variantas buvo parašytas analogiškai kaip ir 2.2 teiginio  $\tilde{H}_1$  dalis, pastebėjus galimą trumpesnę variantą, jis ir pasirinktas. Tas pats nebuvo padaryta teiginio 2.2 įrodyme, nes tada išsitrintų rezultatas, kad  $T_1$  išraiškoje yra  $\mathbf{O}_p(n_d^{1/2})$  narys. Šis faktas reikalingas 4 skyriuje, komentuojant empirinius rezultatus.

lygybės pusė pagal tikimybę artėja į  $\mathbf{Q}'_{12}(\beta_{0,d} - \mathbf{f}(\gamma_0))$ . Kadangi  $n_d^{-1}\Xi'_0\Xi_0 \xrightarrow{p} \mathbf{Q}_{22}$ , tai:

$$\text{plim}(\hat{\boldsymbol{\eta}}_0^{nls}) - \boldsymbol{\eta}_0 = \mathbf{Q}_{22}^{-1}\mathbf{Q}'_{12}(\beta_{0,d} - \mathbf{f}(\gamma_0)). \quad (\text{C.34})$$

Taigi papildomų stacionarių kintamųjų įvertiniai  $\hat{\boldsymbol{\eta}}_0^{nls}$  neteisingos apribojimo funkcijos atveju yra nesuderinti, jei  $\mathbf{Q}_{22}^{-1}\mathbf{Q}'_{12}(\beta_{0,d} - \mathbf{f}(\gamma_0)) \neq \mathbf{0}$ . Iš NMKM įvertinių būtinosios sąlygos (3.7) pirmųjų  $d + 1$  lygybių:

$$\begin{aligned} n_d^{-1}\mathbf{D}'_{f,\hat{\gamma}}\mathbf{V}'\mathbf{V}(\mathbf{f}(\hat{\gamma}) - \beta_{0,d}) &= n_d^{-1}\mathbf{D}'_{f,\hat{\gamma}}\mathbf{V}'\Xi_0(\boldsymbol{\eta}_0 - \hat{\boldsymbol{\eta}}_0^{nls}) + \\ &+ n_d^{-1}\mathbf{D}'_{f,\hat{\gamma}}\mathbf{V}'\mathbf{1}(\alpha - \hat{\alpha}^{nls}) + n_d^{-1}\mathbf{D}'_{f,\hat{\gamma}}\mathbf{V}'\Xi_1(\boldsymbol{\psi}_1 - \hat{\boldsymbol{\psi}}_1^{nls}) + n_d^{-1}\mathbf{D}'_{f,\hat{\gamma}}\mathbf{V}'\mathbf{u}. \end{aligned} \quad (\text{C.35})$$

Abiejose (C.35) pusėse perėję prie ribos pagal tikimybę ir pasinaudoję (C.34), gauname:

$$\begin{aligned} \mathbf{D}'_{f,\gamma_0}\mathbf{Q}_{11}(\beta_{0,d} - \mathbf{f}(\gamma_0)) &= \mathbf{D}'_{f,\gamma_0}\mathbf{Q}_{12}(\text{plim}(\hat{\boldsymbol{\eta}}_0^{nls}) - \boldsymbol{\eta}_0) \\ &= \mathbf{D}'_{f,\gamma_0}\mathbf{Q}_{12}\mathbf{Q}_{22}^{-1}\mathbf{Q}'_{12}(\beta_{0,d} - \mathbf{f}(\gamma_0)). \end{aligned} \quad (\text{C.36})$$

Priminsime, kad  $\mathbf{A} = \mathbf{Q}_{11} - \mathbf{Q}_{12}\mathbf{Q}_{22}^{-1}\mathbf{Q}'_{12}$ . Iš (C.36) gauname sąlygą, kurią turi tenkinti  $\gamma_0$ :

$$\mathbf{D}'_{f,\gamma_0}\mathbf{A}(\beta_{0,d} - \mathbf{f}(\gamma_0)) = \mathbf{0}.$$

Kadangi  $\boldsymbol{\Delta} = \mathbf{D}_{f,\gamma_0}(\mathbf{D}'_{f,\gamma_0}\mathbf{A}\mathbf{D}_{f,\gamma_0})^{-1}\mathbf{D}'_{f,\gamma_0}$ , tai

$$(\beta_{0,d} - \mathbf{f}(\gamma_0))'\mathbf{A}\boldsymbol{\Delta}\mathbf{A}(\beta_{0,d} - \mathbf{f}(\gamma_0)) = 0.$$

Todėl iš (C.30) gauname:

$$\hat{\sigma}_u^2 n_d^{-1}T_3 \xrightarrow{p} (\beta_{0,d} - \mathbf{f}(\gamma_0))'\mathbf{A}(\beta_{0,d} - \mathbf{f}(\gamma_0)).$$

Kadangi  $\mathbf{A}$  yra teigiamai apibrėžta, tai  $\hat{\sigma}_u^2 n_d^{-1}T_3$  pagal tikimybę artėja į teigiamą skaičių. Dėl to  $T_3 \xrightarrow{p} \infty$ , kai  $n_d \rightarrow \infty$ . □

## D Teiginio 3.2 įrodymas

Iš statistikos  $T_4$  apibrėžimo (3.12) gauname:

$$T_4 = n_d/\hat{\sigma}_u^2 \left( (\hat{\beta}'_{0,d}, \hat{\boldsymbol{\eta}}'_0)' - \mathbf{f}_0(\hat{\boldsymbol{\psi}}_0) \right)' \mathbf{F}_{\tilde{\mathbf{V}}} \hat{\boldsymbol{\Sigma}}_{h_4} \mathbf{F}'_{\tilde{\mathbf{V}}} \left( (\hat{\beta}'_{0,d}, \hat{\boldsymbol{\eta}}'_0)' - \mathbf{f}_0(\hat{\boldsymbol{\psi}}_0) \right).$$

Kadangi  $\mathbf{F}_{\tilde{\mathbf{V}}}\mathbf{F}'_{\tilde{\mathbf{V}}} = n_d^{-1}\tilde{\mathbf{V}}'\tilde{\mathbf{V}}$ , tai iš  $\hat{\boldsymbol{\Sigma}}_{h_4}$  apibrėžimo (3.11),  $\mathbf{F}_{\tilde{\mathbf{V}}}\hat{\boldsymbol{\Sigma}}_{h_4}\mathbf{F}'_{\tilde{\mathbf{V}}}$  yra dviejų matricių skirtumas:

$$\mathbf{F}_{\tilde{\mathbf{V}}}\hat{\boldsymbol{\Sigma}}_{h_4}\mathbf{F}'_{\tilde{\mathbf{V}}} = n_d^{-1}\tilde{\mathbf{V}}'\tilde{\mathbf{V}} - n_d^{-1}\tilde{\mathbf{V}}'\tilde{\mathbf{V}}\mathbf{D}_{f_0,\hat{\gamma}}(\mathbf{D}'_{f_0,\hat{\gamma}}n_d^{-1}\tilde{\mathbf{V}}'\tilde{\mathbf{V}}\mathbf{D}_{f_0,\hat{\gamma}})^{-1}\mathbf{D}'_{f_0,\hat{\gamma}}n_d^{-1}\tilde{\mathbf{V}}'\tilde{\mathbf{V}}. \quad (\text{D.1})$$

Pagal išdėstymą  $\tilde{\mathbf{V}} = \begin{bmatrix} \mathbf{V} & \mathbf{\Xi}_0 \end{bmatrix}$ , išskaidykime matricas  $n_d^{-1}\tilde{\mathbf{V}}'\tilde{\mathbf{V}}$  ir  $\mathbf{D}_{f_0,\hat{\gamma}}$ :

$$n_d^{-1}\tilde{\mathbf{V}}'\tilde{\mathbf{V}} = \begin{bmatrix} n_d^{-1}\mathbf{V}'\mathbf{V} & n_d^{-1}\mathbf{V}'\mathbf{\Xi}_0 \\ n_d^{-1}\mathbf{\Xi}_0'\mathbf{V} & n_d^{-1}\mathbf{\Xi}_0'\mathbf{\Xi}_0 \end{bmatrix} =: \begin{bmatrix} \mathbf{V}_{11} & \mathbf{V}_{12} \\ \mathbf{V}_{12}' & \mathbf{V}_{22} \end{bmatrix}, \quad \mathbf{D}_{f_0,\hat{\gamma}} = \begin{bmatrix} \mathbf{D} & \mathbf{0} \\ \mathbf{0} & \mathbf{I}_{d_0} \end{bmatrix},$$

kur  $\mathbf{D} := \mathbf{D}_{f,\hat{\gamma}}$ .

Parodysime, kad matricos  $\mathbf{F}_{\tilde{\mathbf{V}}}\hat{\Sigma}_{h_4}\mathbf{F}_{\tilde{\mathbf{V}}}'$  visi blokai, išskyrus viršutinį kairįjį, lygūs nuliui. Matrica  $(\mathbf{D}_{f_0,\hat{\gamma}}'n_d^{-1}\tilde{\mathbf{V}}'\tilde{\mathbf{V}}\mathbf{D}_{f_0,\hat{\gamma}})^{-1}$  susideda iš keturių blokų:

$$(\mathbf{D}_{f_0,\hat{\gamma}}'n_d^{-1}\tilde{\mathbf{V}}'\tilde{\mathbf{V}}\mathbf{D}_{f_0,\hat{\gamma}})^{-1} = \begin{bmatrix} \mathbf{D}'\mathbf{V}_{11}\mathbf{D} & \mathbf{D}'\mathbf{V}_{12} \\ \mathbf{V}_{12}'\mathbf{D} & \mathbf{V}_{22} \end{bmatrix}^{-1} =: \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}' & \mathbf{A}_{22} \end{bmatrix}.$$

Iš [10] atvirkštinės blokinės matricos skaičiavimo taisyklės 2b (sk. 9.11.3, p. 148) gauname:

$$\mathbf{A}_{11} = (\mathbf{D}'\mathbf{V}_{11}\mathbf{D} - \mathbf{D}'\mathbf{V}_{12}\mathbf{V}_{22}^{-1}\mathbf{V}_{12}'\mathbf{D})^{-1}, \quad (\text{D.2})$$

$$\mathbf{A}_{12} = -\mathbf{A}_{11}\mathbf{D}'\mathbf{V}_{12}\mathbf{V}_{22}^{-1}, \quad (\text{D.3})$$

$$\mathbf{A}_{22} = \mathbf{V}_{22}^{-1} + \mathbf{V}_{22}^{-1}\mathbf{V}_{12}'\mathbf{D}\mathbf{A}_{11}\mathbf{D}'\mathbf{V}_{12}\mathbf{V}_{22}^{-1}. \quad (\text{D.4})$$

Kadangi  $\mathbf{D}_{f_0,\hat{\gamma}}'n_d^{-1}\tilde{\mathbf{V}}'\tilde{\mathbf{V}}\mathbf{D}_{f_0,\hat{\gamma}}$  yra simetrinė ir teigiamai apibrėžta, tai, kaip pagrįsta priede B, matricos  $\mathbf{V}_{22}$  ir  $\mathbf{D}'\mathbf{V}_{11}\mathbf{D} - \mathbf{D}'\mathbf{V}_{12}\mathbf{V}_{22}^{-1}\mathbf{V}_{12}'\mathbf{D}$  turi atvirkštinės matricas. Lygybėje (D.1) gauto matricų skirtumo antrąją matricą pažymėkime  $\mathbf{C}$  ir išskaidykime ją:

$$\mathbf{C} =: \begin{bmatrix} \mathbf{C}_{11} & \mathbf{C}_{12} \\ \mathbf{C}_{12}' & \mathbf{C}_{22} \end{bmatrix}.$$

Reikia parodyti, kad  $\mathbf{C}_{12} = \mathbf{V}_{12}$  ir  $\mathbf{C}_{22} = \mathbf{V}_{22}$ .

Pradėkime nuo lygybės  $\mathbf{C}_{22} = \mathbf{V}_{22}$  įrodymo. Po paprastų blokinių matricų sandaugos veiksmų, pasinaudojant (D.2), (D.3) ir (D.4), gauta, kad  $\mathbf{C}_{22} = \mathbf{C}_{22,1} + \mathbf{C}_{22,2} + \mathbf{C}_{22,3} + \mathbf{C}_{22,4}$ , kur

$$\begin{aligned} \mathbf{C}_{22,1} &:= \mathbf{V}_{12}'\mathbf{D}\mathbf{A}_{11}\mathbf{D}'\mathbf{V}_{12}, & \mathbf{C}_{22,2} &:= -\mathbf{V}_{12}'\mathbf{D}\mathbf{A}_{11}\mathbf{D}'\mathbf{V}_{12}, \\ \mathbf{C}_{22,3} &:= -\mathbf{V}_{12}'\mathbf{D}\mathbf{A}_{11}\mathbf{D}'\mathbf{V}_{12}, & \mathbf{C}_{22,4} &:= \mathbf{V}_{22} + \mathbf{V}_{12}'\mathbf{D}\mathbf{A}_{11}\mathbf{D}'\mathbf{V}_{12}. \end{aligned}$$

Galima matyti, kad  $\mathbf{C}_{22} = \mathbf{V}_{22}$ .

Parodykime, kad  $\mathbf{C}_{12} = \mathbf{V}_{12}$ . Po paprastų blokinių matricų sandaugos veiksmų gauta, kad  $\mathbf{C}_{12} = \mathbf{C}_{12,1} + \mathbf{C}_{12,2} + \mathbf{C}_{12,3} + \mathbf{C}_{12,4}$ , kur

$$\begin{aligned} \mathbf{C}_{12,1} &:= \mathbf{V}_{11}\mathbf{D}\mathbf{A}_{11}\mathbf{D}'\mathbf{V}_{12}, & \mathbf{C}_{12,2} &:= -\mathbf{V}_{12}\mathbf{V}_{22}^{-1}\mathbf{V}_{12}'\mathbf{D}\mathbf{A}_{11}\mathbf{D}'\mathbf{V}_{12}, \\ \mathbf{C}_{12,3} &:= -\mathbf{V}_{11}\mathbf{D}\mathbf{A}_{11}\mathbf{D}'\mathbf{V}_{12}, & \mathbf{C}_{12,4} &:= \mathbf{V}_{12} + \mathbf{V}_{12}\mathbf{V}_{22}^{-1}\mathbf{V}_{12}'\mathbf{D}\mathbf{A}_{11}\mathbf{D}'\mathbf{V}_{12}. \end{aligned}$$

$\mathbf{C}_{12,1} + \mathbf{C}_{12,3} = \mathbf{0}$ ,  $\mathbf{C}_{12,2} + \mathbf{C}_{12,4} = \mathbf{V}_{12}$ . Taigi  $\mathbf{C}_{12} = \mathbf{V}_{12}$ .

Kadangi  $\mathbf{C}_{22} = \mathbf{V}_{22}$  ir  $\mathbf{C}_{12} = \mathbf{V}_{12}$ , tai iš (D.1) išplaukia, kad matricos  $\mathbf{F}_{\tilde{\mathbf{V}}}\hat{\Sigma}_{h_4}\mathbf{F}_{\tilde{\mathbf{V}}}'$  visi nariai,

išskyrus viršutinį kairįjį bloką, lygūs nuliui. Tą nesunku patikrinti empiriškai. Vadinasi, iš tikrųjų įvertiniai prie papildomų stacionarių kintamųjų į statistiką  $T_4$  neįeina, kas nėra akivaizdu ją apibrėžiant. Taigi,

$$T_4 = n_d / \hat{\sigma}_u^2 (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))' (\mathbf{V}_{11} - \mathbf{C}_{11}) (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})). \quad (\text{D.5})$$

Iš statistikos  $T_3$  apibrėžimo (3.10) turime:

$$T_3 = n_d / \hat{\sigma}_u^2 (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))' \mathbf{F}_{\hat{A}} \hat{\Sigma}_{h_3} \mathbf{F}_{\hat{A}}' (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})). \quad (\text{D.6})$$

Taigi reikia parodyti, kad  $\mathbf{F}_{\hat{A}} \hat{\Sigma}_{h_3} \mathbf{F}_{\hat{A}}' = \mathbf{V}_{11} - \mathbf{C}_{11}$ .

Raskime, kam lygus matricos  $\mathbf{C}$  viršutinis kairysis blokas  $\mathbf{C}_{11}$ . Po keleto algebrinių veiksmų gauta, kad  $\mathbf{C}_{11} = \mathbf{C}_{11,1} + \mathbf{C}_{11,2} + \mathbf{C}_{11,3} + \mathbf{C}_{11,4}$ , kur

$$\begin{aligned} \mathbf{C}_{11,1} &:= \mathbf{V}_{11} \mathbf{D} \mathbf{A}_{11} \mathbf{D}' \mathbf{V}_{11}, \\ \mathbf{C}_{11,2} &:= -\mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}' \mathbf{D} \mathbf{A}_{11} \mathbf{D}' \mathbf{V}_{11}, \\ \mathbf{C}_{11,3} &:= -\mathbf{V}_{11} \mathbf{D} \mathbf{A}_{11} \mathbf{D}' \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}', \\ \mathbf{C}_{11,4} &:= \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}' + \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}' \mathbf{D} \mathbf{A}_{11} \mathbf{D}' \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}'. \end{aligned}$$

Pažymėkime  $\Delta := \mathbf{D} \mathbf{A}_{11} \mathbf{D}'$ . Iš  $\hat{\mathbf{A}}$  apibrėžimo (3.8),  $\hat{\mathbf{A}} = \mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}'$ . Tada

$$\begin{aligned} \mathbf{C}_{11} &= (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') \Delta \mathbf{V}_{11} - (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') \Delta \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}' + \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}' \\ &= (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') \Delta (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') + \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}' \\ &= \hat{\mathbf{A}} \Delta \hat{\mathbf{A}} + \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}'. \end{aligned} \quad (\text{D.7})$$

Taigi,

$$\mathbf{V}_{11} - \mathbf{C}_{11} = \hat{\mathbf{A}} - \hat{\mathbf{A}} \Delta \hat{\mathbf{A}}. \quad (\text{D.8})$$

Liko parodyti, kad  $\mathbf{F}_{\hat{A}} \hat{\Sigma}_{h_3} \mathbf{F}_{\hat{A}}' = \hat{\mathbf{A}} - \hat{\mathbf{A}} \Delta \hat{\mathbf{A}}$ . Pastebėkime, kad iš (D.2):

$$\mathbf{A}_{11} = \left( \mathbf{D}' (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') \mathbf{D} \right)^{-1} = (\mathbf{D}' \hat{\mathbf{A}} \mathbf{D})^{-1}.$$

Todėl  $\Delta = \mathbf{D} (\mathbf{D}' \hat{\mathbf{A}} \mathbf{D})^{-1} \mathbf{D}'$ . Taigi

$$\hat{\mathbf{A}} - \hat{\mathbf{A}} \Delta \hat{\mathbf{A}} = \hat{\mathbf{A}} - \hat{\mathbf{A}} \mathbf{D} (\mathbf{D}' \hat{\mathbf{A}} \mathbf{D})^{-1} \mathbf{D}' \hat{\mathbf{A}} = \mathbf{F}_{\hat{A}} \hat{\Sigma}_{h_3} \mathbf{F}_{\hat{A}}', \quad (\text{D.9})$$

kur paskutinė lygybė gauta pasinaudojant  $\hat{\Sigma}_{h_3}$  apibrėžimu (3.9). Iš (D.5), (D.6), (D.8) ir (D.9) lygybių gauname, kad  $T_4 = T_3$ . □



## E Teiginio 3.3 įrodymas

Šis įrodymas panašus į teiginio 3.2 įrodymą. Lygiai taip pat parodoma, kad matrica, iš kurios padauginami įverčiai, susideda iš keturių blokų, iš kurių trys yra nulinės matricos. Tačiau, skirtingai nei statistikos  $T_4$  atveju,  $T_5 \neq T_3$ .

$$T_5 = n_d / \hat{\sigma}_u^2 (\hat{\Gamma} - \tilde{\mathbf{f}}(\hat{\psi}))' \mathbf{F}_{\tilde{\mathbf{Z}}} \hat{\Sigma}_{h_5} \mathbf{F}_{\tilde{\mathbf{Z}}} (\hat{\Gamma} - \tilde{\mathbf{f}}(\hat{\psi})).$$

Matrica  $\mathbf{F}_{\tilde{\mathbf{Z}}} \hat{\Sigma}_{h_5} \mathbf{F}_{\tilde{\mathbf{Z}}}'$  yra tokia:

$$\mathbf{F}_{\tilde{\mathbf{Z}}} \hat{\Sigma}_{h_5} \mathbf{F}_{\tilde{\mathbf{Z}}} = n_d^{-1} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} - n_d^{-1} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{D}_{\tilde{\mathbf{f}}, \hat{\gamma}} ( \mathbf{D}_{\tilde{\mathbf{f}}, \hat{\gamma}}' n_d^{-1} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} \mathbf{D}_{\tilde{\mathbf{f}}, \hat{\gamma}} )^{-1} \mathbf{D}_{\tilde{\mathbf{f}}, \hat{\gamma}}' n_d^{-1} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}}. \quad (\text{E.1})$$

Išskaidykime matricą  $\tilde{\mathbf{Z}}$  taip:  $\tilde{\mathbf{Z}} = \begin{bmatrix} \mathbf{V} & \Xi_{0,1} \end{bmatrix}$ , kur  $\Xi_{0,1} := \begin{bmatrix} \Xi_0 & \mathbf{1} & \mathbf{X} & \Xi_1 \end{bmatrix}$  yra visi likę duomenys be  $\mathbf{V}$ . Pagal šį išskaidymą matricas  $n_d^{-1} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}}$  ir  $\mathbf{F}_{\tilde{\mathbf{Z}}} \hat{\Sigma}_{h_5} \mathbf{F}_{\tilde{\mathbf{Z}}}'$  sudaro keturi blokai:

$$n_d^{-1} \tilde{\mathbf{Z}}' \tilde{\mathbf{Z}} = \begin{bmatrix} n_d^{-1} \mathbf{V}' \mathbf{V} & n_d^{-1} \mathbf{V}' \Xi_{0,1} \\ n_d^{-1} \Xi_{0,1}' \mathbf{V} & n_d^{-1} \Xi_{0,1}' \Xi_{0,1} \end{bmatrix} =: \begin{bmatrix} \mathbf{V}_{11} & \mathbf{V}_{12} \\ \mathbf{V}_{12}' & \mathbf{V}_{22} \end{bmatrix}, \quad \mathbf{F}_{\tilde{\mathbf{Z}}} \hat{\Sigma}_{h_5} \mathbf{F}_{\tilde{\mathbf{Z}}} =: \begin{bmatrix} \mathbf{G}_{11} & \mathbf{G}_{12} \\ \mathbf{G}_{12}' & \mathbf{G}_{22} \end{bmatrix}. \quad (\text{E.2})$$

Jakobianas  $\mathbf{D}_{\tilde{\mathbf{f}}, \hat{\gamma}}$  pagal savo apibrėžimą (3.5) yra:

$$\mathbf{D}_{\tilde{\mathbf{f}}, \hat{\gamma}} = \begin{bmatrix} \mathbf{D} & \mathbf{0} \\ \mathbf{0} & \mathbf{I}_{d_0+d_1+2} \end{bmatrix},$$

kur  $\mathbf{D} := \mathbf{D}_{\mathbf{f}, \hat{\gamma}}$ . Čia reikia pastebėti, kad teiginio 3.2 įrodyme priede D lygiai taip pat išskaidyta matrica  $\mathbf{F}_{\tilde{\mathbf{V}}} \hat{\Sigma}_{h_4} \mathbf{F}_{\tilde{\mathbf{V}}}'$  ir gauta, kad visi jos blokai, išskyrus kairįjį viršutinį, lygūs nuliui. Kadangi ir  $\mathbf{D}_{\tilde{\mathbf{f}}, \hat{\gamma}}$  yra tos pačios struktūros kaip ir  $\mathbf{D}_{\mathbf{f}, \hat{\gamma}}$ , tai, nenorint perrašinėti to paties, galima pasiremti priede D pateiktu išvedimu ir teigti, kad  $\mathbf{G}_{12} = \mathbf{0}$ ,  $\mathbf{G}_{22} = \mathbf{0}$ . Taigi,

$$T_5 = n_d / \hat{\sigma}_u^2 (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))' \mathbf{G}_{11} (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})). \quad (\text{E.3})$$

Raskime, kam lygi matrica  $\mathbf{G}_{11}$ . Skirtumo (E.1) antrąją matricą pažymėjus  $\mathbf{C}$ , jos kairysis viršutinis blokas  $\mathbf{C}_{11}$ , pagal (D.7) antrąją lygybę, yra:

$$\mathbf{C}_{11} = (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') \mathbf{D} \mathbf{A}_{11} \mathbf{D}' (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') + \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}', \quad (\text{E.4})$$

kur iš (D.2):

$$\mathbf{A}_{11} = \left( \mathbf{D}' \mathbf{V}_{11} \mathbf{D} - \mathbf{D}' \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}' \mathbf{D} \right)^{-1} = \left( \mathbf{D}' (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') \mathbf{D} \right)^{-1}. \quad (\text{E.5})$$

Iš (E.1) ir (E.4) gauname, kad

$$\mathbf{G}_{11} = (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') - (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') \mathbf{D} \mathbf{A}_{11} \mathbf{D}' (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}'). \quad (\text{E.6})$$

Statistika  $T_3$  iš (D.6) ir (D.9) yra:

$$T_3 = n_d / \hat{\sigma}_u^2 (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))' \mathbf{H}_{11} (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})), \text{ kur} \quad (\text{E.7})$$

$$\mathbf{H}_{11} := \hat{\mathbf{A}} - \hat{\mathbf{A}} \mathbf{D} (\mathbf{D}' \hat{\mathbf{A}} \mathbf{D})^{-1} \mathbf{D}' \hat{\mathbf{A}}. \quad (\text{E.8})$$

Taigi iš (E.3) ir (E.7),  $T_5 - T_3$  yra:

$$T_5 - T_3 = n_d / \hat{\sigma}_u^2 (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))' (\mathbf{G}_{11} - \mathbf{H}_{11}) (\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})). \quad (\text{E.9})$$

Parodysime, kad  $\mathbf{G}_{11} - \mathbf{H}_{11} \xrightarrow{p} \mathbf{0}$ . Iš (E.5), (E.6) ir (E.8) galima matyti, kad užtenka parodyti, kad  $\hat{\mathbf{A}} - (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') \xrightarrow{p} \mathbf{0}$ . Iš  $\mathbf{V}_{11}$ ,  $\mathbf{V}_{12}$  ir  $\mathbf{V}_{22}$  apibrėžimo (E.2) bei  $\hat{\mathbf{A}}$  apibrėžimo (3.8):

$$\begin{aligned} \hat{\mathbf{A}} - (\mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{12}') &= n_d^{-1} \mathbf{V}' \Xi_{0,1} (n_d^{-1} \Xi_{0,1}' \Xi_{0,1})^{-1} n_d^{-1} \Xi_{0,1}' \mathbf{V} - \\ &\quad - n_d^{-1} \mathbf{V}' \Xi_0 (n_d^{-1} \Xi_0' \Xi_0)^{-1} n_d^{-1} \Xi_0' \mathbf{V}. \end{aligned} \quad (\text{E.10})$$

Apibrėžkime tokią normavimo matricą  $\mathbf{L}$ :

$$\mathbf{L} := \begin{bmatrix} \mathbf{I}_{d_0} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & 1 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & n_d^{1/2} \mathbf{I}_{d_1+1} \end{bmatrix}.$$

Tada (E.10) skirtumo pirmas narys yra:

$$\begin{aligned} n_d^{-1} \mathbf{V}' \Xi_{0,1} (n_d^{-1} \Xi_{0,1}' \Xi_{0,1})^{-1} n_d^{-1} \Xi_{0,1}' \mathbf{V} &= \\ &= n_d^{-1} \mathbf{V}' \Xi_{0,1} \mathbf{L}^{-1} \mathbf{L} (n_d^{-1} \Xi_{0,1}' \Xi_{0,1})^{-1} \mathbf{L} \mathbf{L}^{-1} n_d^{-1} \Xi_{0,1}' \mathbf{V} \\ &= n_d^{-1} \mathbf{V}' \Xi_{0,1} \mathbf{L}^{-1} (\mathbf{L}^{-1} n_d^{-1} \Xi_{0,1}' \Xi_{0,1} \mathbf{L}^{-1})^{-1} \mathbf{L}^{-1} n_d^{-1} \Xi_{0,1}' \mathbf{V}. \end{aligned} \quad (\text{E.11})$$

$n_d^{-1} \mathbf{V}' \Xi_{0,1} \mathbf{L}^{-1}$  išsiskaido į tris dalis:

$$n_d^{-1} \mathbf{V}' \Xi_{0,1} \mathbf{L}^{-1} = \begin{bmatrix} n_d^{-1} \mathbf{V}' \Xi_0 & n_d^{-1} \mathbf{V}' \mathbf{1} & n_d^{-3/2} \mathbf{V}' \tilde{\mathbf{X}} \end{bmatrix} \xrightarrow{p} \begin{bmatrix} \mathbf{Q}_{12} & \mathbf{0} & \mathbf{0} \end{bmatrix}. \quad (\text{E.12})$$

Čia pasinaudota teiginio 3.1 įrodyme gautais rezultatais, kad  $\mathbf{V}' \mathbf{1} = \mathbf{O}_p(n_d^{1/2})$ ,  $\mathbf{V}' \tilde{\mathbf{X}} = \mathbf{O}_p(n_d)$  ir pažymėjimais

$$\begin{bmatrix} \mathbf{Q}_{11} & \mathbf{Q}_{12} \\ \mathbf{Q}_{12}' & \mathbf{Q}_{22} \end{bmatrix} := \text{plim} \begin{bmatrix} n_d^{-1} \mathbf{V}' \mathbf{V} & n_d^{-1} \mathbf{V}' \Xi_0 \\ n_d^{-1} \Xi_0' \mathbf{V} & n_d^{-1} \Xi_0' \Xi_0 \end{bmatrix}, \quad \tilde{\mathbf{X}} := \begin{bmatrix} \mathbf{X} & \Xi_1 \end{bmatrix}.$$

Matricai  $(\mathbf{L}^{-1}n_d^{-1}\Xi'_{0,1}\Xi_{0,1}\mathbf{L}^{-1})^{-1}$  gauname:

$$\begin{aligned}
(\mathbf{L}^{-1}n_d^{-1}\Xi'_{0,1}\Xi_{0,1}\mathbf{L}^{-1})^{-1} &= \begin{bmatrix} n_d^{-1}\Xi'_0\Xi_0 & n_d^{-1}\Xi'_0\mathbf{1} & n_d^{-3/2}\Xi'_0\tilde{\mathbf{X}} \\ n_d^{-1}\mathbf{1}'\Xi_0 & 1 & n_d^{-3/2}\mathbf{1}'\tilde{\mathbf{X}} \\ n_d^{-3/2}\tilde{\mathbf{X}}'\Xi_0 & n_d^{-3/2}\tilde{\mathbf{X}}'\mathbf{1} & n_d^{-2}\tilde{\mathbf{X}}'\tilde{\mathbf{X}} \end{bmatrix}^{-1} \xrightarrow{p} \\
&\xrightarrow{p} \begin{bmatrix} \mathbf{Q}_{22}^{-1} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \begin{bmatrix} 1 & \text{dlim}(n_d^{-3/2}\mathbf{1}'\tilde{\mathbf{X}}) \\ \text{dlim}(n_d^{-3/2}\tilde{\mathbf{X}}'\mathbf{1}) & \text{dlim}(\tilde{\mathbf{X}}'\tilde{\mathbf{X}}) \end{bmatrix}^{-1} \end{bmatrix}. \quad (\text{E.13})
\end{aligned}$$

Čia pasinaudota tuom, kad  $\tilde{\mathbf{X}}'\tilde{\mathbf{X}} = \mathbf{O}_p(n_d^2)$ ,  $\tilde{\mathbf{X}}'\mathbf{1} = \mathbf{O}_p(n_d^{3/2})$ . Kaip pagrįsta priede C, iš prielaidų N4 ir N5 išplaukia, kad (E.13) riboje visos atvirkštinės matricos egzistuoja. Taigi iš (E.11), (E.12) ir (E.13) gauname, kad

$$n_d^{-1}\mathbf{V}'\Xi_{0,1}(n_d^{-1}\Xi'_{0,1}\Xi_{0,1})^{-1}n_d^{-1}\Xi'_{0,1}\mathbf{V} \xrightarrow{p} \mathbf{Q}_{12}\mathbf{Q}_{22}^{-1}\mathbf{Q}'_{12}.$$

Antrai skirtumo E.10 daliai taip pat galioja  $n_d^{-1}\mathbf{V}'\Xi_0(n_d^{-1}\Xi'_0\Xi_0)^{-1}n_d^{-1}\Xi'_0\mathbf{V} \xrightarrow{p} \mathbf{Q}_{12}\mathbf{Q}_{22}^{-1}\mathbf{Q}'_{12}$ . Taigi iš (E.10):  $\hat{\mathbf{A}} - (\mathbf{V}_{11} - \mathbf{V}_{12}\mathbf{V}_{22}^{-1}\mathbf{V}'_{12}) \xrightarrow{p} \mathbf{0}$ , todėl  $\mathbf{G}_{11} - \mathbf{H}_{11} \xrightarrow{p} \mathbf{0}$ .

Tegu galioja  $\tilde{H}_0$ . Priede C parodyta, kad  $\sqrt{n_d}(\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma}))$  asimptotiškai pasiskirstęs pagal normalųjį dėsnį. Vadinas,  $\sqrt{n_d}(\hat{\beta}_{0,d} - \mathbf{f}(\hat{\gamma})) = \mathbf{O}_p(1)$ . Kadangi  $\hat{\sigma}_u^2 \xrightarrow{p} \sigma_u^2$  ir  $\mathbf{G}_{11} - \mathbf{H}_{11} \xrightarrow{p} \mathbf{0}$ , tai iš (E.9) išplaukia, kad  $T_5 - T_3 \xrightarrow{p} 0$ .

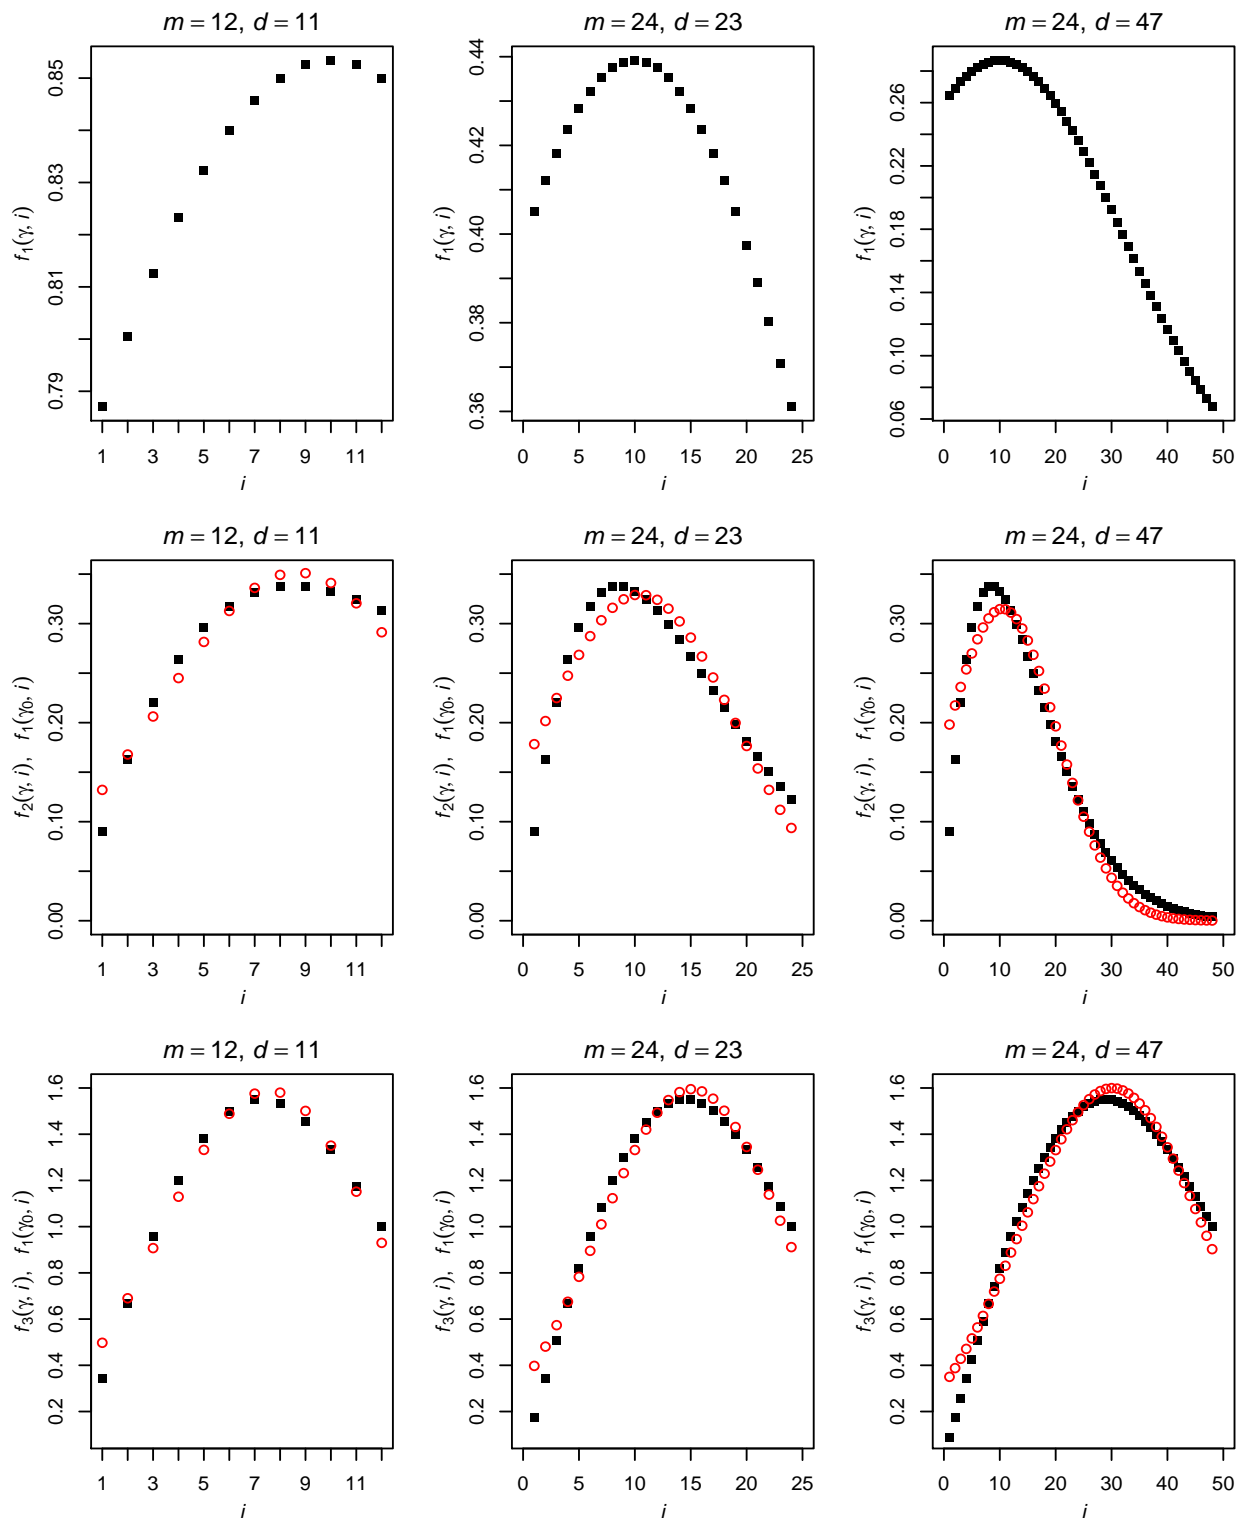
Tegu galioja  $\tilde{H}_1$ . Tegu  $\gamma_0 := \text{plim}(\hat{\gamma})$ . Kadangi  $\hat{\beta}_{0,d} \xrightarrow{p} \beta_{0,d}$  ir  $\mathbf{G}_{11} - \mathbf{H}_{11} \xrightarrow{p} \mathbf{0}$ , tai iš (E.9):

$$n_d^{-1}(T_5 - T_3) \xrightarrow{p} (\beta_{0,d} - \mathbf{f}(\gamma_0))' \mathbf{0} (\beta_{0,d} - \mathbf{f}(\gamma_0)) / \sigma_u^2 = 0.$$

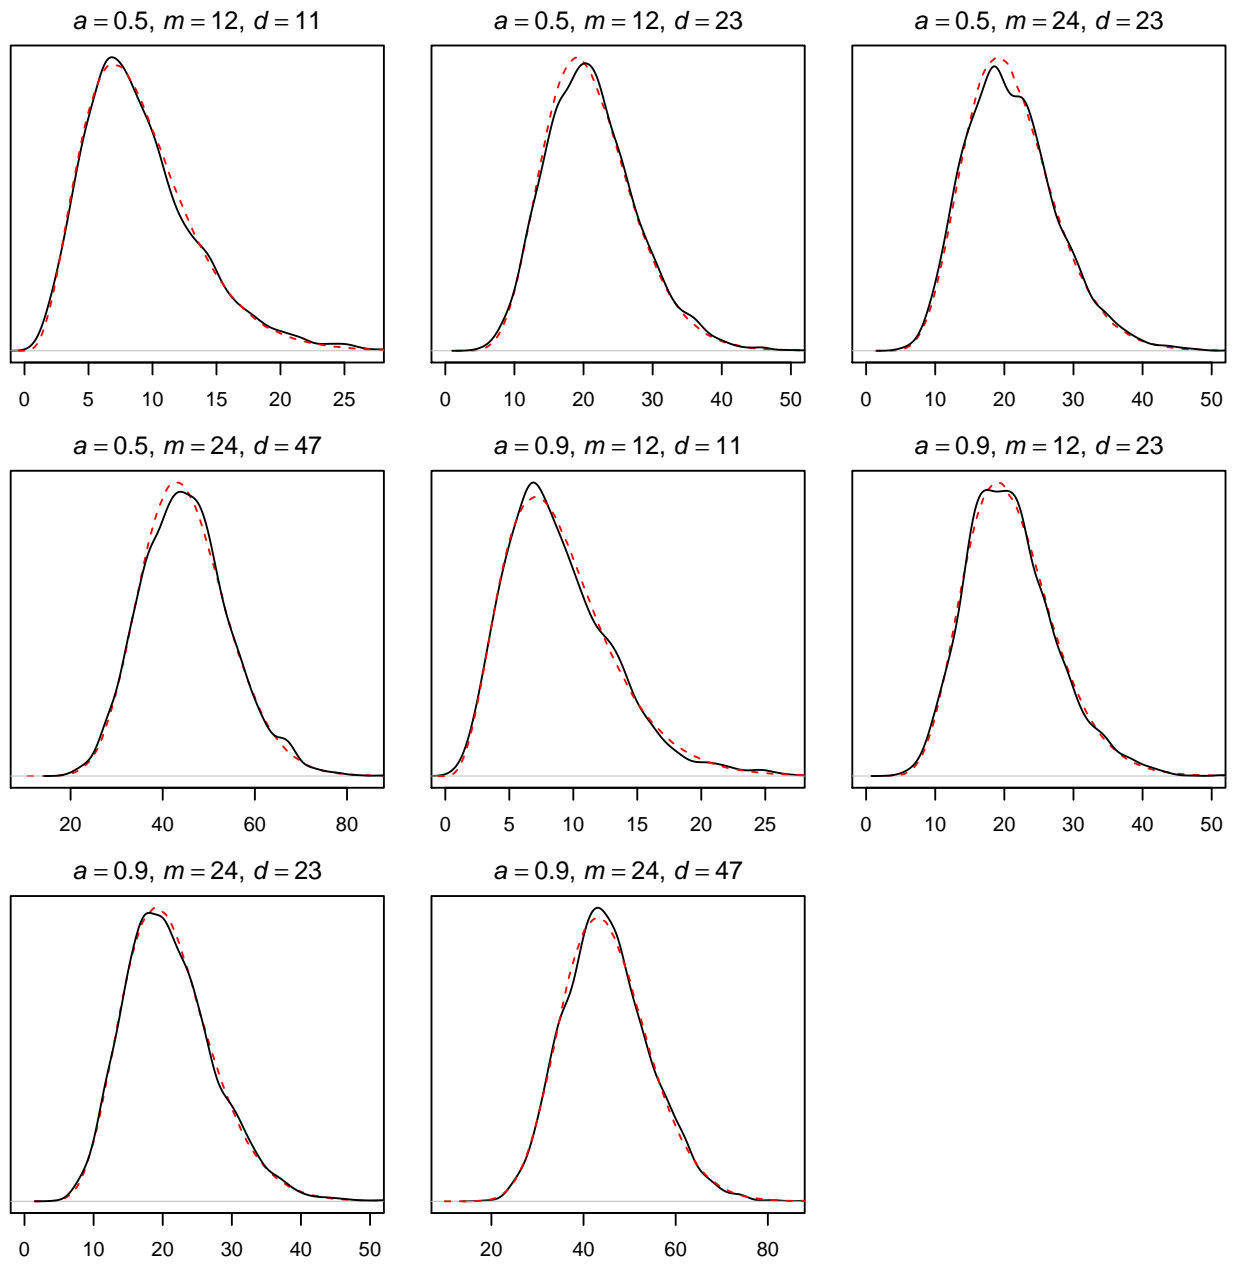
□

## II Grafikai

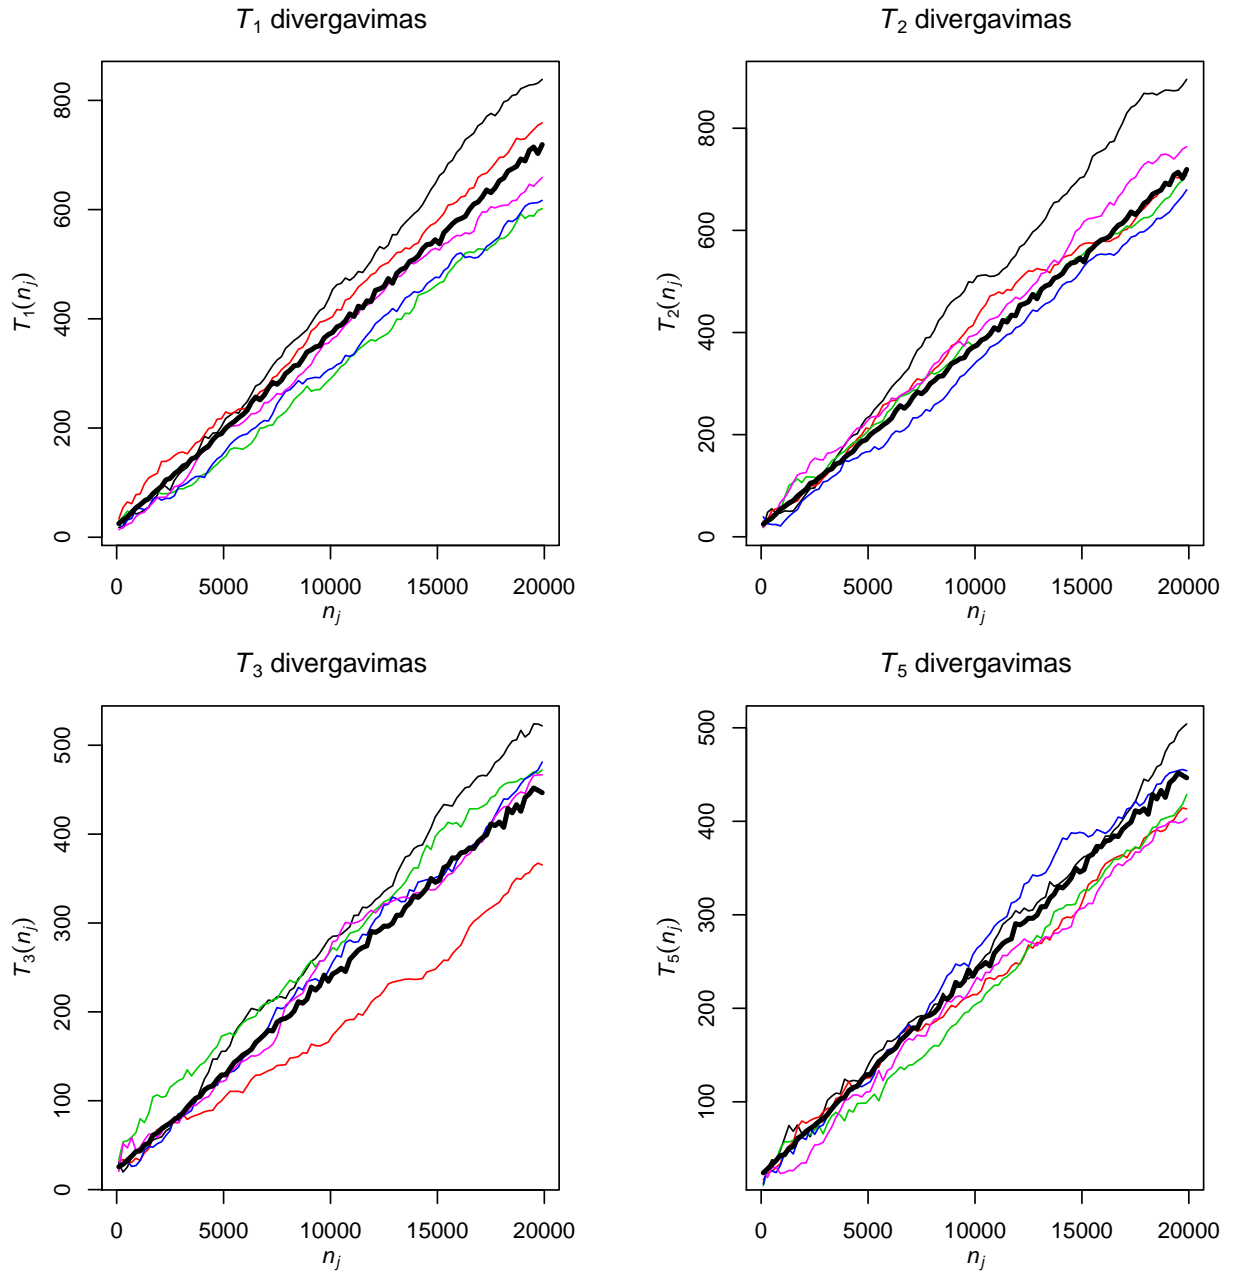
1 pav. Funkcijų  $f_j$  grafikai  $\{(i, f_j(\gamma, i))\}_{i=1, \dots, d+1}$ ,  $j = 1, 2, 3$ , bei funkcijos  $f_1$  geriausios aproksimacijos grafikai  $\{(i, f_1(\gamma_0, i))\}_{i=1, \dots, d+1}$ . Viršutiniai trys pav. atitinka funkcijos  $f_1$ , viduriniai – funkcijos  $f_2$ , apatiniai – funkcijos  $f_3$  grafikus, kurie piešiami juodais kvadratais. Raudoni tuščiaviduriai rutuliukai – geriausios  $f_1$  aproksimacijos funkcijoms  $f_2$  ir  $f_3$ .




2 pav. Statistikos  $T_3$  empirinės tankio funkcijos grafikai (juoda ištiesinė linija), kai  $\tilde{H}_0$  teisinga, bei  $\chi^2(d+1-3)$  atsitiktinio dydžio tankio funkcijos grafikai (raudona punktyrinė linija). Imties dydis  $n_d = 2\,000$ , Monte Carlo kartojimų skaičius  $rep = 4\,000$ .



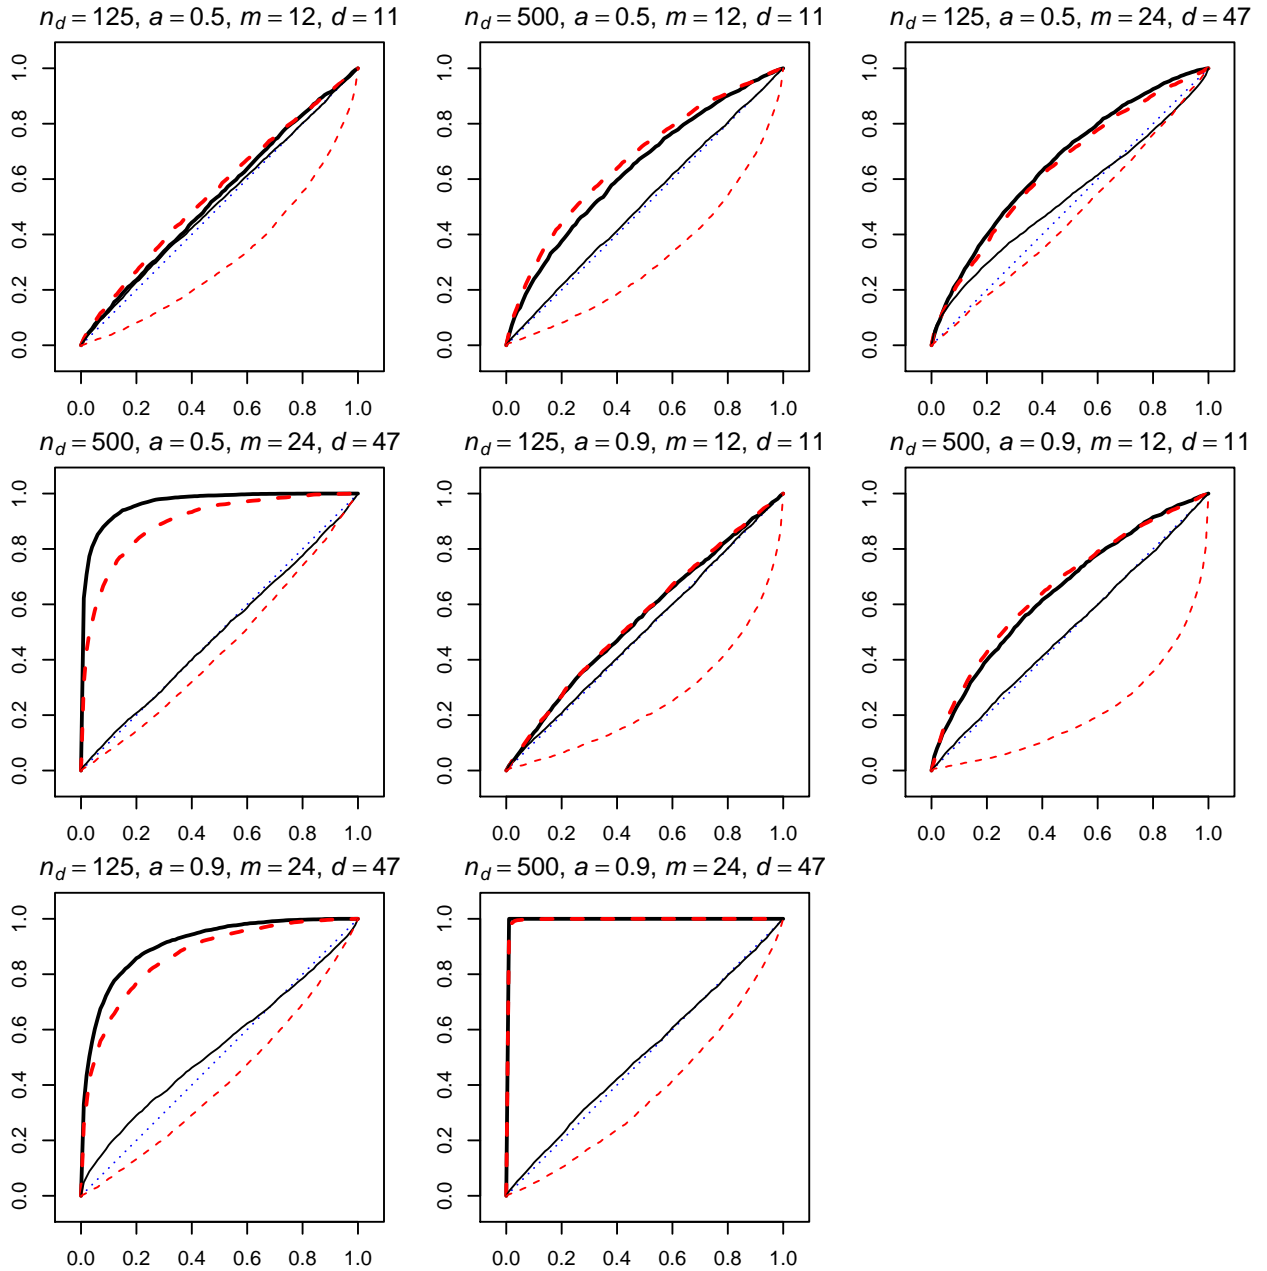
3 pav. Grafikų  $G_i := \{(n_j, T_i(n_j))\}_{j=1, \dots, k}$  realizacijos statistikoms  $T_1$ ,  $T_2$ ,  $T_3$  ir  $T_5$ , kai apribojimo funkcija pasirenkama neteisingai. Kiekvienai statistikai atskirame grafike pateikta po penkias  $G_i$  realizacijas, kurios žymimos plonesnėmis spalvotomis linijomis. Storesne juoda linija žymimi statistikų vidurkių grafikai  $\bar{G}_i := \{(n_j, \bar{T}_i(n_j))\}_{j=1, \dots, k}$ ,  $i = 1, 2, 3, 5$ , kai Monte Carlo kartojimų skaičius  $rep = 100$ .



4 pav. Statistikų  $T_M$  ir  $T_W$  empirinių tankio funkcijų grafikai skirtingiems imties dydžiams  $n_d$ , kai nulinė hipotezė teisinga. Juoda ištisinė linija žymi  $T_M$  empirinės tankio funkcijos grafiką, mėlyna taškinė-punktyrinė linija –  $T_W$  empirinės tankio funkcijos grafiką, kai Monte Carlo kartojimų skaičius  $rep = 4000$ . Raudona punktyrinė linija yra  $\chi^2(6)$  atsitiktinio dydžio tankio funkcijos grafikas.

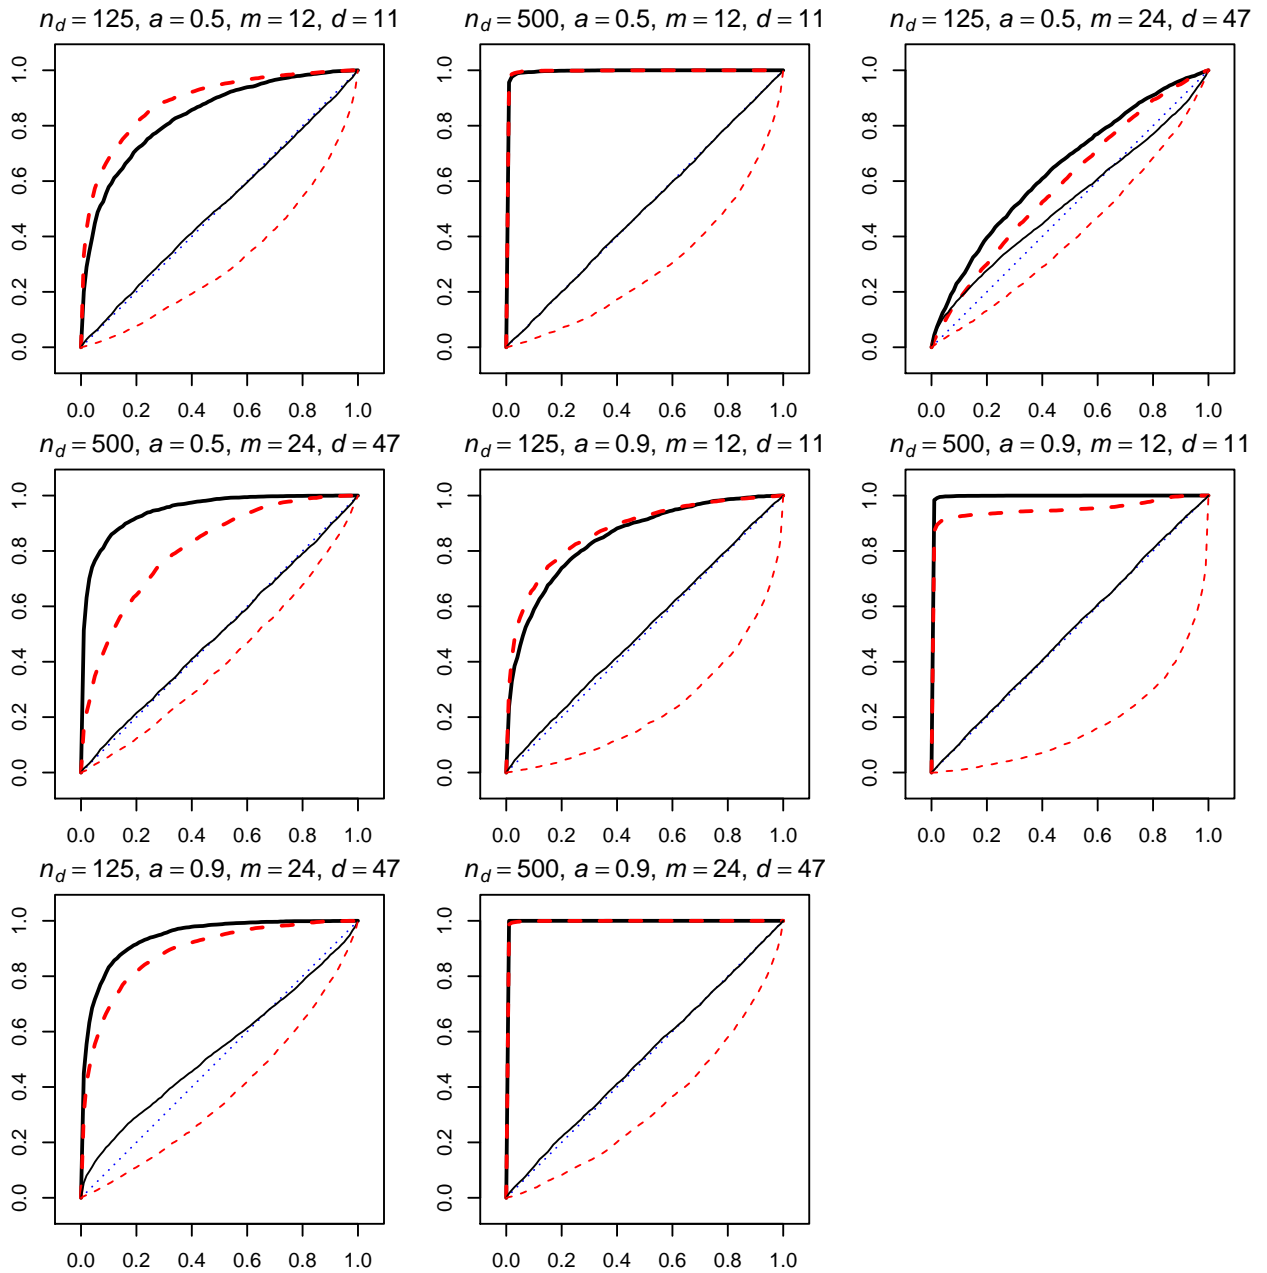


5 pav. ROC ir P-P kreivės statistikoms  $T_1$  ir  $T_M$ , kai parametrai  $\beta_{0,d}$  yra funkcijos  $f_2$  reikšmės. Stora juoda ištisinė linija – ROC kreivės statistikai  $T_1$ , stora raudona punktyrinė linija – ROC kreivės statistikai  $T_M$ . Plona juoda ištisinė linija – P-P kreivės statistikai  $T_1$ , plona raudona punktyrinė linija – P-P kreivės statistikai  $T_M$ . Mėlyna taškinė linija yra  $45^\circ$  tiesė. Monte Carlo kartojimų skaičius  $rep = 4000$ .





6 pav. ROC ir P-P kreivės statistikoms  $T_1$  ir  $T_M$ , kai parametrai  $\beta_{0,d}$  yra funkcijos  $f_3$  reikšmės. Stora juoda ištisinė linija – ROC kreivės statistikai  $T_1$ , stora raudona punktyrinė linija – ROC kreivės statistikai  $T_M$ . Plona juoda ištisinė linija – P-P kreivės statistikai  $T_1$ , plona raudona punktyrinė linija – P-P kreivės statistikai  $T_M$ . Mėlyna taškinė linija yra  $45^\circ$  tiesė. Monte Carlo kartojimų skaičius  $rep = 4000$ .



### III Lentelės

5 lentelė. Įvertinta testų galia statistikoms  $T_1$ ,  $T_2$  ir  $T_M$ , kai parametrams vertinti naudojama apribojimo funkcija  $f_1$ , o parametrai  $\beta_{0,d}$  yra funkcijų  $f_2$  arba  $f_3$  reikšmės. Reikšmingumo lygmuo  $\alpha^* = 0,05$ , Monte Carlo kartojimų skaičius  $rep = 4000$ .

$a$	$m$	$d$	$n_d$	$\beta_{0,d} = f_2(\gamma)$			$\beta_{0,d} = f_3(\gamma)$		
				$T_1$	$T_2$	$T_M$	$T_1$	$T_2$	$T_M$
0,5	12	11	75	0,092	0,084	0,024	0,298	0,290	0,205
			125	0,088	0,085	0,033	0,450	0,442	0,360
			200	0,092	0,090	0,038	0,700	0,696	0,639
			500	0,149	0,148	0,108	0,988	0,988	0,978
		23	75	0,184	0,168	0,086	0,276	0,260	0,180
			125	0,200	0,190	0,132	0,385	0,374	0,299
			200	0,297	0,290	0,234	0,582	0,575	0,523
			500	0,688	0,685	0,616	0,974	0,974	0,962
	24	23	75	0,182	0,168	0,104	0,279	0,262	0,171
			125	0,212	0,204	0,149	0,375	0,364	0,303
			200	0,278	0,272	0,210	0,584	0,578	0,511
			500	0,682	0,680	0,638	0,976	0,976	0,962
		47	75	0,298	0,262	0,085	0,302	0,261	0,056
			125	0,288	0,270	0,132	0,268	0,253	0,078
			200	0,382	0,368	0,188	0,328	0,320	0,090
			500	0,856	0,854	0,496	0,784	0,780	0,255
0,9	12	11	75	0,098	0,092	0,018	0,346	0,335	0,175
			125	0,086	0,096	0,032	0,519	0,511	0,288
			200	0,102	0,121	0,045	0,754	0,749	0,486
			500	0,164	0,176	0,065	0,996	0,996	0,810
		23	75	0,273	0,253	0,135	0,525	0,508	0,326
			125	0,370	0,360	0,238	0,763	0,757	0,613
			200	0,582	0,576	0,434	0,950	0,949	0,882
			500	0,967	0,967	0,925	1,000	1,000	1,000
	24	23	75	0,282	0,265	0,142	0,523	0,505	0,325
			125	0,386	0,376	0,235	0,779	0,771	0,596
			200	0,571	0,562	0,408	0,953	0,952	0,868
			500	0,977	0,976	0,924	1,000	1,000	0,999
		47	75	0,558	0,527	0,230	0,630	0,592	0,245
			125	0,764	0,754	0,400	0,852	0,844	0,441
			200	0,955	0,953	0,634	0,988	0,988	0,688
			500	1,000	1,000	0,987	1,000	1,000	0,992

6 lentelė. Įvertinta koreguota testų galia statistikoms  $T_1$ ,  $T_2$  ir  $T_M$ , kai parametrams vertinti naudojama apribojimo funkcija  $f_1$ , o parametrai  $\beta_{0,d}$  yra funkcijų  $f_2$  arba  $f_3$  reikšmės. Reikšmingumo lygmuo  $\alpha^* = 0,05$ , Monte Carlo kartojimų skaičius  $rep = 4\,000$ .

$a$	$m$	$d$	$n_d$	$\beta_{0,d} = f_2(\gamma)$			$\beta_{0,d} = f_3(\gamma)$		
				$T_1$	$T_2$	$T_M$	$T_1$	$T_2$	$T_M$
0,5	12	11	75	0,046	0,046	0,067	0,232	0,231	0,344
			125	0,069	0,068	0,083	0,397	0,396	0,532
			200	0,076	0,075	0,098	0,685	0,686	0,798
			500	0,152	0,151	0,126	0,988	0,988	0,993
		23	75	0,101	0,104	0,121	0,156	0,160	0,222
			125	0,134	0,134	0,168	0,292	0,290	0,374
			200	0,247	0,250	0,318	0,540	0,541	0,618
			500	0,680	0,680	0,712	0,970	0,970	0,975
	24	23	75	0,097	0,098	0,128	0,157	0,158	0,238
			125	0,160	0,158	0,209	0,286	0,282	0,366
			200	0,232	0,234	0,299	0,536	0,532	0,614
			500	0,657	0,656	0,704	0,972	0,972	0,980
		47	75	0,074	0,075	0,092	0,078	0,080	0,063
			125	0,144	0,148	0,144	0,132	0,133	0,109
			200	0,282	0,277	0,230	0,241	0,246	0,136
			500	0,831	0,832	0,545	0,748	0,746	0,347
0,9	12	11	75	0,078	0,080	0,070	0,262	0,258	0,356
			125	0,066	0,066	0,069	0,480	0,478	0,545
			200	0,086	0,080	0,080	0,742	0,742	0,736
			500	0,159	0,126	0,138	0,995	0,995	0,902
		23	75	0,158	0,158	0,206	0,342	0,346	0,468
			125	0,284	0,284	0,371	0,702	0,706	0,775
			200	0,500	0,499	0,608	0,932	0,932	0,944
			500	0,967	0,967	0,972	1,000	1,000	1,000
	24	23	75	0,145	0,155	0,214	0,372	0,374	0,471
			125	0,290	0,292	0,372	0,696	0,693	0,762
			200	0,530	0,527	0,612	0,943	0,944	0,957
			500	0,974	0,974	0,977	1,000	1,000	1,000
		47	75	0,224	0,229	0,272	0,248	0,266	0,319
			125	0,596	0,598	0,486	0,721	0,720	0,544
			200	0,932	0,933	0,713	0,976	0,976	0,806
			500	1,000	1,000	0,996	1,000	1,000	0,998